Universidad Nacional de Luján

PC-SMOTE: Una variante de SMOTE controlada por percentiles

Tesina de grado presentada para optar al título de
Licenciado en Sistemas de Información

Juan Natello

Director: Santiago Banchero

2026

RESUMEN

El aprendizaje automático supervisado enfrenta dificultades en conjuntos de datos con desbalance de clases, especialmente cuando este fenómeno se combina con el solapamiento estructural. En ese contexto, técnicas de sobremuestreo como SMOTE pueden degradar el rendimiento del clasificador si generan muestras sintéticas en regiones ambiguas del espacio de datos.

Este trabajo presenta **PC-SMOTE** (Percentile-Controlled SMOTE), una variante de SMOTE que utiliza una heurística geométrica basada en percentiles para definir radios de vecindad y combinar filtros de densidad, riesgo y pureza. El objetivo es regular la selección de semillas y la generación de muestras sintéticas de acuerdo con la distribución local de distancias observada en cada clase.

La metodología fue evaluada experimentalmente mediante un modelo Random Forest sobre diversos conjuntos de datos reales con asimetría severa, entre ellos Shuttle, US Crime, Telco Churn y Predict Faults. Los resultados sugieren que PC-SMOTE puede mejorar el rendimiento predictivo en escenarios con separabilidad local suficiente y, en casos de alto solapamiento, reducir la generación de sintéticos cuando la vecindad no resulta favorable, por lo que en conjunto estos hallazgos indican que la heurística propuesta puede ser útil para regular la interpolación en contextos geométricamente heterogéneos.

Palabras claves: Aprendizaje Automático, Desbalance de Clases, Solapamiento Estructural, Sobremuestreo, SMOTE, Geometría de Datos, Percentiles.

AGRADECIMIENTOS

Quiero agradecer a mi director de tesis Santiago Banchero por su dedicación y su guía constante a lo largo de todo el desarrollo de este trabajo, haciendo también extensivo este reconocimiento a mi esposa por su acompañamiento durante toda esta etapa, ya que su respaldo fue un pilar fundamental para poder transitar este exigente camino y alcanzar finalmente esta meta en mi carrera profesional

A mis padres, por los valores inculcados y el ejemplo de esfuerzo.
A mis hijos Giovanna y Dante, por ser mi mayor inspiración
y el motivo de cada paso que doy hacia el futuro.

Índice general

Resumen I

Índice VIII

1.. INTRODUCCIÓN Y OBJETIVOS 1
- 1.1. Introducción 1
- 1.2. Motivación 2
  - 1.2.1. Selección geométrica de semillas 2
- 1.3. Definición del Problema 2
- 1.4. Objetivos 3
  - 1.4.1. Objetivo General 3
  - 1.4.2. Objetivos Específicos 3
  - 1.4.3. Estructura de la Tesis 3

2.. MARCO TEORICO 5
- 2.1. Aprendizaje Automático y Clasificación 5
- 2.2. El Problema del Desbalance de Clases 5
- 2.3. Técnicas de Preprocesamiento: Remuestreo 7
  - 2.3.1. Sobremuestreo Sintético: Evolución Algorítmica y Sensibilidad Espacial 9
  - 2.3.2. Enfoques Híbridos: Integración Externa y Filtrado de Ruido 10
- 2.4. Conceptos Geométricos en Datos 10

3.. METODOLOGÍA 13
- 3.1. Arquitectura de PC-SMOTE 13
  - 3.1.1. Fase 1 (definición heurística de radios mediante percentiles) 15
    - 3.1.1.1. Límites geométricos y alta dimensionalidad 16
  - 3.1.2. Fase 2 (Filtros de pureza/ densidad y riesgo) 16
    - 3.1.2.1. El uso de un k fijo para evaluar la pureza 16
    - 3.1.2.2. Variación en la cantidad de semillas válidas 18
  - 3.1.3. Fase 3 (Etapa de Generación adaptativa) 18
- 3.2. Pipeline de sobremuestreo 20
  - 3.2.1. Descripción de los Conjuntos de Datos 20
- 3.3. Pipeline de entrenamiento y testeo 22
- 3.4. Métricas de Evaluación 22
  - 3.4.1. Precisión y Exhaustividad 24
  - 3.4.2. F1-score 24
  - 3.4.3. F1 macro-average 24

4.. RESULTADOS 25
- 4.1. Análisis de la configuración geométrica basada en percentiles 25
- 4.2. Análisis de Radios 25
  - 4.2.1. Lectura aplicada del análisis geométrico en Telco Churn 26
- 4.3. Dinámica de filtrado en PC-SMOTE 27
- 4.4. Análisis de resultados de la implementación de PC-SMOTE 35

5.. CONCLUSIONES Y TRABAJOS FUTUROS 41
5.1. Conclusiones 41
5.2. Discusión 41
5.3. Trabajos Futuros 42

Bibliografía 43

1. INTRODUCCIÓN Y OBJETIVOS

El desbalance de clases es un problema recurrente en la construcción de modelos de aprendizaje automático supervisado, ya que induce sesgos hacia la clase mayoritaria y reduce la capacidad del modelo para reconocer los casos minoritarios [6, 5, 1]. Esta limitación resulta especialmente relevante cuando la clase minoritaria concentra el mayor interés analítico o decisional.

Un ejemplo paradigmático de esta problemática es el dataset *Shuttle* [20], donde la detección de estados críticos en transbordadores espaciales se ve dificultada por el predominio de condiciones normales sobre las anomalías. En escenarios de este tipo, los modelos suelen favorecer a la clase mayoritaria y exhibir bajos niveles de sensibilidad ante eventos poco frecuentes.

Frente a este problema, las técnicas de sobremuestreo sintético se han consolidado como una alternativa para incrementar la representación de la clase minoritaria sin descartar datos [2, 1]. No obstante, su utilidad depende de que la generación de nuevas muestras respete la estructura local del espacio de datos. En ese marco, este trabajo estudia una variante de SMOTE que incorpora criterios de adaptabilidad geométrica y una heurística basada en percentiles para regular la selección de semillas y la generación de muestras sintéticas.

1.1. Introducción

Ante el escenario de desbalance previamente descrito, una respuesta ampliamente utilizada ha sido el preprocesamiento mediante remuestreo, cuyo objetivo es modificar la distribución de clases antes del entrenamiento [15, 5]. Estas estrategias suelen agruparse en tres familias principales: el submuestreo (*under-sampling*), que reduce la representación de la clase mayoritaria; el sobremuestreo (*over-sampling*), que incrementa la presencia de la clase minoritaria; y los enfoques híbridos, que combinan ambos mecanismos en un mismo esquema de remuestreo [6, 1]. Dentro de la familia de sobremuestreo, SMOTE se consolidó como un método clásico para la generación de muestras sintéticas [2].

Esta técnica interpola nuevos ejemplos entre vecinos minoritarios cercanos, lo que supuso un avance importante frente a la simple replicación de instancias. Sin embargo, su formulación original no considera explícitamente la estructura local de la clase mayoritaria ni el grado de solapamiento entre clases [1], por lo que puede introducir ruido, entendido aquí como muestras sintéticas ubicadas en regiones ambiguas o poco seguras que deterioran la frontera de decisión del clasificador [11, 17]. En consecuencia, la utilidad del sobremuestreo depende en gran medida de cómo se define la vecindad local: qué vecinos observar, cuán cerca deben estar y con qué criterios aceptar una semilla para interpolar.

Este problema vuelve crítica la elección de los hiperparámetros que regulan la vecindad local, en particular el número de vecinos considerados, los radios o umbrales de cercanía y los criterios de aceptación por densidad, riesgo y pureza, que en muchos métodos se fijan de manera estática o empírica [12, 1]. A partir de esta limitación surgió la motivación central del presente trabajo: buscar una definición más adaptable de la cercanía entre muestras. Para ello, se parte de una primera ayuda provista por algoritmos basados en k vecinos más cercanos, que permiten relevar la vecindad inmediata de cada instancia, y luego se utiliza la distribución empírica de las distancias observadas para definir, mediante percentiles, qué significa que dos muestras estén "cerca" en cada conjunto de datos.

En esta tesis se mantiene fijo el número de vecinos k, mientras que se calibran experimentalmente los percentiles de radio para densidad y riesgo, el criterio de pureza y los umbrales de aceptación asociados. Esta preocupación por adaptar el sobremuestreo a la geometría local ya aparece en antecedentes relevantes de la literatura. Desde extensiones geométricas tempranas como G-SMOTE, que amplían la región de generación más allá del segmento lineal original [3], hasta propuestas recientes como LD-SMOTE y VS-SMOTE, orientadas a incorporar criterios locales de densidad y control del ruido [12, 17], se observa una evolución hacia técnicas cada vez más sensibles a la estructura espacial de los datos. En continuidad con esa línea, la propuesta desarrollada en esta tesis busca articular y combinar esas ideas mediante una heurística basada en percentiles que permita adaptar la geometría de trabajo a través de radios de densidad y riesgo, utilizando esa información tanto para la selección de semillas candidatas como para la generación de muestras sintéticas.

1.2. Motivación

Si bien el sobremuestreo es un terreno ampliamente explorado, persisten desafíos de investigación vinculados a la adaptabilidad de los algoritmos a la diversidad geométrica de los datos. Además, revisiones recientes señalan que el desempeño de los métodos de remuestreo depende en gran medida de su capacidad para identificar regiones problemáticas y ajustar su comportamiento al contexto local [1, p. 14], lo que motiva la incorporación de heurísticas basadas en percentiles que definan la noción de cercanía y vecindad según la geometría específica de cada conjunto de datos.

1.2.1. Selección geométrica de semillas

Por ello, resulta relevante estudiar estrategias que no se limiten a interpolar entre vecinos minoritarios, sino que también consideren la calidad geométrica de las instancias utilizadas como semillas. La incorporación de criterios de densidad, riesgo y pureza permite formular reglas de selección más sensibles a la estructura local del dataset.

Desde esta perspectiva, la propuesta de esta tesis se orienta al diseño de una técnica de remuestreo que combine percentiles y filtros geométricos para regular la elección de semillas candidatas y la posterior síntesis de ejemplos artificiales.

1.3. Definición del Problema

El principal inconveniente a resolver es la sinergia perjudicial que se produce entre el desbalance de clases y el solapamiento estructural (class overlap), ya que estudios previos han demostrado que la asimetría en la distribución de datos por sí sola no obstaculiza el aprendizaje si las clases son fácilmente separables. Sin embargo, la presencia del desbalance exacerba factores de dificultad como el solapamiento y los pequeños disyuntos (small disjuncts), elevando la complejidad del problema [1, 6]. En consecuencia, las escasas muestras de la clase minoritaria pueden quedar inmersas en regiones dominadas por la clase mayoritaria, degradando sustancialmente el rendimiento de los modelos de aprendizaje [4, 23].

Como ejemplo aplicado puede considerarse el escenario de mantenimiento predictivo industrial, evaluado en este trabajo mediante el dataset *Predict Faults* [10]. En este entorno, las maquinarias próximas a una falla pueden presentar parámetros térmicos y físicos muy similares a los de máquinas en funcionamiento normal, por lo que el espacio

de datos exhibe un alto grado de solapamiento y la frontera entre clases se vuelve difícil de delimitar.

Bajo estas condiciones, las técnicas de sobremuestreo que interpolan sin evaluar adecuadamente la seguridad de la vecindad local pueden generar instancias sintéticas en regiones ambiguas. Esto favorece la intrusión sobre el espacio de la clase dominante, aumenta el ruido y deteriora la capacidad del clasificador para distinguir entre condiciones normales y situaciones de falla.

Por lo tanto, el problema central radica en la falta de criterios geométricos basados en percentiles que permitan ajustar los umbrales de densidad, riesgo y pureza a partir de la evidencia empírica provista por cada dataset. Esto plantea la necesidad de una técnica que oriente la generación de muestras sintéticas hacia regiones más adecuadas para la interpolación y preserve, en la medida de lo posible, la estructura local del conjunto de datos original.

1.4. Objetivos

En función del problema planteado, esta investigación propone una variante de SMOTE que incorpora criterios de adaptabilidad geométrica y una heurística basada en percentiles para regular la generación de muestras sintéticas.

1.4.1. Objetivo General

El objetivo general de este trabajo es desarrollar y validar un algoritmo de sobremuestreo, denominado PC-SMOTE, que incorpore criterios geométricos basados en percentiles para mejorar el rendimiento de modelos de clasificación en conjuntos de datos desbalanceados.

1.4.2. Objetivos Específicos

Para alcanzar este objetivo general, se plantean los siguientes objetivos específicos:

- **Sintetizar** el marco teórico y las limitaciones de los métodos actuales de sobremuestreo.
- **Formalizar** las etapas de funcionamiento de PC-SMOTE y describir los criterios geométricos que intervienen en cada una de ellas.
- **Implementar** PC-SMOTE en un entorno de desarrollo que permita su reproducción experimental.
- **Analizar** el comportamiento de PC-SMOTE en distintos escenarios de solapamiento y ruido.
- **Validar** estadísticamente la técnica mediante pruebas experimentales sobre datasets con alta disparidad.

1.4.3. Estructura de la Tesis

Para facilitar la lectura, la tesis se organiza en cinco capítulos. El primer capítulo introduce el problema del desbalance de clases, su relación con el solapamiento estructural y los objetivos que orientan el trabajo.

El segundo capítulo presenta los fundamentos teóricos y matemáticos relevantes. En particular, revisa la evolución de las técnicas de sobremuestreo y discute la necesidad de incorporar criterios de adaptabilidad geométrica y heurísticas basadas en percentiles.

El tercer capítulo describe la arquitectura y el funcionamiento de PC-SMOTE, incluyendo sus etapas principales y el flujo general del proceso de remuestreo, entrenamiento y evaluación.

El cuarto capítulo expone el diseño experimental y los resultados obtenidos, comparando la propuesta con métodos de referencia.

Finalmente, el quinto capítulo presenta las conclusiones generales, las limitaciones del estudio y posibles líneas de trabajo futuro.

2. MARCO TEORICO

En el presente capítulo se establecen las bases teóricas y conceptuales sobre las cuales se sostiene esta investigación: inicialmente se abordarán los fundamentos del aprendizaje automático y la clasificación supervisada, luego se profundizará en el problema del desbalance de clases y en la forma en que el solapamiento estructural exacerba su dificultad, y posteriormente se describirán las técnicas de preprocesamiento con especial énfasis en el sobremuestreo y en SMOTE como método clásico. Finalmente, se introducirán conceptos geométricos relevantes para el análisis de vecindades y el uso de percentiles como heurística para definir radios de trabajo, lo que constituye el núcleo teórico del algoritmo propuesto en este trabajo.

2.1. Aprendizaje Automático y Clasificación

El aprendizaje automático supervisado tiene como objetivo principal inducir un modelo o clasificador capaz de predecir la clase de salida para instancias previamente no vistas, buscando siempre una alta capacidad de generalización [6]. En términos formales, el proceso de clasificación implica obtener una aproximación empírica de una función desconocida para mapear un vector de entrada multidimensional hacia valores objetivo o etiquetas de clase específicas [1], a partir del conocimiento extraído de un conjunto de entrenamiento compuesto por instancias cuyas etiquetas ya son conocidas por el sistema.

2.2. El Problema del Desbalance de Clases

En el ámbito de la clasificación, un conjunto de datos se considera desbalanceado cuando existe una disparidad significativa en el número de muestras que pertenecen a las diferentes clases. Convencionalmente, la clase con el menor número de instancias se denomina clase minoritaria (o positiva) y suele representar el concepto de mayor interés analítico, mientras que la clase predominante se conoce como clase mayoritaria (o negativa) [6, 5, 1].

El principal inconveniente de esta condición es que los algoritmos de clasificación estándar asumen distribuciones de clases relativamente equilibradas y son guiados por métricas de evaluación globales, como la precisión general (accuracy). Esto provoca que el modelo tienda a sesgarse hacia la clase mayoritaria para maximizar su rendimiento, ignorando a menudo a los ejemplos de la clase minoritaria al ser incapaz de distinguirlos o al tratarlos simplemente como ruido [5].

Sin embargo, revisiones recientes en la literatura demuestran que la asimetría por sí sola no obstaculiza el proceso de aprendizaje si las clases son fácilmente y linealmente separables [18, 1], y en ese marco el desbalance actúa más bien como un catalizador que exacerba otros factores de dificultad intrínsecos de los datos, siendo el **solapamiento de clases (class overlap)** uno de los fenómenos más perjudiciales [18, 1]. Este solapamiento ocurre cuando existen regiones del espacio pobladas simultáneamente por muestras de diferentes clases, lo que dificulta definir una frontera de decisión clara sin inducir sobreajuste [6, 18] y, cuando además la escasez de muestras minoritarias se combina con ese escenario, las instancias positivas quedan inmersas en regiones dominadas por la clase negativa, elevando drásticamente la complejidad del problema y degradando el rendimiento predictivo [5, 1].

La Figura 2.1 presenta una representación conceptual de este fenómeno sobre un plano bidimensional de atributos, donde ambas clases comparten una región común y la delimitación de la frontera de decisión se vuelve menos nítida. En estas figuras, los ejes f_1 y f_2 representan dos atributos del conjunto de datos, de modo que cada punto corresponde a una muestra observada en ese subespacio de características y no a la gráfica de una función.

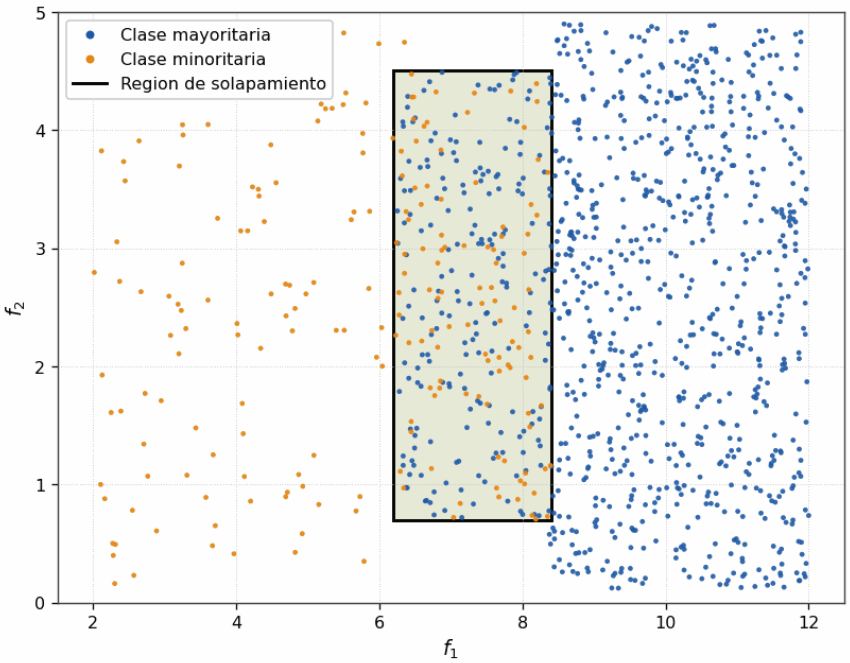

Figura 2.1: Representación conceptual del solapamiento estructural entre clases.

Otro factor de dificultad estrechamente relacionado son los **pequeños disyuntos** (*small disjuncts*), entendidos como subregiones pequeñas y escasamente representadas de una clase que quedan aisladas respecto del patrón dominante de esa misma clase [6, 1]. Debido a su reducido tamaño, estas estructuras tienden a quedar mal modeladas por el clasificador y se vuelven especialmente frágiles cuando, además, coexisten con desbalance y solapamiento.

La Figura 2.2 ilustra este concepto mediante pequeños grupos minoritarios escasamente representados y muestra que su dificultad aumenta cuando alguno de ellos queda inmerso en una región de solapamiento con la clase mayoritaria.

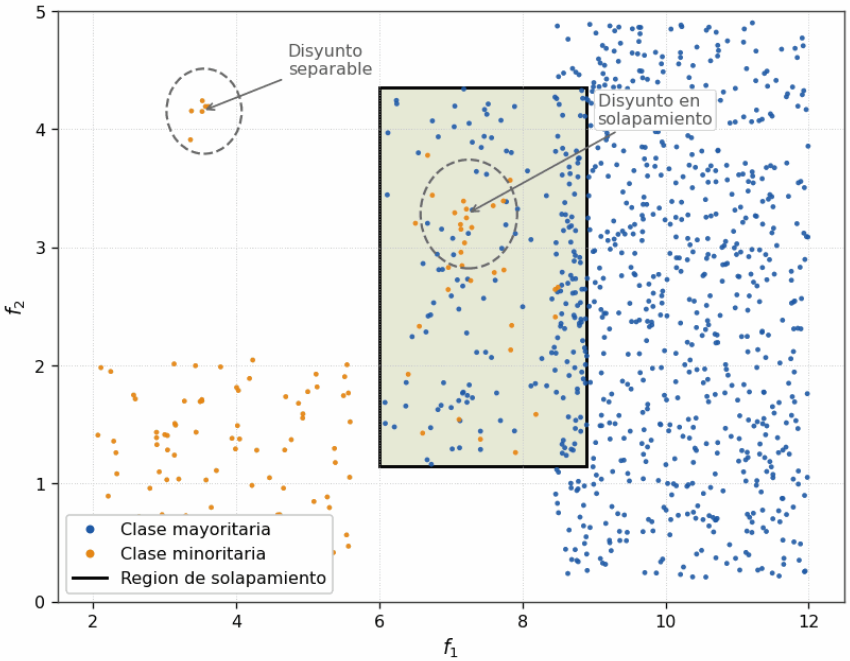

Figura 2.2: Representación conceptual de pequeños disyuntos minoritarios y de su mayor dificultad cuando coexisten con solapamiento.

2.3. Técnicas de Preprocesamiento: Remuestreo

En la literatura sobre aprendizaje con clases desbalanceadas suele distinguirse, en primer lugar, entre estrategias a nivel de datos, a nivel del algoritmo, sensibles al costo y basadas en *ensembles* [5]. La propuesta desarrollada en esta tesis se inscribe dentro del primer grupo, ya que interviene sobre la distribución del conjunto de entrenamiento antes de la etapa de aprendizaje, sin modificar internamente el funcionamiento del clasificador.

Dentro de las estrategias a nivel de datos, el remuestreo constituye una de las familias más utilizadas para corregir la asimetría entre clases [15, 1]. Estas técnicas suelen agruparse en tres grandes subfamilias: el submuestreo (under-sampling), que reduce la representación de la clase mayoritaria; el sobremuestreo (over-sampling), que incrementa la presencia de la clase minoritaria; y los enfoques híbridos, que combinan ambos mecanismos en un mismo esquema de remuestreo [6, 1]. La Figura 2.3 resume esta organización general y sitúa el recorte específico adoptado en este trabajo.

Dentro del sobremuestreo, además, resulta útil diferenciar entre sobremuestreo aleatorio y sobremuestreo sintético. El primero equilibra la clase minoritaria mediante la réplica de instancias ya observadas; su simplicidad lo convierte en un punto de partida natural, aunque sus limitaciones son conocidas, en particular la posibilidad de inducir sobreajuste al duplicar ejemplos idénticos [1, p. 15]. El segundo, en cambio, busca generar nuevas muestras a partir de la estructura local de la clase minoritaria. Dentro de este último grupo pueden distinguirse variantes lineales clásicas, enfoques orientados a frontera o dificultad, métodos geométricos con sensibilidad espacial y esquemas híbridos apoyados en *clustering* o filtrado previo. En este marco, PC-SMOTE puede ubicarse dentro del sobremuestreo sintético geométrico con sensibilidad local, en línea con la discusión de Carvalho et al. sobre métodos que identifican regiones apropiadas para sobremuestrear y adaptan la generación a la estructura local del espacio de datos [1, p. 19], así como con la idea de Santos et al. de que el desbalance debe analizarse conjuntamente con el solapamiento estructural

[18, pp. 228–229].

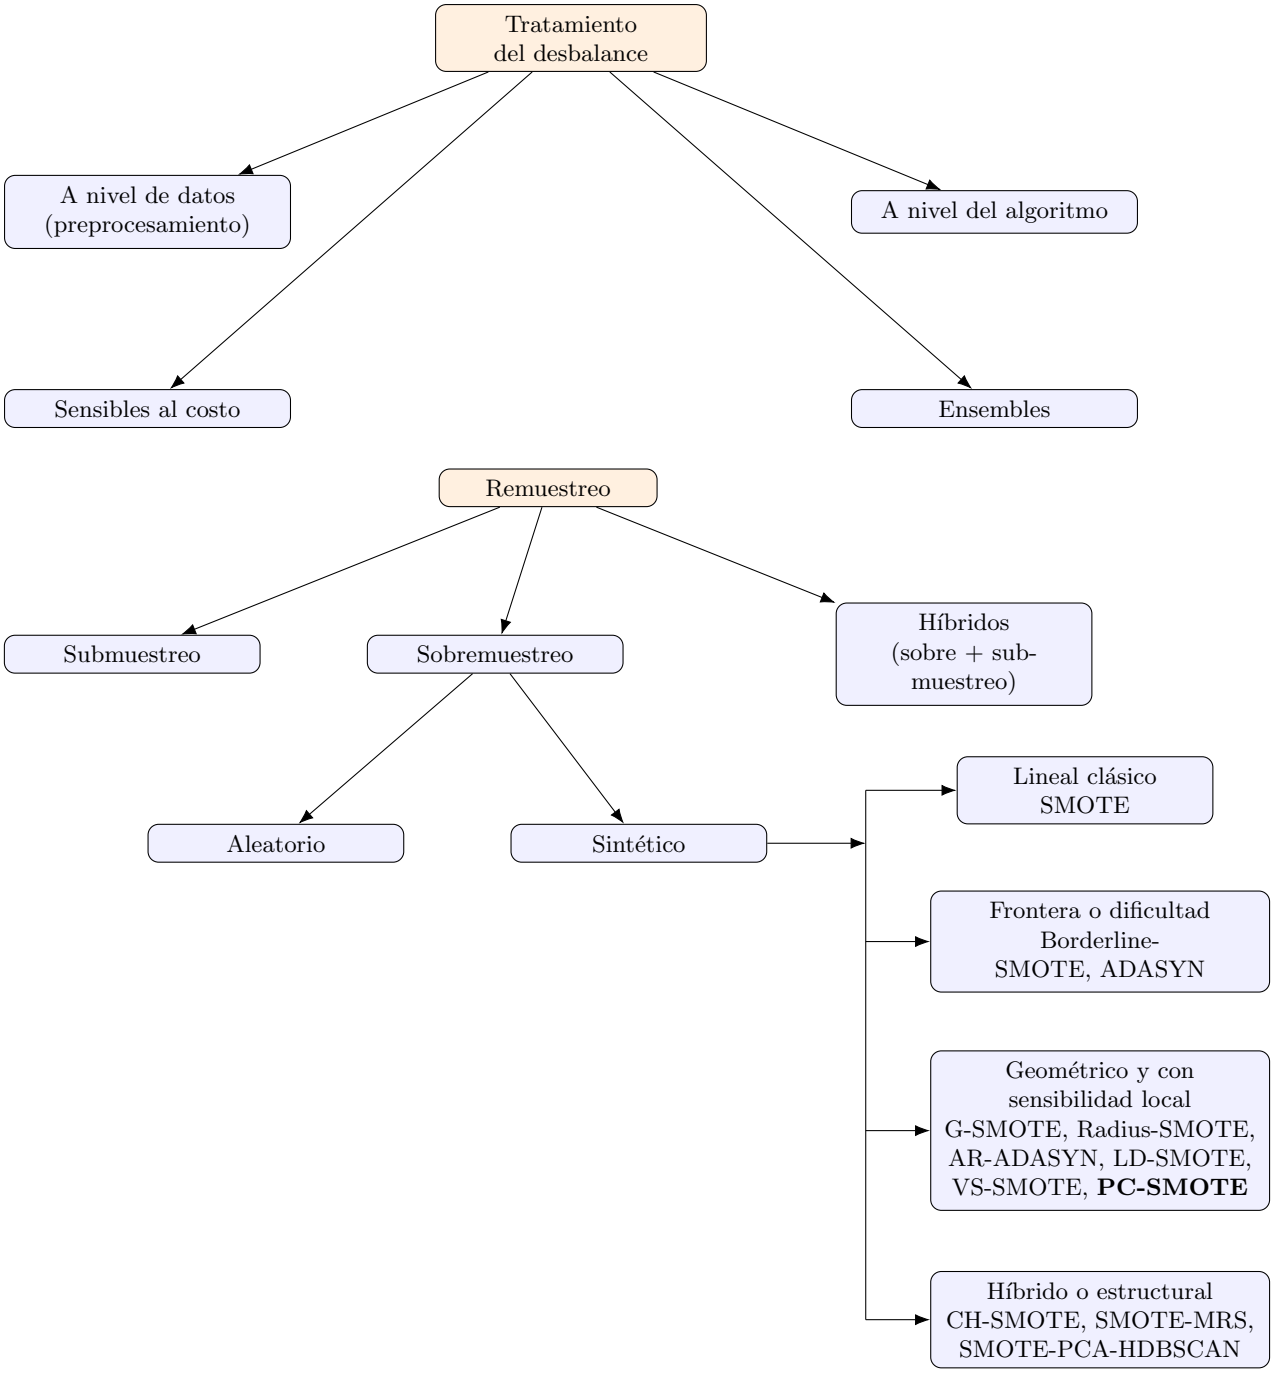

Figura 2.3: Árbol conceptual de familias y subfamilias para el tratamiento del desbalance. Arriba se muestran las familias generales; abajo se detalla la rama de remuestreo relevante para esta tesis.

La Figura 2.4 resume de forma esquemática las dos operaciones básicas del remuestreo, sobre las cuales también se construyen los enfoques híbridos: el submuestreo actúa eliminando observaciones de la clase mayoritaria, mientras que el sobremuestreo incrementa la presencia de la clase minoritaria mediante la incorporación de nuevas muestras.

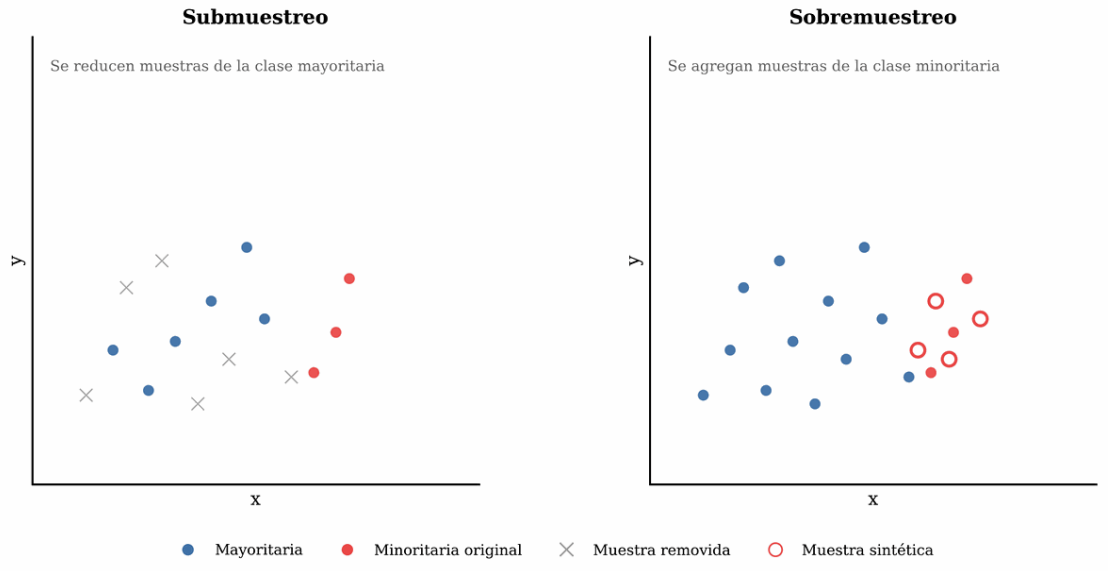

Figura 2.4: Representación conceptual de las operaciones básicas de remuestreo: submuestreo y sobremuestreo.

2.3.1. Sobremuestreo Sintético: Evolución Algorítmica y Sensibilidad Espacial

Para comprender la evolución de las técnicas de sobremuestreo resulta fundamental analizar primero aquellas metodologías que buscaron mejorar el mecanismo interno de generación, cuyo punto de partida es SMOTE, introducido por Chawla et al. [2], que equilibra las clases mediante interpolación lineal entre ejemplos minoritarios y cuyas limitaciones espaciales motivaron variantes tempranas como Borderline-SMOTE de Han et al. [7], que restringe la generación a muestras cercanas a la frontera de decisión, y ADASYN de He et al. [8], que adapta la cantidad de ejemplos sintéticos según la dificultad local de aprendizaje.

Esta primera etapa evolutiva dio paso a una segunda generación de algoritmos enfocados en la restricción geométrica: G-SMOTE de Douzas y Bacao [3] generaliza el mecanismo de SMOTE al permitir la generación dentro de una región geométrica flexible alrededor de cada instancia minoritaria, cuya forma y extensión pueden ajustarse mediante transformaciones geométricas y distintas estrategias de selección de vecindad, con el objetivo de reducir ejemplos ruidosos y aumentar la variedad de muestras sintéticas, mientras que Radius-SMOTE de Pradipta et al. [16] delimita una región segura circular para acotar el espacio de generación de muestras sintéticas y AR-ADASYN de Park y Kim [14] incorpora información angular para refinar ADASYN y obtener una distribución radial más fiel, aunque conserva sensibilidad a la selección de vecinos lejanos.

En una línea similar, αDBASMOTE de Feng y Li [4] combina elementos de Borderline-SMOTE y ADASYN mediante un factor de distancia ponderada para estimar la vulnerabilidad espacial. En conjunto, estas propuestas representan avances frente a la interpolación lineal ciega, pero también evidencian que el uso de métricas rígidas dificulta capturar la heterogeneidad geométrica de los conjuntos de datos.

A estas innovaciones se sumaron arquitecturas estructurales de gran valor como OCH-SMOTE de Wang y Awang [22], que perfecciona la selección global forzando la interpolación hacia el centro de gravedad de la clase minoritaria bajo la asunción de que dicha trayectoria es segura. A ello se añade SOMM, propuesto por Khorshidi y Aickelin [11], que

intenta alejar las instancias sintéticas de la zona dominante mediante vectores direccionales, aunque ambos enfoques descansan en supuestos geométricos fuertes o en mecanismos reactivos, en lugar de evaluar preventivamente la seguridad del entorno local.

Esta misma necesidad de evaluación preventiva se observa en estimadores contemporáneos de notable complejidad: LD-SMOTE de Lyu et al. [12] estima rigurosamente la densidad local, aunque deja en segundo plano la evaluación de la pureza, mientras que VS-SMOTE de Qiu et al. [17] se enfoca en la pureza de los subespacios sin integrar un análisis profundo de densidad.

En conjunto, estas propuestas muestran que densidad y pureza suelen tratarse de manera parcial, manteniendo abierto el desafío de articular ambos criterios dentro de una misma estrategia de generación sintética.

2.3.2. Enfoques Híbridos: Integración Externa y Filtrado de Ruido

Por otro lado, la literatura también ha encarado el problema del desbalance de manera externa mediante enfoques híbridos que combinan el sobremuestreo con herramientas adicionales para filtrar el ruido o reestructurar el espacio antes de la clasificación, destacándose en esta rama el modelo SMOTE-MRS desarrollado por Saputra et al. [19] que integra SMOTE con agrupamiento K-Means para garantizar que las muestras sintéticas se produzcan dentro de subgrupos homogéneos, así como la propuesta SMOTE-PCA-HDBSCAN introducida por Nasaruddin et al. [13] que utiliza el análisis de componentes principales para reducir la dimensionalidad y luego aplica el clustering adaptativo HDBSCAN para detectar y eliminar el ruido de manera dinámica, a las que se suma la implementación de redes generativas antagónicas documentada por Zhou et al. [4], quienes combinaron el modelo CGAN con la distancia de Wasserstein para generar datos altamente realistas evitando la propagación de ruido.

Estas metodologías demuestran que, aunque los pipelines híbridos resultan potentes para depurar el conjunto de datos, la incorporación de arquitecturas de agrupamiento o redes neuronales externas incrementa el costo computacional y la cantidad de hiperparámetros a calibrar. En consecuencia, sigue siendo relevante investigar métodos de sobremuestreo que preserven la calidad geométrica de las muestras sintéticas sin depender de algoritmos auxiliares complejos.

2.4. Conceptos Geométricos en Datos

Para superar las deficiencias de la interpolación ciega de SMOTE, los enfoques del estado del arte han transitado hacia una evaluación de la geometría local de los datos. Este análisis permite categorizar a las muestras en regiones seguras (safe), de frontera (danger) o de ruido, dependiendo de la proporción y distancia de las clases presentes en su vecindario inmediato [1].

Para abordar adecuadamente la complejidad geométrica resulta indispensable asimilar que la densidad y distribución de la información en un conjunto de datos real nunca se presenta de manera uniforme, lo que convierte a la utilización de hiperparámetros estáticos o radios de vecindad fijos en una estrategia altamente ineficaz al momento de intentar capturar la verdadera estructura de las fronteras de decisión. En este contexto, la aplicación de **percentiles** en la minería de datos adquiere una utilidad relevante, ya que permite definir radios de vecindad a partir de la distribución empírica de distancias euclidianas evaluadas previamente mediante métodos tradicionales como k-NN, y desde esta perspectiva los percentiles pueden entenderse como una heurística geométrica para ajustar los radios de trabajo al entorno espacial observado.

El uso de percentiles permite adaptar el concepto de "radio" o "cercanía" a la morfología específica de cada clase y conjunto de datos, entendida como la forma que adopta su distribución espacial, así como su grado de concentración, dispersión y conectividad local. A su vez, cuando en este trabajo se alude a la topología de los datos, el término se utiliza en un sentido descriptivo y no formal para referir a cómo se organizan las vecindades y a qué tan conectadas o separadas aparecen las regiones del espacio de atributos. A partir de radios definidos heurísticamente mediante percentiles, es posible establecer umbrales de densidad local, pureza y riesgo, lo que favorece que la selección de semillas y la posterior generación de muestras sintéticas se concentren en entornos geométricamente más estables, mitigando la intrusión en el espacio de la clase mayoritaria y preservando la calidad informativa de los datos generados.

3. METODOLOGÍA

En estrecha consonancia con los fundamentos teóricos establecidos en el capítulo anterior, la presente sección describe el diseño metodológico adoptado para abordar el problema de la clasificación en conjuntos de datos con un desbalance severo. Esta investigación es de naturaleza experimental y cuantitativa, y tiene como propósito formalizar y evaluar la técnica de sobremuestreo PC-SMOTE, contrastándola con estrategias de remuestreo ya establecidas en el estado del arte. Por ello, la validación empírica resulta indispensable en este contexto, ya que permite aislar el efecto de la geometría local de los datos y medir de forma objetiva la capacidad del algoritmo para mejorar la generalización del modelo predictivo en escenarios complejos.

Esta evolución metodológica resulta crucial ya que, como afirman Santos et al. [18] y respaldan revisiones recientes de la literatura, el desbalance de clases por sí solo no es el único responsable de la degradación del rendimiento de los modelos predictivos, sino que es su sinergia con factores de dificultad intrínsecos —particularmente el solapamiento de clases (*class overlap*), los pequeños disyuntos (*small disjuncts*) y el ruido— lo que constituye el escenario estructural más perjudicial para el aprendizaje automático [1, p. 6]. Bajo estas condiciones, las técnicas tradicionales de sobremuestreo, como SMOTE, tienden a generar muestras sintéticas en regiones dominadas por la clase mayoritaria, incrementando el ruido y provocando un sobreajuste o sobregeneralización de las fronteras de decisión [1, p. 18]. Por ello, se vuelve necesario plantear un diseño orientado a los datos (*data-centric*) que evalúe activamente la viabilidad del espacio antes de sintetizar nueva información.

Para dar respuesta a este desafío estructural y garantizar una evaluación rigurosa, la metodología de este trabajo se organiza en tres etapas principales, de las cuales la primera describe la arquitectura de PC-SMOTE. Allí se presenta la formalización general del algoritmo y se desarrollan sus tres fases constitutivas: (1) la definición heurística de radios mediante percentiles, (2) la aplicación de filtros geométricos y de pureza para seleccionar semillas candidatas y (3) la etapa de generación e interpolación adaptativa para crear muestras minoritarias.

La segunda etapa detalla el *pipeline* (flujo de trabajo) de sobremuestreo implementado para la experimentación. Este abarca desde la preparación y limpieza inicial del conjunto de datos mediante la detección de anomalías con *Isolation Forest*, hasta la construcción de las distintas versiones sobremuestreadas del conjunto de entrenamiento.

La tercera etapa describe el proceso de entrenamiento y testeo del modelo base seleccionado (Random Forest), incluyendo la búsqueda y optimización de hiperparámetros, así como la elección de métricas de rendimiento robustas frente al desbalance —como la métrica *F1-macro*— para evaluar de manera justa la capacidad del clasificador para reconocer a la clase minoritaria de interés.

3.1. Arquitectura de PC-SMOTE

Previo a detallar los fundamentos de cada una de las fases que componen la arquitectura del modelo, se presenta a continuación la formalización general en pseudocódigo del algoritmo PC-SMOTE (Algoritmo 1). Esta representación permite visualizar el flujo lógico de los datos, desde la definición de radios hasta la generación sintética. La implementación completa en Python se encuentra disponible de forma pública en el repositorio

del proyecto.[1]

Algorithm 1 PC-SMOTE (Percentile-Controlled SMOTE)

Require: D: Conjunto de datos de entrenamiento ($D_{min} \cup D_{maj}$)
Require: k: Número de vecinos más cercanos a evaluar
Require: $PRdens, PRriesgo$: Percentiles base para la definición heurística de radios
Require: $U_{dens}, U_{riesgo}, U_{pureza}$: Umbrales de aceptación geométrica
Ensure: D_{new}: Conjunto de datos balanceado

// **Fase 1: Definición heurística de radios**
$Distancias \leftarrow \emptyset$
for cada $x_i \in D_{min}$ **do**
  $Vecinos \leftarrow$ obtener los k vecinos más cercanos de x_i en D
  Agregar las distancias euclidianas de $Vecinos$ a $Distancias$
end for
$Radio_{dens} \leftarrow Percentil(Distancias, PRdens)$
$Radio_{riesgo} \leftarrow Percentil(Distancias, PRriesgo)$

// **Fase 2: Filtros Geométricos y de Pureza**
$Semillas_Validas \leftarrow \emptyset$
for cada $x_i \in D_{min}$ **do**
  $Densidad_i \leftarrow \frac{|\{x_j \in D \text{ tal que } dist(x_i,x_j) \leq Radio_{dens}\}|}{k}$
  $Riesgo_i \leftarrow \frac{|\{x_j \in D_{maj} \text{ tal que } dist(x_i,x_j) \leq Radio_{riesgo}\}|}{k}$
  $Pureza_i \leftarrow CalcularPureza(x_i, k)$ ▷ Evaluado por proporción o entropía
  if $Densidad_i \geq U_{dens}$ **and** $Riesgo_i \leq U_{riesgo}$ **and** $Pureza_i \geq U_{pureza}$ **then**
    $Semillas_Validas \leftarrow Semillas_Validas \cup \{x_i\}$
  end if
end for

// **Fase 3: Etapa de Generación e Interpolación Adaptativa**
$N_{sinteticos} \leftarrow |D_{maj}| - |D_{min}|$
$Sinteticos \leftarrow \emptyset$
while $|Sinteticos| < N_{sinteticos}$ **and** $|Semillas_Validas| > 0$ **do**
  $x_{semilla} \leftarrow$ Seleccionar muestra aleatoria de $Semillas_Validas$
  $x_{vecino} \leftarrow$ Seleccionar vecino aleatorio de $x_{semilla}$ dentro del $Radio_{dens}$
  $\alpha \leftarrow Aleatorio(0{,}4, 0{,}6)$ ▷ Control de sobregeneralización
  $x_{nuevo} \leftarrow x_{semilla} + \alpha \times (x_{vecino} - x_{semilla})$
  $Sinteticos \leftarrow Sinteticos \cup \{x_{nuevo}\}$
end while
Retornar $D_{new} \leftarrow D \cup Sinteticos$

Las subsecciones siguientes desarrollan las tres fases que integran esta arquitectura: la definición heurística de radios, el filtrado de semillas candidatas y la generación adaptativa de muestras sintéticas.

[1] Repositorio del proyecto: `https://github.com/jnatmed/tesis_pcsmote_natello`

3.1.1. Fase 1 (definición heurística de radios mediante percentiles)

En esta fase se determinan los umbrales de radio por densidad y riesgo, junto con el umbral de entropía. Estos valores establecen los límites operativos de la vecindad, adecuando la escala espacial a la estructura de cada clase.

En este sentido, la heurística basada en percentiles permite fijar los umbrales de radio tanto para los cálculos de densidad como de riesgo, así como el umbral de entropía, de acuerdo con el percentil configurado. Para ello, el algoritmo toma cada muestra de la clase actual y recorre sus k vecinos más cercanos utilizando un clasificador k-NN. Para cada vecino se calcula la distancia euclidiana respecto de la muestra de referencia, y al finalizar este proceso se obtienen $X \times k$ distancias totales, donde X corresponde al número de instancias de la clase evaluada.

Sobre el conjunto total de distancias se calcula el percentil definido por el parámetro de configuración. El valor resultante se interpreta como un radio adaptativo que representa el umbral por densidad y el umbral por riesgo.

> «*El uso de percentiles busca representar de manera más flexible la noción de cercanía en datasets con densidades heterogéneas. En un dominio como Telco Churn, algunos subgrupos presentan alta concentración mientras otros son más dispersos, por lo que un radio único puede resultar excesivo en ciertos sectores e insuficiente en otros. La Fase 1 incorpora esta observación como una heurística geométrica para definir radios de trabajo a partir de la distribución empírica de distancias.*»

En el paso siguiente se calculan todas las métricas de densidad, riesgo y pureza —ya sea por proporción o por entropía— para la clase actual, utilizando los umbrales previamente obtenidos.

El cálculo de estas métricas, que caracterizan el comportamiento de los casos minoritarios en un conjunto de datos desbalanceado, constituye un proceso multifacético basado en la evaluación de la vecindad de cada instancia. Para ello, en primer lugar se determina la **densidad** de cada caso minoritario obteniéndose al contar cuántos de sus k vecinos más cercanos (sin distinguir a qué clase pertenecen) se encuentran a una distancia menor o igual al *Percentil Radio Densidad* (PRD), dado que el objetivo principal de este filtro es captar vecindades densas en términos generales, dejando el análisis estricto de las clases a cargo de los filtros de pureza por entropía o proporción.

En contraste, para evaluar la vulnerabilidad o la posible ubicación en la frontera entre clases, se calcula el **riesgo** de cada caso minoritario, contabilizando cuántos de los k vecinos más cercanos pertenecen a la clase mayoritaria y se encuentran a una distancia menor o igual al *Percentil Radio Riesgo* (PRR). Un riesgo elevado indica que la instancia minoritaria se encuentra peligrosamente próxima a la clase dominante, lo que sugiere que podría tratarse de un caso en zona de frontera o de difícil clasificación.

La última métrica puede aplicarse de dos maneras diferentes: la primera corresponde a la **pureza por proporción**, que consiste en contar cuántos vecinos de la misma clase existen dentro de la vecindad definida por los k vecinos más cercanos. Este cálculo constituye una forma directa de evaluar la cohesión local de la clase minoritaria, sin imponer una restricción basada en el radio percentil, y proporciona una visión clara de la concentración local de la clase de interés.

Alternativamente, la pureza puede evaluarse mediante la **entropía**, calculada para cada instancia minoritaria a partir de la distribución de clases presentes entre sus k vecinos más cercanos. Así, la entropía actúa como una medida de incertidumbre o mezcla de clases

en el entorno inmediato de la instancia, de modo que un valor alto indica un entorno altamente mezclado o ruidoso y sugiere que la instancia minoritaria se encuentra ubicada en una zona de solapamiento significativo entre clases.

3.1.1.1. Límites geométricos y alta dimensionalidad

Esta fase presenta una limitación geométrica importante: la distancia euclidiana resulta más fiable en espacios de baja o moderada dimensionalidad. En conjuntos con un número muy elevado de características, la convergencia de distancias asociada a la maldición de la dimensionalidad puede volver poco informativos los percentiles calculados [17, 22]. Por esta razón, en escenarios ultradimensionales se considera recomendable aplicar previamente técnicas de reducción de dimensionalidad, como PCA [13, 19], antes de estimar los radios heurísticos del algoritmo.

3.1.2. Fase 2 (Filtros de pureza/ densidad y riesgo)

A estos conjuntos de densidades, riesgos y pureza (proporción — riesgo) se les aplica el filtro correspondiente de densidad, riesgo y pureza, también recibidos por parámetro, quedando solo aquellas semillas que hayan superado los tres filtros.

Como demuestran enfoques recientes (Predipta et. al.[16]) filtrar las muestras minoritarias iniciales para descartar el ruido y conservar unicamente las instancias situadas en zonas estructuralmente seguras (SAFE), garantiza que la posterior generacion de sinteticos no invada el territorio de la clase mayoritaria ni provoque nuevos conflictos en las regiones de solapamiento.

Con el objetivo de complementar la interpretación de los casos ilustrados en las figuras siguientes, se desarrolló un recurso interactivo complementario accesible en línea.[2]

3.1.2.1. El uso de un k fijo para evaluar la pureza

Antes de aplicar los filtros de la Fase 2, es necesario justificar el uso de un parámetro de vecindad fijo (k) para el cálculo de la entropía. Aunque la Fase 1 define radios variables mediante percentiles, la entropía de Shannon requiere una base comparable entre instancias, por lo que se mantiene constante la cantidad de vecinos observados.

Esta decisión responde a un criterio de normalización: si el número de vecinos variara entre regiones densas y dispersas, los valores de entropía dejarían de ser directamente comparables. En consecuencia, la arquitectura adopta un valor constante de $k = 7$ para la evaluación de la pureza, mientras que el umbral de aceptación de dicha pureza se explora experimentalmente según el criterio utilizado.

De este modo, la estrategia experimental distingue entre parámetros fijos y parámetros explorados. Se mantiene fijo $k = 7$ como tamaño base del vecindario para preservar la comparabilidad entre instancias y clases, mientras que se varían los percentiles de radio para densidad y riesgo, el criterio de pureza (proporción o entropía), el parámetro asociado a ese criterio —umbral de pureza por proporción o percentil de entropía— y los umbrales de aceptación de densidad y riesgo.

De esta forma, la semilla candidata queda sometida a tres análisis geométricos complementarios: debe pertenecer a un vecindario suficientemente denso, presentar una presión acotada de vecinos contrarios y, simultáneamente, exhibir un nivel adecuado de pureza local.

[2] Recurso interactivo disponible en: `https://jnatmed.github.io/ejemplo-interactivo-pcsmote/pcsmote_interactivo.html`.

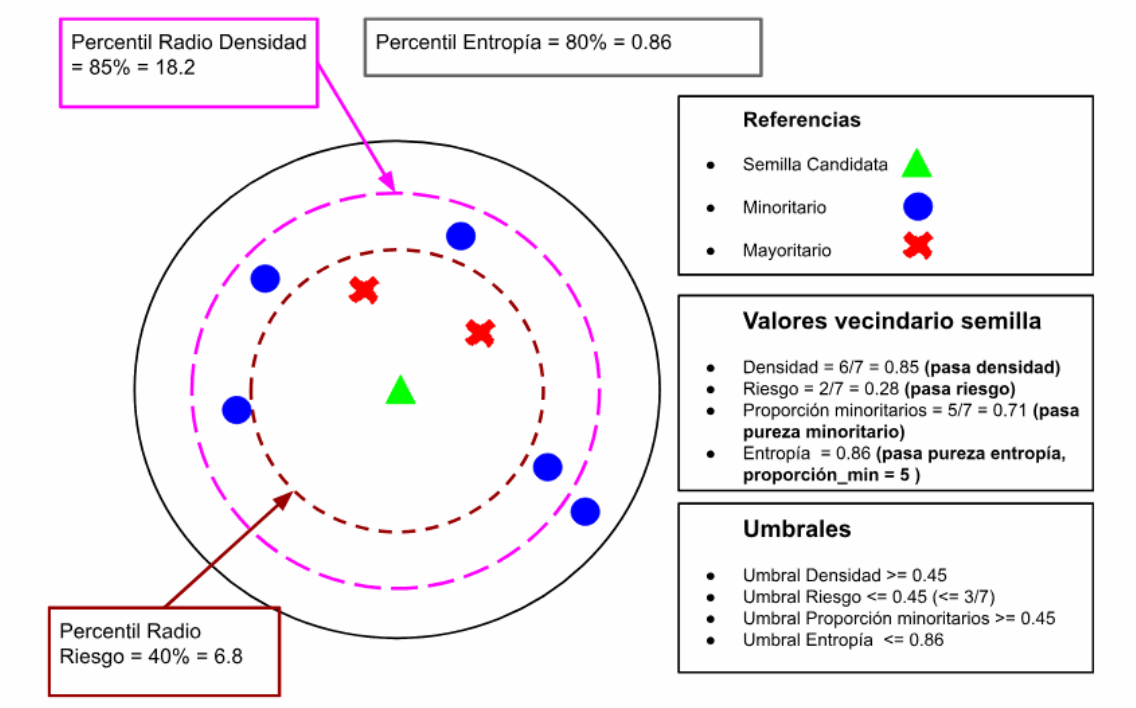

Figura 3.1: Caso Aceptacion Semilla Candidata

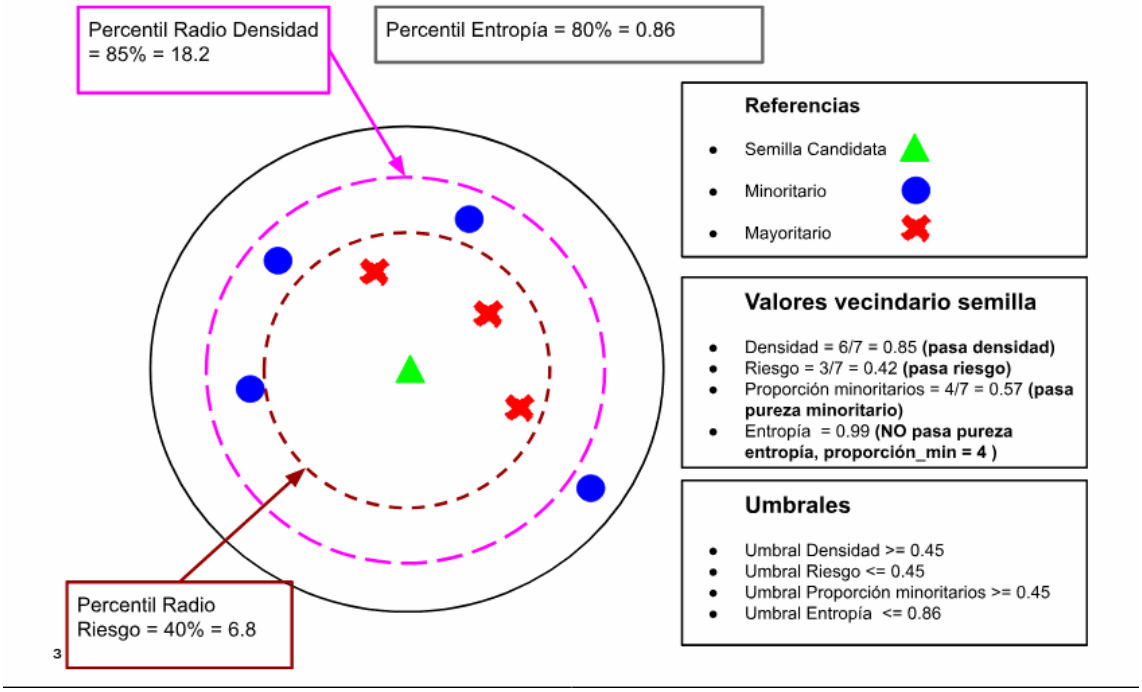

Figura 3.2: Caso Rechazo Semilla Candidata

Tabla 3.1: Análisis de vecindarios y criterios de aceptación en PC-SMOTE basados en entropía y proporción de clase.

V. Min.	V. May.	Prop. Min.	Entropía	Interpretación	Aceptación PC-SMOTE
7	0	1,00	0,00	Pureza absoluta	Aceptado (Ideal)
6	1	0,86	0,59	Contaminación mínima	Aceptado
5	2	0,71	0,86	Contaminación moderada	Aceptado
4	3	0,57	0,99	Frontera (Dom. Min.)	Aceptado
3	4	0,43	0,99	Frontera (Dom. May.)	Aceptado ($t_{dom} = 0,4$)
2	5	0,29	0,86	Ruido	Descartado
1	6	0,14	0,59	Ruido	Descartado
0	7	0,00	0,00	Vecindario opuesto	Descartado

El uso de percentiles y umbrales permite regular de manera escalonada y controlada la evaluación de los vecindarios obtenidos por el clasificador k-NN. En efecto, dicho clasificador identifica los vecinos más cercanos, pero no incorpora por sí mismo un criterio acerca de cuán apropiada resulta la distancia observada desde el punto de vista geométrico. Por ello, PC-SMOTE añade esta capa de análisis al examinar esos k vecinos mediante los filtros de densidad, riesgo y pureza, definiendo así si una semilla resulta apta para la generación de muestras sintéticas de la misma clase.

3.1.2.2. Variación en la cantidad de semillas válidas

La cantidad de semillas que superan los filtros de densidad, riesgo y pureza no se fija de antemano, sino que depende de la geometría local observada en cada clase. En consecuencia, PC-SMOTE puede operar con diferentes niveles de cobertura de semillas candidatas según el dataset y la configuración experimental considerada.

Este comportamiento forma parte del mecanismo de selección del algoritmo: solo las instancias que satisfacen simultáneamente los criterios definidos ingresan a la etapa de interpolación. El análisis empírico de cómo varía esta cobertura entre conjuntos de datos se presenta en el capítulo de resultados y se retoma en la discusión final.

3.1.3. Fase 3 (Etapa de Generación adaptativa)

En esta fase, al momento de examinar cada una de las semillas que pasaron el filtro, se seleccionan aquellos vecinos de su misma clase de manera aleatoria, pero se usan solo aquellos que estén dentro del $PR_{\text{radio_densidad}}$, a fin de asegurar la generación de sintéticos dentro del vecindario seguro.

Además, a diferencia de *SMOTE* que trabaja con σ entre 0,1 y 0,9, *PC-SMOTE* genera un σ entre 0,4 y 0,6 para procurar generar el nuevo sintético en medio de ambas muestras. La idea central es que no esté "accidentalmente" pegado a ninguna de las dos muestras, es decir, ni demasiado próximo a la semilla que superó los filtros, ni demasiado próximo al vecino con el cual va a interpolar.

Finalmente, tras estas dos verificaciones se procede a realizar el cálculo de interpolación correspondiente.

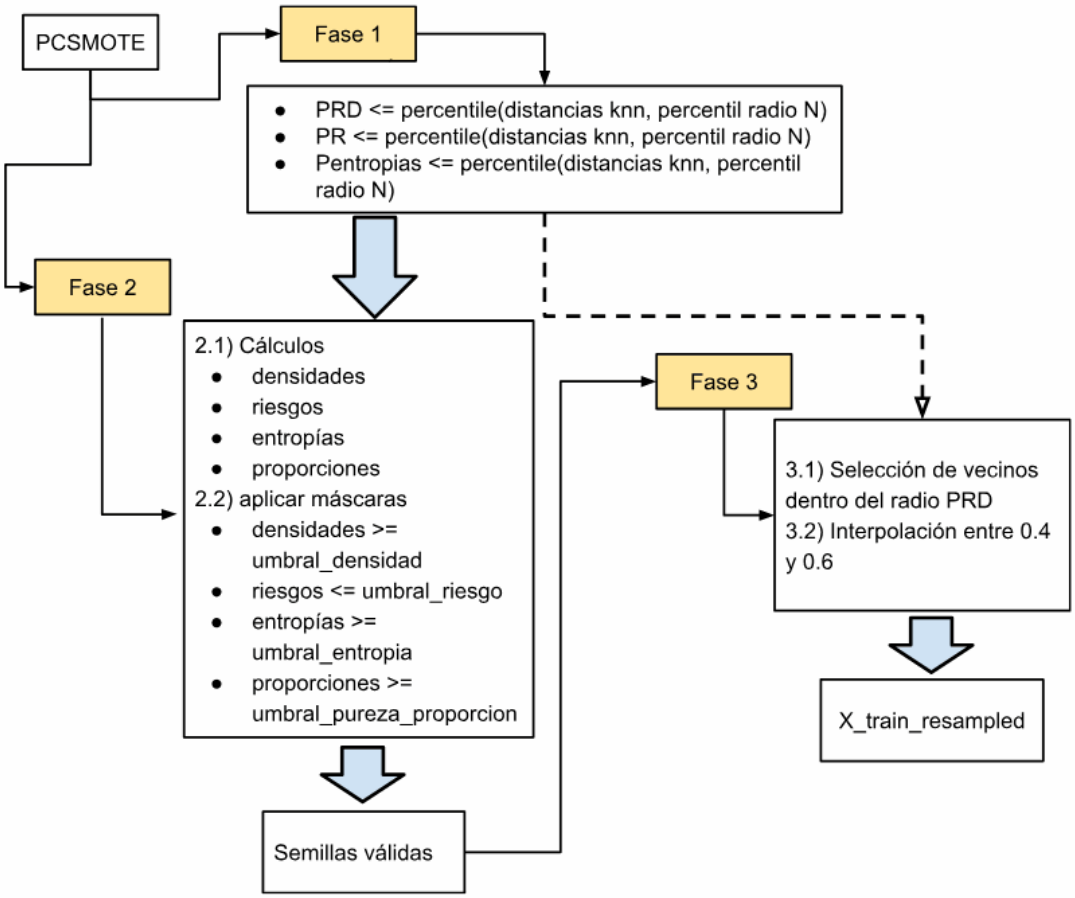

Figura 3.3: Etapas del sobremuestreo de PC-SMOTE

3.2. Pipeline de sobremuestreo

La Figura 3.4 ilustra el *pipeline* de sobremuestreo, cuyo proceso comienza con la división de cada *dataset* en conjuntos de entrenamiento (*train*) y de prueba (*test*). A partir del conjunto de entrenamiento, se calculan la mediana y el rango intercuartílico, definido por el primer cuartil (Q_1, percentil 25) y el tercer cuartil (Q_3, percentil 75).

Posteriormente, tanto el conjunto de entrenamiento como el de prueba se escalan. La normalización se realiza utilizando la técnica *Robust Scaler* (ver Ecuación 3.1), que consiste en restar la mediana a cada muestra y dividir el resultado por la diferencia entre Q_3 y Q_1:

$$X_{scaled} = \frac{X - \text{mediana}}{Q_3 - Q_1} \tag{3.1}$$

El conjunto de datos de testeo se reserva inicialmente para la etapa de prueba del modelo de aprendizaje, tras lo cual el trabajo se centra exclusivamente en el conjunto de entrenamiento. El conjunto de datos de testeo se obtiene de este conjunto inicial y se utiliza para evaluar el rendimiento final del modelo.

El proceso de preparación del conjunto de entrenamiento comienza con la Limpieza de Datos, donde se aplica el algoritmo *Isolation Forest*. Este proceso se ajusta mediante umbrales de percentiles predefinidos (0 % para no aplicación, 1 % para limpieza leve, 3 % para limpieza media y 5 % para limpieza profunda) para controlar el nivel de depuración.

Una vez reducido el tamaño del conjunto de entrenamiento a causa de la limpieza, se procede al Sobremuestreo (*Oversampling*) Clásico, para lo cual se emplean técnicas conocidas como *SMOTE*, *Borderline SMOTE* y *ADASYN*. Finalmente, se aplica la técnica de sobremuestreo propuesta en este trabajo: *PC-SMOTE*.

Como resultado de estas etapas de preparación, se obtienen cinco versiones distintas del conjunto de entrenamiento (*train set*) para cada *dataset*: el conjunto original, y cuatro conjuntos sobremuestreados utilizando *SMOTE*, *Borderline SMOTE*, *ADASYN* y *PC-SMOTE*, respectivamente. Con la obtención de estos cinco conjuntos, concluye la fase de preparación de datos, dando paso a la fase de entrenamiento y testeo del modelo de aprendizaje.

3.2.1. Descripción de los Conjuntos de Datos

Con el propósito de evaluar rigurosamente el comportamiento de la heurística geométrica propuesta, se seleccionaron cuatro conjuntos de datos reales que presentan desafíos críticos de desbalance y solapamiento estructural.

En primer lugar, destaca el dataset Shuttle, el cual se caracteriza por un predominio masivo de las condiciones de vuelo normales frente a las anomalías. Esto genera una pérdida sustantiva de información relevante al operar sobre 9 características numéricas que describen las posiciones de los radiadores en un transbordador espacial de la NASA [20].

A esto se suma el conjunto de datos Telco Churn, que refleja un escenario comercial de telecomunicaciones donde el abandono del servicio crea nubes de dispersión altamente irregulares [9]. Asimismo, se incorpora el dataset Predict Faults, cuyo entorno de mantenimiento predictivo industrial simula fallas en maquinarias empleando parámetros físicos y térmicos casi idénticos a los de funcionamiento normal [10].

Finalmente, el conjunto US Crime aporta un nivel adicional de ruido espacial mediante 143 características demográficas y socioeconómicas originales, incluyendo niveles de ingresos y composición racial [21]. Esta colección integral permite validar cómo la técni-

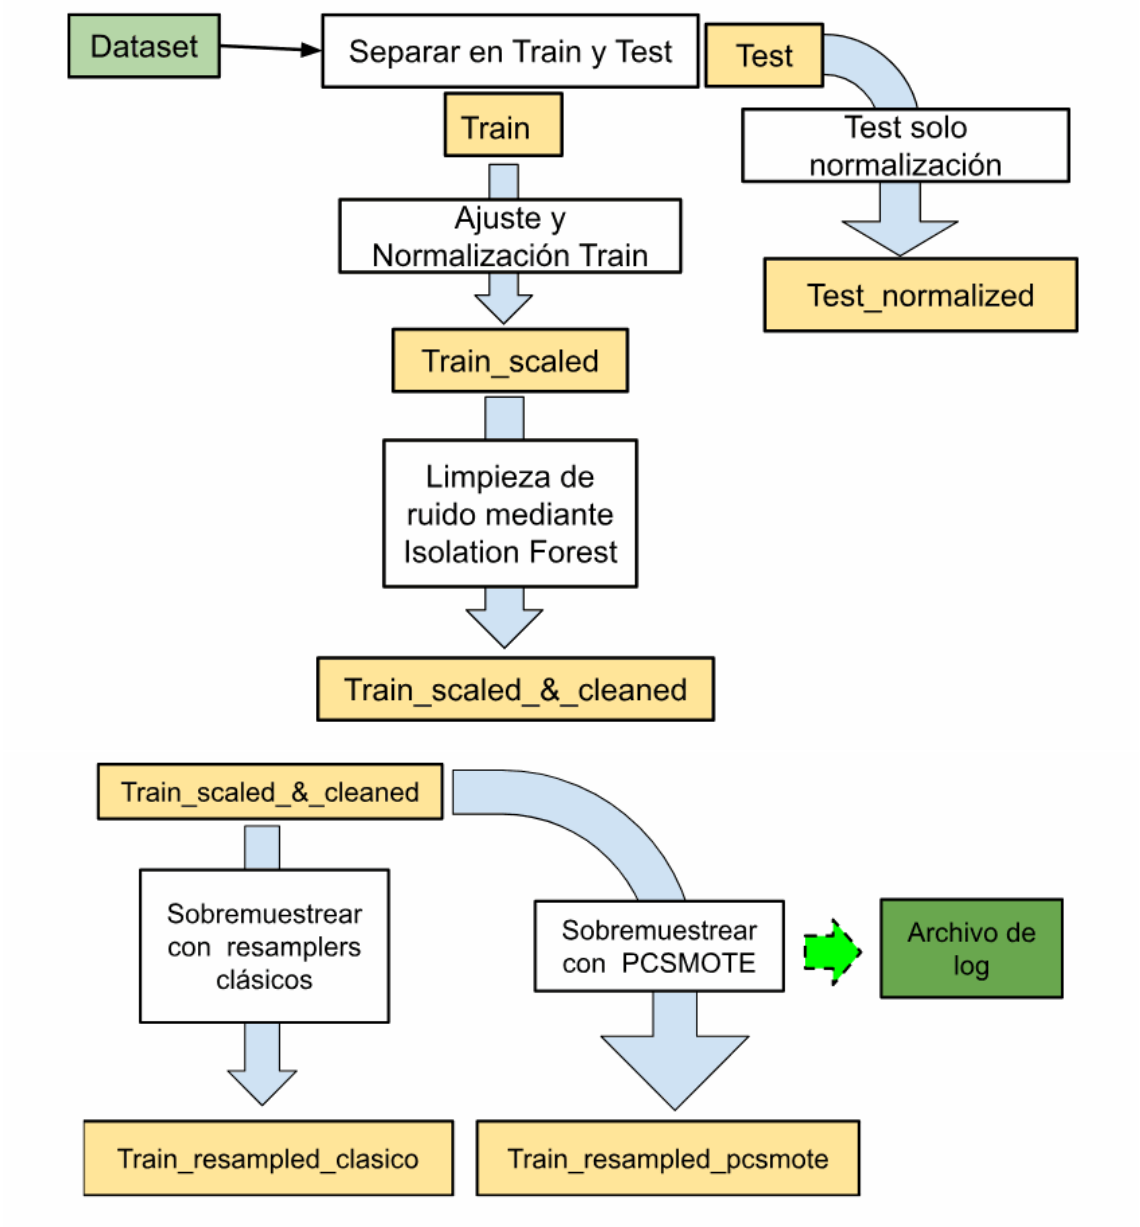

Figura 3.4: Etapas del sobremuestreo de PC-SMOTE

Tabla 3.2: Características principales de los conjuntos de datos experimentales

Dataset	**Instancias**	**Atributos**	**Distribución**	**Tipo**
Shuttle [20]	58.000	9	Maj: 45.586 Min: 12.414	Multiclase (7)
Predict Faults [10]	10.000	Múltiples	Maj: 9.652 Min: 348	Binaria
Telco Churn [9]	7.043	Múltiples	Maj: 5.174 Min: 1.869	Binaria
US Crime [21]	1.994	143	Maj: 1.844 Min: 150	Binaria

ca propuesta adapta sus radios percentiles a distintas configuraciones geométricas para mejorar el rendimiento predictivo.

3.3. Pipeline de entrenamiento y testeo

El pipeline de Entrenamiento y Testeo se estructura en dos fases, de las cuales la primera consiste en la **Optimización del Modelo Base**. Dentro de esta se realiza el *Entrenamiento y Búsqueda de Hiperparámetros*, empleando el conjunto de entrenamiento original para una búsqueda en grilla mediante *Random Search CV* con el fin de identificar los mejores hiperparámetros para un modelo de aprendizaje *Random Forest*.

Posteriormente, se lleva a cabo la *Evaluación del Modelo Base*. Utilizando los hiperparámetros óptimos hallados, se evalúa el rendimiento del modelo sobre el conjunto de testeo, calculando las métricas $F1_{macro}$, $F1_{weighted}$ y precisión (*accuracy*) mediante validación cruzada.

La segunda fase es la **Evaluación de Estrategias de Sobremuestreo**, en la cual se realiza el *Entrenamiento y Testeo con Sobremuestreo*. Para ello, se toma un nuevo modelo *Random Forest* configurado con los mejores hiperparámetros hallados previamente, que se entrena individualmente con cada tipo de conjunto de entrenamiento sobremuestreado —producido por *SMOTE*, *Borderline SMOTE*, *ADASYN* y *PC-SMOTE*— y luego se evalúa con el conjunto de testeo correspondiente.

Finalmente, se procede al *Análisis Comparativo*, obteniendo las métricas $F1_{macro}$, $F1_{weighted}$ y precisión para cada variante de sobremuestreo. Esto permite establecer un *ranking* comparativo, centrado en la métrica de interés ($F1_{macro}$), y determinar el porcentaje de mejora (Δ) de cada estrategia respecto al caso base o *baseline*.

3.4. Métricas de Evaluación

Dado que la comparación entre estrategias de sobremuestreo depende directamente del criterio con que se mida el rendimiento, en esta sección se presentan las métricas adoptadas en la evaluación experimental. Primero se definen los conceptos fundamentales de Precisión y Exhaustividad, luego se detalla el F_1-score y, finalmente, la métrica F_1-macro average [1, p. 13]. Esta última se utiliza como indicador principal, ya que el desbalance de clases —propio de los datasets analizados— puede provocar en otras métricas una falsa sensación de eficiencia o exactitud.

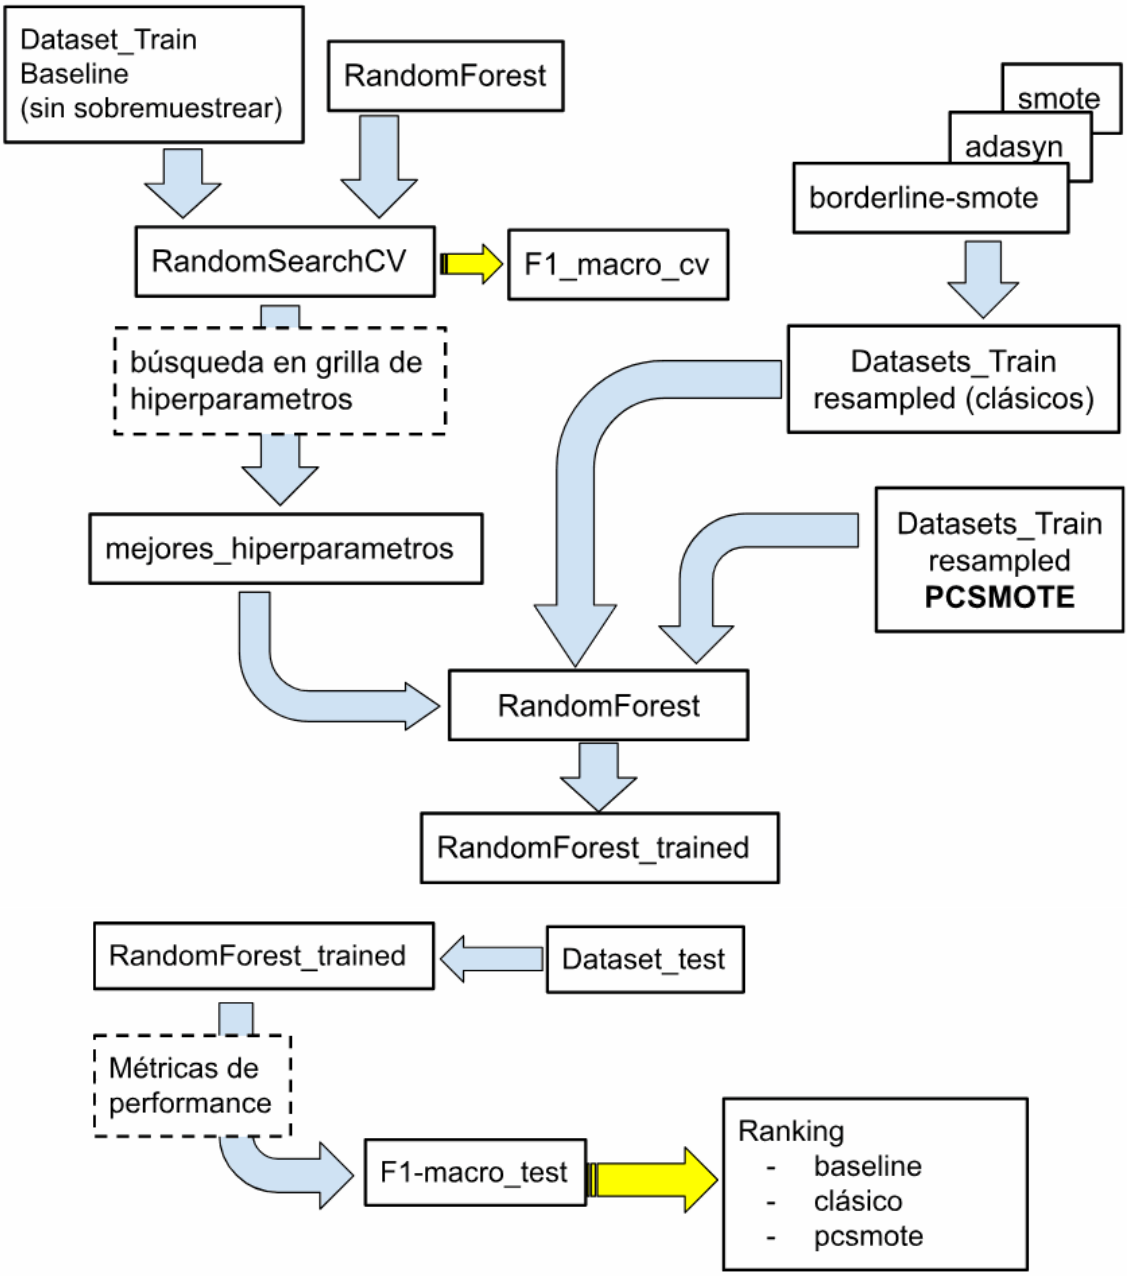

Figura 3.5: Etapa de Train y Test del Modelo de Aprendizaje

3.4.1. Precisión y Exhaustividad

La **Precisión** (P), también conocida como valor predictivo positivo, mide la capacidad del modelo para no etiquetar como positiva una muestra que es negativa. Una precisión baja indica un alto número de falsos positivos (FP):

$$P = \frac{TP}{TP + FP} \tag{3.2}$$

Por otro lado, la **Exhaustividad** (R, por *Recall*) o sensibilidad, mide la capacidad del modelo para detectar todas las muestras positivas dentro del conjunto de datos. Es crítica en escenarios donde omitir un caso positivo (falso negativo) tiene un alto costo:

$$R = \frac{TP}{TP + FN} \tag{3.3}$$

Donde TP representa los verdaderos positivos y FN los falsos negativos. En el desarrollo de variantes de SMOTE controladas por percentiles, el objetivo central es mejorar el *Recall* de la clase minoritaria sin degradar drásticamente la precisión.

3.4.2. F1-score

El F_1-score es la media armónica entre la precisión y la exhaustividad. Se utiliza como una métrica única que busca un equilibrio entre ambas. A diferencia de la media aritmética, la media armónica penaliza fuertemente los valores extremos, de modo que si cualquiera de las dos métricas (P o R) es baja, el F_1-score reflejará dicho rendimiento deficiente:

$$F1 = 2 \cdot \frac{P \cdot R}{P + R} \tag{3.4}$$

3.4.3. F1 macro-average

La métrica principal para evaluar los resultados de esta investigación es el F_1**-macro average**, cuya elección responde a la necesidad de evaluar el rendimiento del modelo de manera equitativa ante el desbalance de datos. A diferencia del promedio simple (*micro-average*), el enfoque *macro* calcula el valor F_1 de forma independiente para cada clase y luego obtiene el promedio aritmético, otorgando el mismo peso a la clase minoritaria que a la mayoritaria.

Para definir el F_1-macro, consideramos el F_1 para cada clase i:

$$F1_i = 2 \cdot \frac{P_i \cdot R_i}{P_i + R_i} \tag{3.5}$$

Finalmente, el F_1-macro se calcula promediando los valores obtenidos para las n clases del conjunto de datos:

$$F1_{\text{macro}} = \frac{1}{n} \sum_{i=1}^{n} F1_i \tag{3.6}$$

Este procedimiento garantiza que cualquier mejora en la clasificación de la clase minoritaria se vea reflejada directamente en la métrica global, evitando que el alto desempeño en la clase predominante enmascare deficiencias del modelo en los casos de mayor interés para este estudio.

4. RESULTADOS

En este capítulo se presentan los hallazgos empíricos derivados de la evaluación de *PC-SMOTE* sobre los conjuntos de datos seleccionados. El análisis comienza con el estudio de la configuración heurística basada en percentiles (Fase 1 del algoritmo) y luego detalla su impacto en el rendimiento del clasificador.

Los resultados indican que la combinación de estos hiperparámetros geométricos permitió ajustar el comportamiento del algoritmo a los conjuntos de datos analizados. Asimismo, el hecho de que *PC-SMOTE* no genere sintéticos o los genere a partir de pocas semillas candidatas aportó información adicional sobre la geometría de cada dataset, ya que en algunos casos los datos mostraron condiciones favorables para métodos basados en vecindad y, en otros, el grado de solapamiento hizo menos conveniente la interpolación local.

4.1. Análisis de la configuración geométrica basada en percentiles

Los resultados expuestos en la **Tabla 4.1** muestran las mejores configuraciones encontradas de *PC-SMOTE* con cada dataset. Es dable destacar que estos valores fueron escalados, ya que de lo contrario la técnica se volvería imprecisa al trabajar con magnitudes de distancia diferentes.

En todos los experimentos se mantuvo fijo $k = 7$ como tamaño base del vecindario, mientras que la exploración se concentró en los percentiles de radio para densidad y riesgo, en el criterio de pureza y en los umbrales geométricos asociados.

La tabla muestra cómo *PC-SMOTE* pudo adaptar los hiperparámetros de radio-densidad, radio-riesgo y entropía a la geometría del dataset gracias al uso de los percentiles. Esto se puede observar entre los conjuntos de datos *Predict Faults* y *Us Crime*, donde se nota cómo la definición de "cerca" varía entre un conjunto de datos y otro y, en *Predict Faults*, por ejemplo, las muestras están tan juntas que incluso un percentil alto sigue tomando un valor de radio físico pequeño, lo que indica una alta concentración de los datos.

Por el contrario, en *Us Crime* y *Shuttle* se observó un valor de radio físico más grande, es decir, se expandió drásticamente para encontrar vecinos en un espacio disperso de alta dimensión. Al cambiar la noción de "cerca" en estos conjuntos, se observó una mejora en el desempeño del clasificador y un mejor aporte por parte de *PC-SMOTE*.

4.2. Análisis de Radios

Se incluye este apartado sobre el análisis de radios porque *PC-SMOTE* utiliza esta información en la primera fase de definición de los valores de radio-densidad y riesgo. Para ello, se puede observar la primera figura donde la curva muestra una distribución acumulada de las distancias euclídeas entre las instancias minoritarias y sus k vecinos más cercanos (ver Figura 4.10).

El gráfico muestra que, dentro del mismo dataset (ver Figura 4.1 y Figura 4.2 - *Shuttle*), la Clase 1 requiere un radio de apenas 0,33 para alcanzar el percentil 70, mientras que la Clase 6 necesita un radio de 981,5 para el mismo percentil. Esto sugiere que un radio fijo habría sido insuficiente para capturar ambas estructuras simultáneamente, mientras que el uso de percentiles permitió ajustar la escala espacial para cada clase.

Tabla 4.1: Configuración de percentiles por dataset y parámetros

Datasets / Hiperparámetros	**Shuttle**	**Telco Churn**	**Predict Faults**	**US Crime**
PR_{dens} (Radio densidad)	70 (medio)	85 (alto)	85 (alto)	85 (alto)
Radio físico densidad	0,40 ∼ 981*	1,43	0,582	18,2
PR_{riesgo} (Radio riesgo)	30 (muy bajo)	40 (bajo)	50 (medio)	40 (bajo)
Radio físico riesgo	0,2 ∼ 503*	1	0,319	6,8
$PR_{\text{entropía}}$	–	70	–	80
Valor entropía	–	0,59	–	0,86
Criterio pureza	proporción	entropía	proporción	entropía
Densidad (umbral densidad)	25	60	45	45
Riesgo (umbral riesgo)	30	45	55	45
Pureza (umbral prop.)	40	–	45	–
Grado de Isolation Forest	1	0	0	0

Nota. * Rango por clase.

En el caso de *Telco Churn*, la curva de radio destaca por su forma creciente con aumentos repentinos. Este fenómeno indica que la clase minoritaria no presenta una densidad binaria (denso/disperso), sino una estratificación estructural en cuatro bloques de densidad decreciente: el **primer segmento (rango percentil 0-20 %)**, caracterizado por radios mínimos (radio $< 0{,}5$), corresponde a los centroides de los *clusters* donde la redundancia de información es máxima, el **segundo bloque (rango percentil 20-55 %)** evidencia un incremento escalonado del radio, indicando la presencia de sub-grupos o *small disjuncts* que requieren una mayor tolerancia espacial para ser conectados, el **tercer tramo (rango percentil 55-85 %)** representa la periferia de las estructuras, donde la densidad disminuye pero mantiene la conectividad suficiente para validar la interpolación (entre 3/7 a 4/7 vecinos dentro del umbral) y, finalmente, el **último segmento** exhibe un crecimiento vertical asintótico, correspondiente a *outliers* globales y ruido desconectado de cualquier estructura latente.

Este análisis sugiere que la elección del Percentil de Densidad al 85 % respondió a un patrón geométrico observable en los datos. Este corte permitió al algoritmo contener los tres primeros bloques estructurales y excluir el cuarto bloque de dispersión, favoreciendo la generación sin incorporar sintéticos en regiones más inestables.

La correlación entre el patrón gráfico observado y los datos operativos se confirma mediante la auditoría de los *logs* generados por *PC-SMOTE*. Específicamente, se constata que el cuarto bloque (Nube de Dispersión) corresponde materialmente a las semillas que presentaron una densidad vecinal crítica, registrando densidades del orden de 0/7, 1/7 y 2/7 vecinos válidos, lo que valida la decisión del algoritmo de clasificar estas instancias como ruido u *outliers* y excluirlas del proceso de generación para preservar la integridad de la frontera de decisión.

4.2.1. Lectura aplicada del análisis geométrico en Telco Churn

La estratificación observada en este conjunto de datos, particularmente el descarte del último bloque asintótico (nube de dispersión) evaluado mediante la entropía de Shannon, puede interpretarse como una decisión asociada a regiones de alta dispersión y mayor mezcla de clases. Desde una lectura aplicada, los vecindarios donde PC-SMOTE permitió generar datos corresponden a sectores con mayor cohesión local, mientras que la nube de dispersión reúne casos menos estables para la interpolación.

En consecuencia, la restricción de la generación en esas zonas puede entenderse como

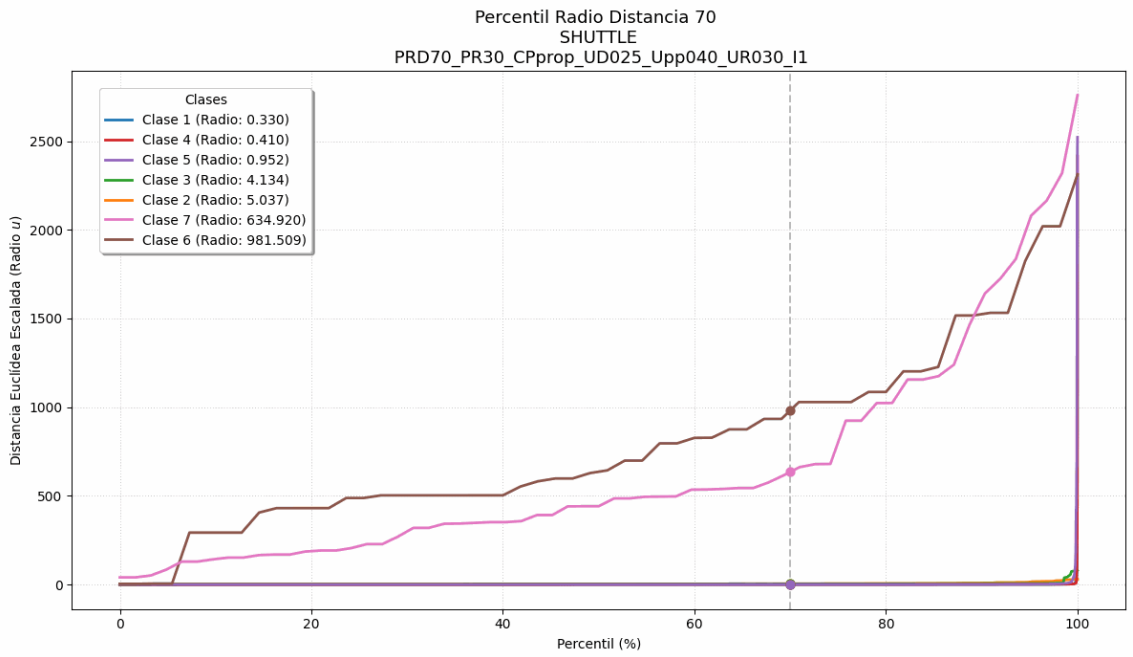

Figura 4.1: Visualizacion de radios por clase del dataset Shuttle.

una medida para evitar la incorporación de sintéticos sobre regiones poco informativas para el modelo.

4.3. Dinámica de filtrado en PC-SMOTE

El análisis transversal de los experimentos muestra cómo *PC-SMOTE* no operó con una tasa de generación uniforme, sino que actuó como un filtro selectivo dependiente de la morfología de los datos, es decir, de la forma y del grado de dispersión que adopta la distribución local de las instancias. La **Figura 4.6** muestra dos comportamientos opuestos en la selección de semillas candidatas sobre el estudio de pureza de un dataset: frente a escenarios muy mezclados, el algoritmo optó por no usar la mayoría de las semillas (ver **Figura 4.9** - caso *predict_faults*), mientras que, cuando la geometría del vecindario resultó apta para la generación de semillas candidatas, el algoritmo aumentó significativamente el porcentaje de aceptación de las mismas (ver **Figuras 4.7** y **4.8** - *telco churn* y *shuttle*).

Esto confirmó que la técnica, logró identificar escenarios con buena separabilidad local, permitiendo la interpolación intensiva sin comprometer la frontera.

En los gráficos radar, la arista "Reparto de Semillas" nos dice si la generación de semillas está concentrada en muchas o pocas muestras, de modo que cuanto más se acerca a 1 más repartido está y, al contrario, cuanto más se acerca a cero, la generación se concentra en pocas candidatas.

A pesar de la alta cobertura de clases observada en algunos casos (como en el caso Shuttle, Figura 4.10), se concluye que esto no es suficiente. Es indispensable que la generación de semillas sintéticas se distribuya en una mayor cantidad de semillas para prevenir el sobreajuste (overfitting).

Es interesante ver cómo las figuras 4.12 y 4.13 de radar en Us Crime y Predict Faults son muy similares. Sin embargo, PC-SMOTE se comportó de manera diferente en ambos casos. En el primer caso, con Us Crime, se observó una interpolación que el clasificador pudo aprovechar y mejorar el poder de generación, mientras que en el segundo caso, a pesar

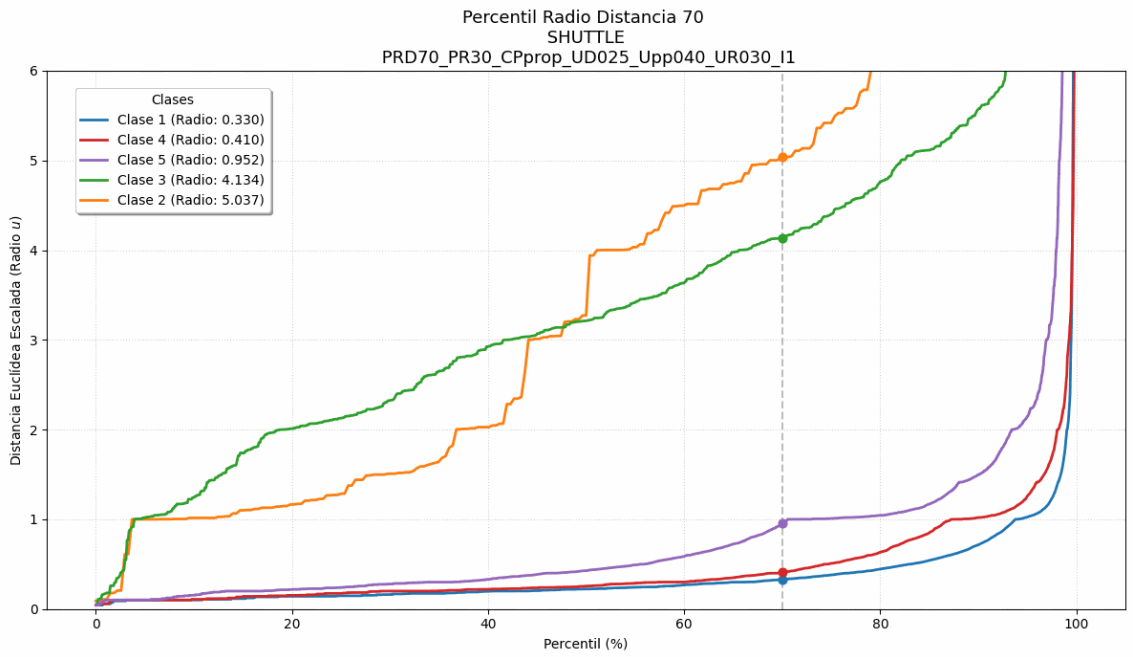

Figura 4.2: Visualizacion de radios con foco en las clases 1 a 5 del dataset Shuttle.

de identificar la estructura, la intervención de la técnica generó un desempeño deficiente del clasificador y no logró superar el caso base (ver Tablas 4.13 y 4.4).

Asimismo, también se pudo observar una relación entre "semillas sintéticas válidas" y "reparto de semillas", es decir que, si hay muchas semillas que pasaron los filtros, luego repercute en una generación más concentrada de sintéticos. Al contrario, cuando pocas semillas pasaron los filtros, la generación de sintéticos es más distribuida.

El mismo fenómeno ocurrió en el caso del dataset Us Crime, donde se alcanzó a cubrir todas las clases en la generación de sintéticos y la distribución de los nuevos ejemplos quedó repartida sobre gran parte de las semillas que superaron los filtros. Sin embargo, en esta ocasión, PC-SMOTE filtró demasiadas semillas, ya que el dataset era muy ruidoso y bastante mezclado.

Lectura aplicada del análisis geométrico (Predict Faults): El comportamiento de PC-SMOTE en el dataset *Predict Faults* (fallas industriales), donde el algoritmo rechazó la mayor parte de las semillas candidatas, sugiere una geometría local altamente mezclada. En este dataset, las maquinarias cercanas a una falla presentan parámetros físicos y térmicos muy similares a los de máquinas en funcionamiento normal.

En estas condiciones, una estrategia de sobremuestreo indiscriminada podría introducir instancias sintéticas en regiones ambiguas y dificultar la discriminación entre clases. Por ello, el hecho de que la técnica reduzca la generación no debe interpretarse necesariamente como una deficiencia, sino como un resultado coherente con la geometría observada.

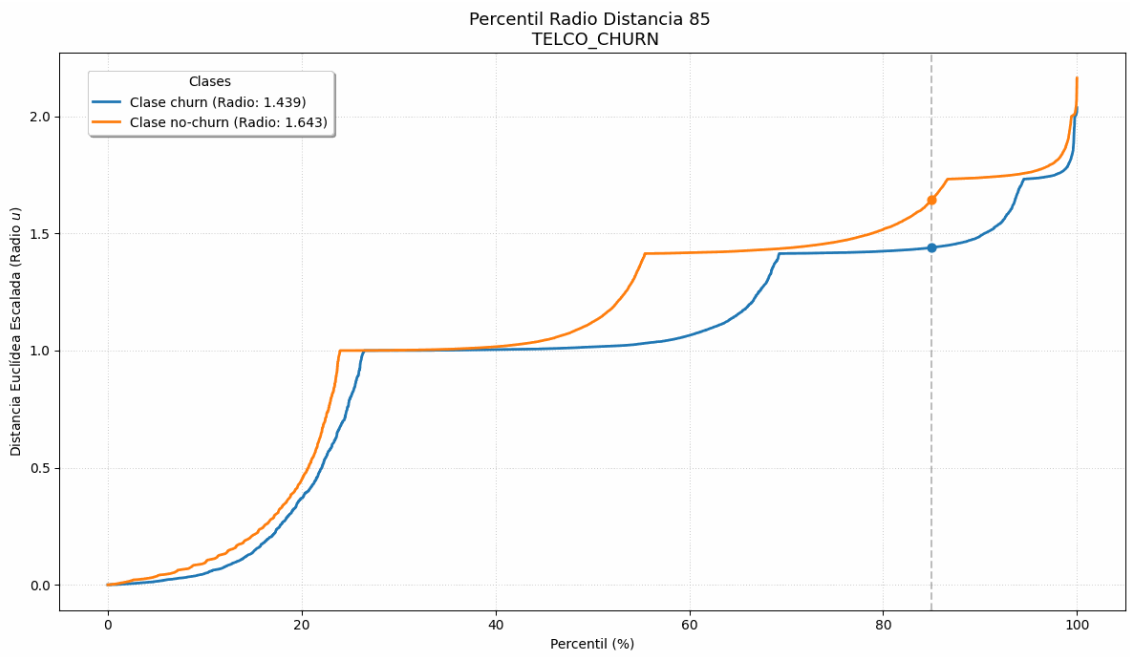

Figura 4.3: Visualizacion de radios por clase del dataset Telco Churn.

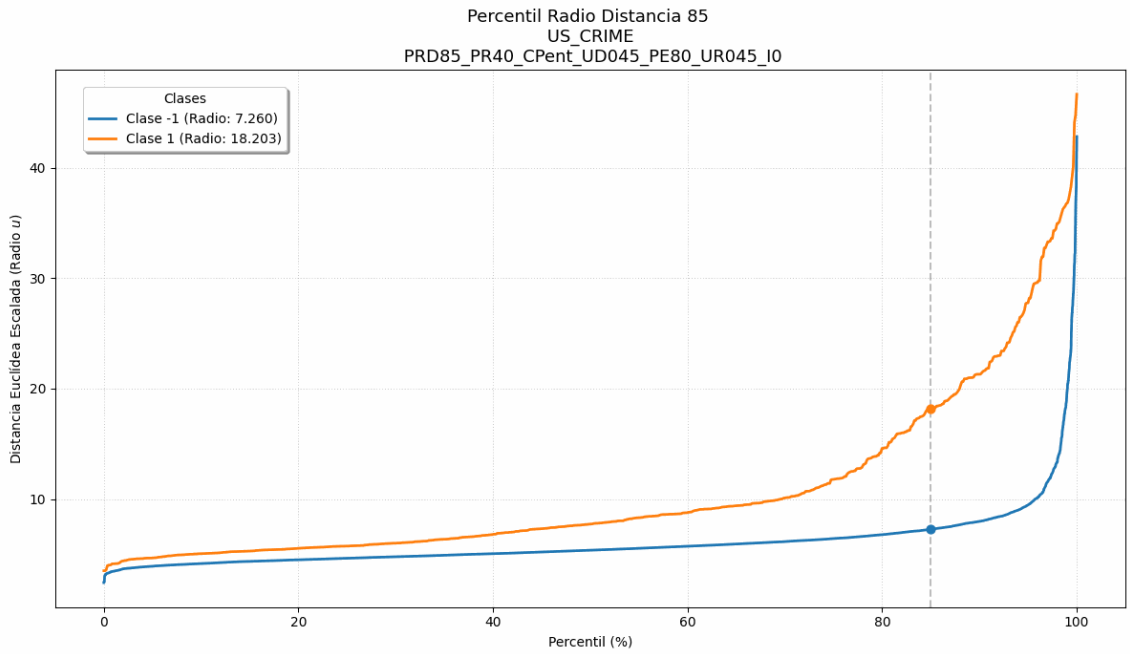

Figura 4.4: Visualizacion de radios por clase del dataset US Crime.

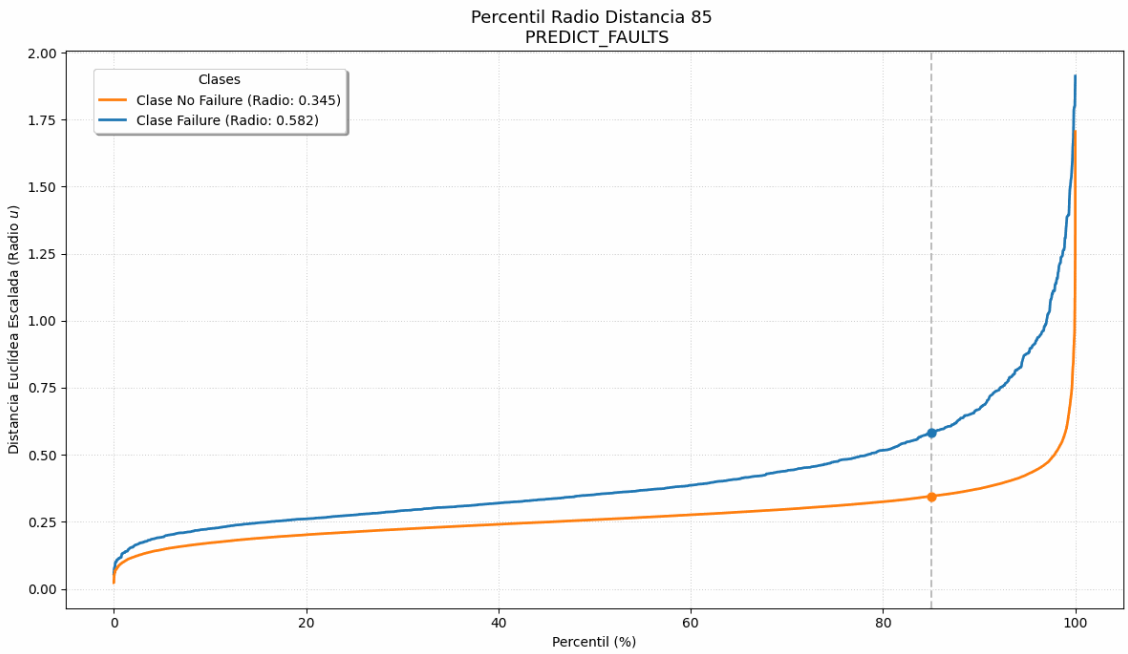

Figura 4.5: Visualizacion de radios por clase del dataset Predict Faults.

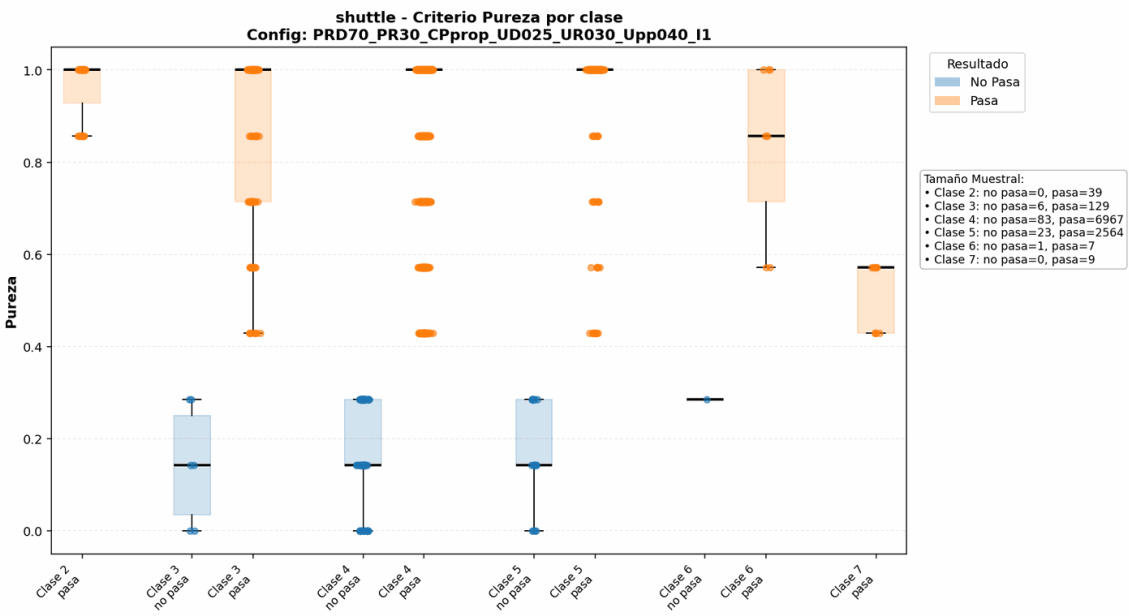

Figura 4.6: Visualizacion de purezas por clase del dataset Shuttle.

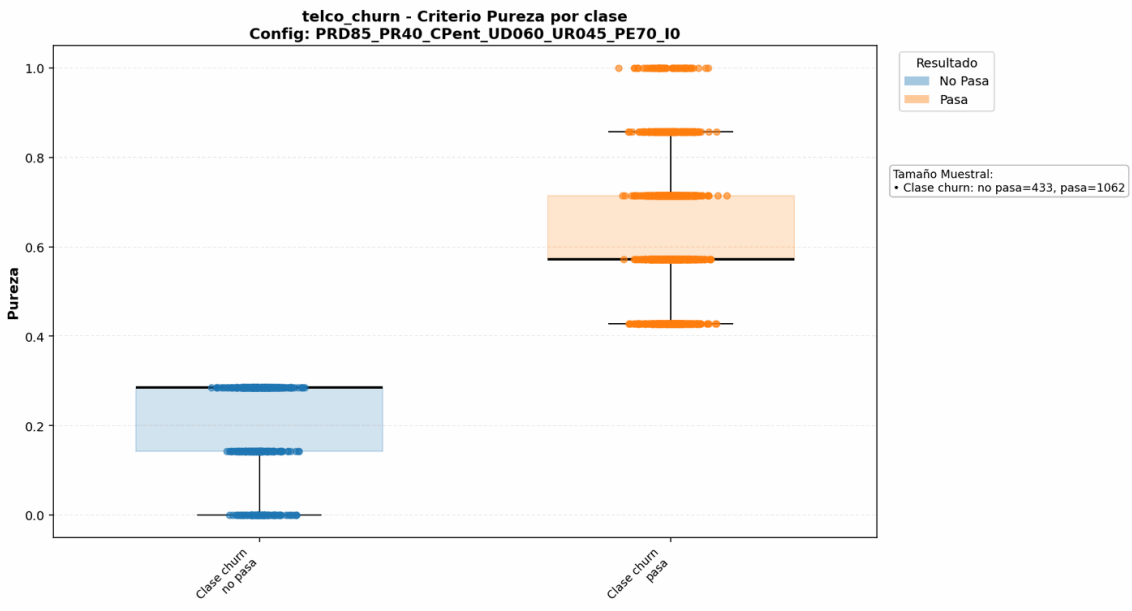

Figura 4.7: Visualizacion de purezas por clase del dataset Telco Churn.

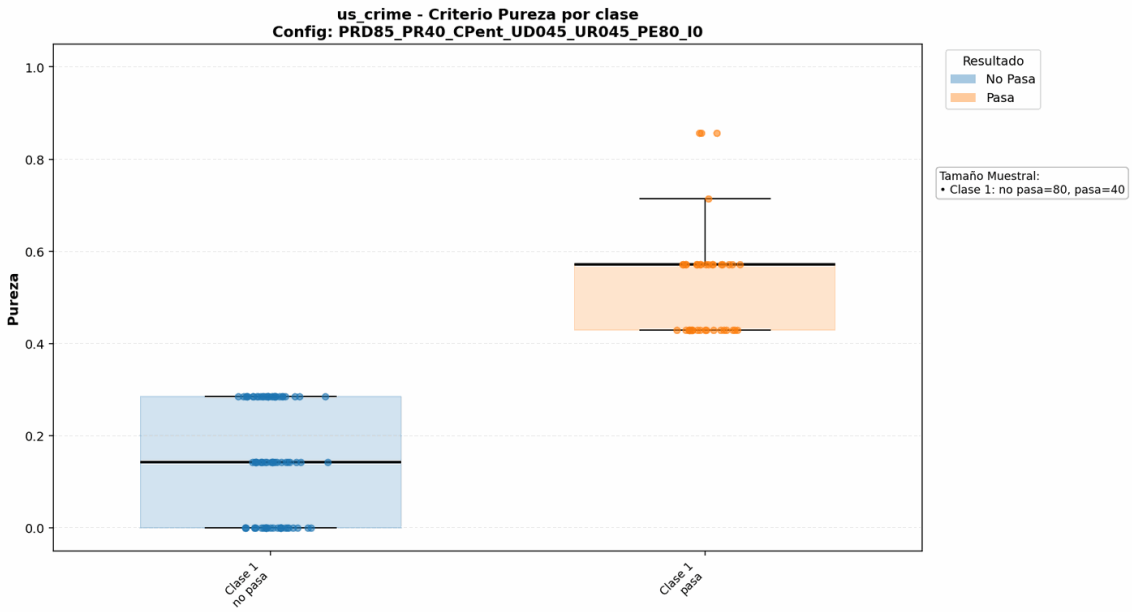

Figura 4.8: Visualizacion de purezas por clase del dataset US Crime.

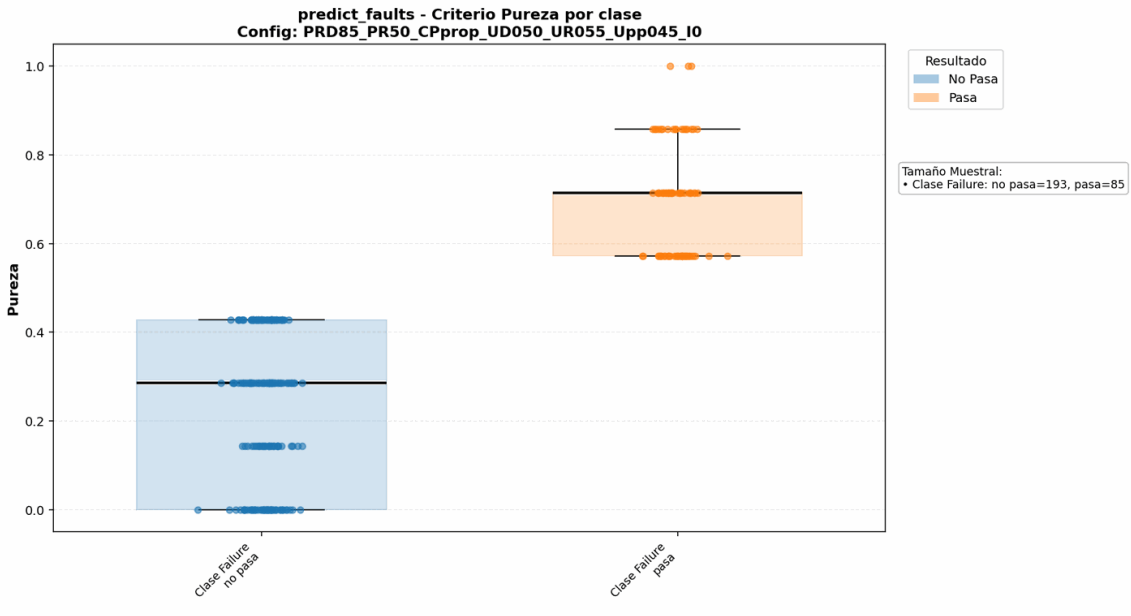

Figura 4.9: Visualizacion de purezas por clase del dataset Predict Faults.

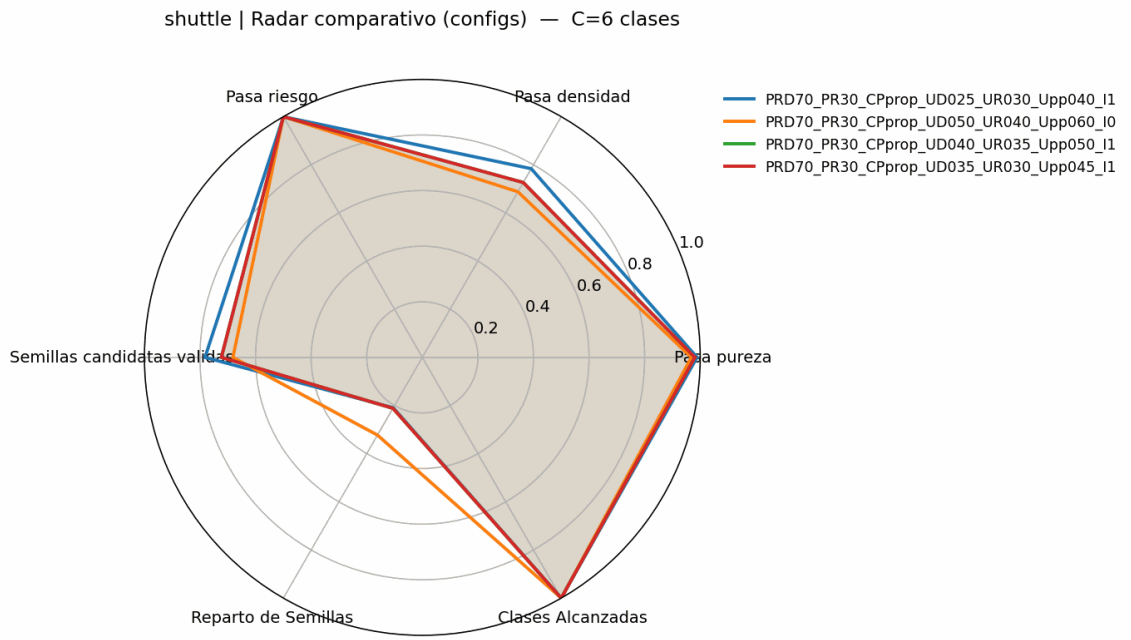

Figura 4.10: Radar comparativo (configs) del dataset Shuttle.

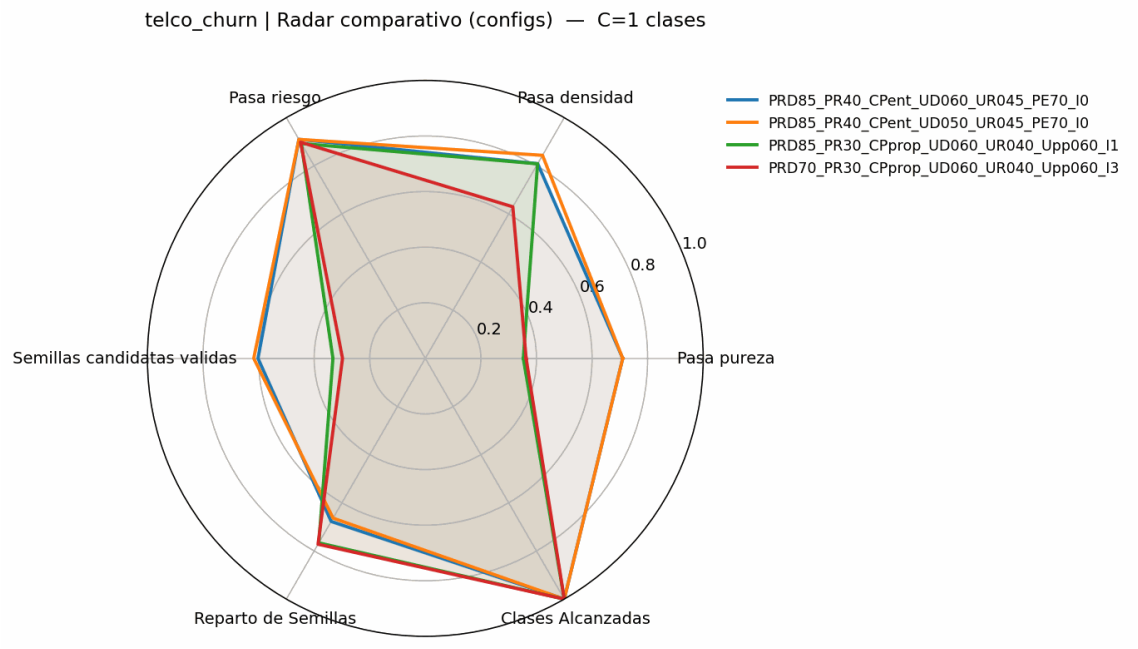

Figura 4.11: Radar comparativo (configs) del dataset Telco Churn.

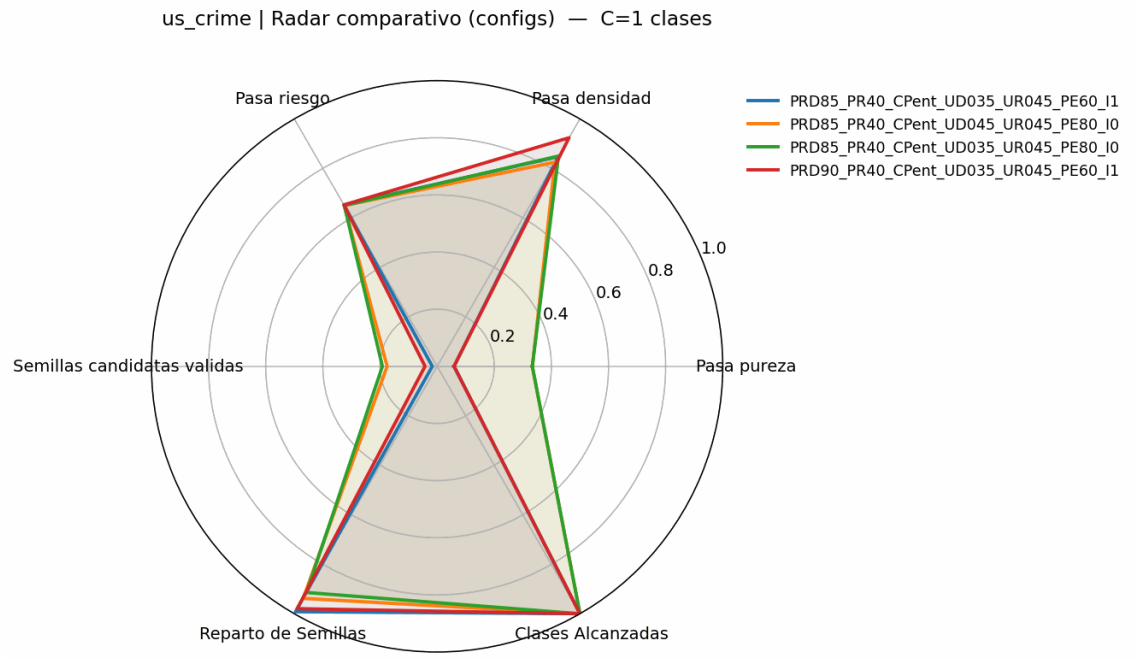

Figura 4.12: Radar comparativo (configs) del dataset US Crime.

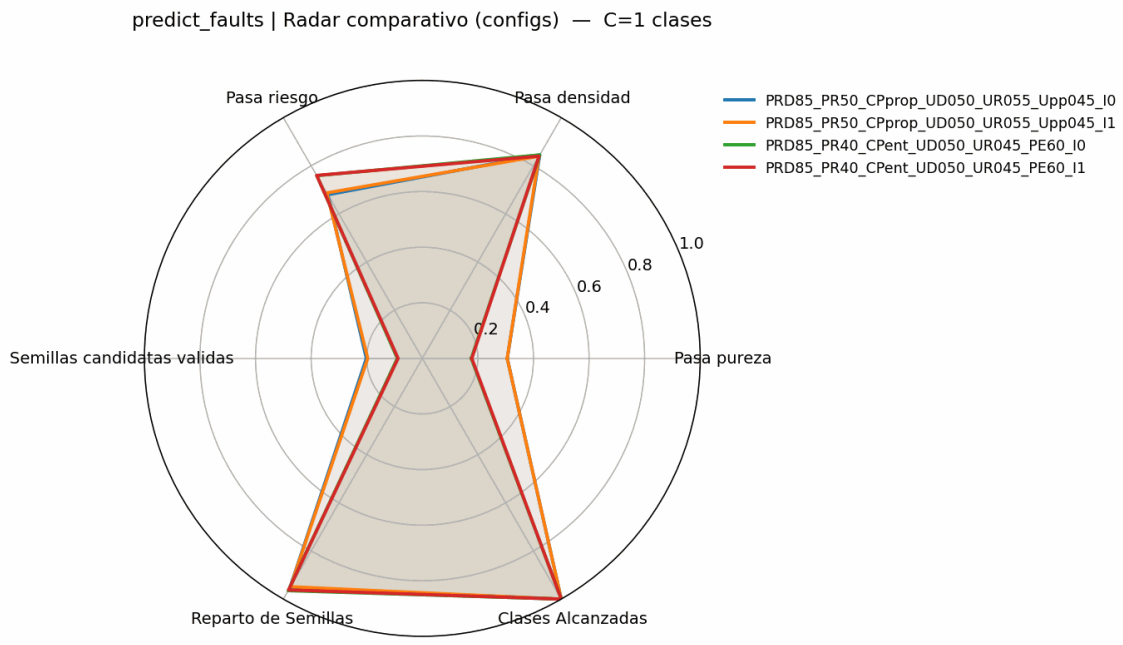

Figura 4.13: Radar comparativo (configs) del dataset Predict Faults.

4.4. Análisis de resultados de la implementación de PC-SMOTE

Para un análisis más detallado y descriptivo, los resultados se presentan en tres tablas distintas para cada conjunto de datos analizado. La **Primera Tabla** muestra las configuraciones de *PC-SMOTE* evaluadas, ordenadas de acuerdo con la mejor puntuación obtenida en la métrica F1-macro, la **Segunda Tabla** presenta el desempeño logrado en el caso base (*baseline*), incluyendo los tamaños de los conjuntos de entrenamiento (*train*) y prueba (*test*), junto con los valores obtenidos de las métricas, y la **Tercera Tabla** contiene la comparación de cada experimento realizado ($E1, E2$, etc.) con el caso base, lo que permite visualizar claramente la eficiencia de la técnica aplicada.

La tabla comparativa se interpreta de la siguiente manera: la primera columna, "Percentil de Isolation Forest", indica el percentil de dicha técnica aplicado para la limpieza de *outliers* (un valor de 0 % significa que no se aplicó esta limpieza), mientras que entre paréntesis se detallan las "Semillas Candidatas", que representan la cantidad de semillas analizadas.

A continuación, se especifica la "Técnica y Semillas Válidas", mostrando el método de sobremuestreo aplicado y la cantidad de semillas que resultaron aptas, y además en la columna "Semillas Válidas (Sem. Val.)" se reporta la cantidad de muestras sintéticas generadas.

Cabe aclarar que, en algunos casos, *PC-SMOTE* no produce la misma cantidad que el *SMOTE* clásico, ya que si ninguna muestra de una clase supera los filtros no se generan sintéticos para ella. No obstante, si al menos una semilla resulta válida, la generación se realiza igualando el número de muestras de la clase mayoritaria.

La columna subsiguiente, denominada "Muestras Totales (Train + Sintéticos)", indica la suma de las muestras originales de entrenamiento y las sintéticas generadas, y finalmente se incluyen las "Métricas de Performance", que consisten en tres indicadores clave para facilitar un análisis profundo y la comparación con otros trabajos. Entre estas métricas destaca la *F1-macro*, calculada como el promedio aritmético de los puntajes F1 obtenidos por cada clase para evaluar la capacidad del clasificador *Random Forest*, ya que esta medida revela la eficacia con la que el modelo identifica correctamente las muestras frente a la cantidad de errores cometidos.

Este desempeño depende en gran medida de la calidad informativa de los datos de entrenamiento. Si una técnica de sobremuestreo genera muestras sintéticas idénticas, resultaría en información redundante (*sobreajuste*), lo cual obstaculiza el trabajo del clasificador.

De lo anteriormente dicho, puede observarse que, en aquellos casos donde *PC-SMOTE* pudo cubrir la generación de sintéticos en todas las clases, el clasificador obtuvo un alto desempeño, como en el caso de *Shuttle* (**Figura 4.10**) e inclusive cuando el dataset era más hostil (vecindades ruidosas y mezcladas) como en *Us Crime* (**Figura 4.12**).

Al analizar los resultados del dataset *Predict Faults* (Tabla 4.4 y Figura 4.13), se observa que la técnica restringió fuertemente la interpolación. Este comportamiento coincide con el análisis previo del conjunto, que mostró una geometría local especialmente ambigua para la generación de sintéticos.

Si bien las técnicas clásicas pueden generar una mayor cantidad de muestras y eventualmente mejorar ciertas métricas, ese aumento no siempre implica una representación más fiel de la estructura local. En este caso, la restricción de PC-SMOTE sugiere que la vecindad disponible no ofrecía condiciones favorables para una interpolación confiable.

Por lo tanto, que PC-SMOTE no supere el F1-macro del caso base en este dataset no invalida la propuesta, sino que muestra que la heurística puede actuar de forma conservadora cuando la geometría local no respalda la generación de sintéticos. Desde esta lectura,

la limitación en la generación de muestras forma parte del comportamiento esperado del algoritmo ante entornos especialmente ambiguos.

En una lectura más amplia, los resultados obtenidos permiten ubicar a PC-SMOTE dentro de la evolución reciente de técnicas de sobremuestreo sensibles a la geometría local. Mientras antecedentes como G-SMOTE introducen la flexibilización de la región de generación sintética y propuestas más recientes como LD-SMOTE y VS-SMOTE refuerzan la relevancia de la densidad local y del control del ruido, los resultados obtenidos en este trabajo sugieren que dicha adaptabilidad también resulta pertinente en una etapa previa de selección de semillas candidatas. En este sentido, PC-SMOTE no se plantea como una reformulación directa de esos métodos, sino como una heurística que, a partir de percentiles, densidad, riesgo y pureza, busca incorporar esa misma sensibilidad geométrica tanto en la elección de las instancias a interpolar como en la generación posterior de ejemplos sintéticos.

Tabla 4.2: Configuración de hiperparámetros por técnica y Umbral de limpieza (Predict Faults)

Exp.	Umbral IF*	Técnica	PR_dist	PR_ries	Criterio	U_den	U_ries	Tipo_P
E1	Umbral 0: no se filtró por IF (candidatas: 278)	**PC-SMOTE**	**85**	**40**	**entropía**	**050**	**045**	**PE60**
E2		PC-SMOTE	85	50	proporción	050	055	Upp045
E3	P 1 % (275)	**PC-SMOTE**	**85**	**40**	**entropía**	**050**	**045**	**PE60**
E4		PC-SMOTE	85	50	proporción	050	055	Upp045
E5	P 3 % (269)	**PC-SMOTE**	**85**	**50**	**proporción**	**050**	**055**	**Upp045**

* El valor entre paréntesis indica las semillas sintéticas candidatas.

Tabla 4.3: Rendimiento en Validación Cruzada (k-fold CV) para el Caso Base (Predict Faults)

Configuración	Tamaño Train (80 %)	Tamaño Test (20 %)	F1_M CV	F1_W CV	Acc CV
Caso Base (Original)	8000	2000	0,865	0,983	0,985

Nota. El conjunto de entrenamiento (80 %) presenta un fuerte desbalance de clases: 7722 instancias pertenecen a la clase mayoritaria (-1) y solo 278 a la clase minoritaria (1).

Tabla 4.4: Rendimiento final en conjunto de prueba: Caso Base vs. Sobremuestreo (Predict Faults)

Exp.	Umbral IF	Técnica	Semillas Validadas*	Sintet.	Train Final (Orig + Sintet.)	F1_M Test	Δ (F1_M)	F1_W Test	Acc Test
–	**Caso Base**	–	–	–	8000	0,856	–	0,982	0,983
E1	Umbral 0: no se filtro por IF (candidatas: 278)	**PC-SMOTE**	**25**	**7444**	**15444**	**0.828**	**-0.028**	**0.978**	**0.980**
E2		PC-SMOTE	56	7444	15444	0,822	−0,034	0,978	0,980
–		borderline	–	7444	15444	0,825	−0,031	0,976	0,977
–		adasyn	–	7453	15453	0,813	−0,043	0,974	0,973
–		smote	–	7444	15444	0,808	−0,048	0,973	0,973
E3	P 1 % (candidatas: 275)	**PC-SMOTE**	**24**	**7369**	**15288**	**0.839**	**-0.017**	**0.979**	**0.981**
E4		PC-SMOTE	54	7369	15288	0,828	−0,028	0,978	0,980
–		borderline	–	7369	15288	0,827	−0,029	0,976	0,976
–		smote	–	7369	15288	0,829	−0,027	0,976	0,975
–		adasyn	–	7380	15299	0,815	−0,041	0,974	0,973
E5	P 3 % (candidatas: 269)	**PC-SMOTE**	**53**	**7221**	**14980**	**0.839**	**-0.017**	**0.979**	**0.980**

* Semillas candidatas validadas en el conjunto de entrenamiento (*train*). Δ ($F1_M$) representa la diferencia absoluta respecto al Caso Base. *Nota:* Las filas en negrita resaltan los experimentos con mejor desempeño relativo.

Tabla 4.5: Configuración de hiperparámetros para experimentos seleccionados (Shuttle)

Exp.	Umbral IF*	Técnica	PR_dist	PR_ries	Criterio	U_den	U_ries	Tipo_P
E1	1 (9828)	*PC-SMOTE*	70	30	proporción	025	030	Upp040
E2	0 (9931)	*PC-SMOTE*	70	30	proporción	050	040	Upp060

* Valor entre paréntesis indica semillas sintéticas candidatas detectadas.

Tabla 4.6: Rendimiento en Validación Cruzada (k-fold CV) para el Caso Base (Shuttle)

Configuración	Tamaño Train	Tamaño Test	F1_M CV	F1_W CV	Acc CV
Caso Base (Original)	46400	11600	0,963	1,000	1,000

Nota. El conjunto de entrenamiento (80 %) se compone de 36469 instancias de la Clase 1 (mayoritaria), y las clases minoritarias: Clase 4 (7122), Clase 5 (2614), Clase 3 (137), Clase 2 (40), Clase 7 (10) y Clase 6 (8).

Este mecanismo también se pudo observar en el conjunto de datos Shuttle (Tabla 4.7), más precisamente en la generación de sintéticos por parte del algoritmo, donde solo se crearon 135.963 muestras, a diferencia de los 208.883 generados por el SMOTE clásico. Esta reducción numérica es una característica del funcionamiento de PC-SMOTE y se manifestó de forma más marcada en ambas aplicaciones en conjunto con Isolation Forest.

Específicamente, con Isolation Forest Umbral Percentil 0, PC-SMOTE no pudo identificar semillas candidatas para las clases minoritarias 6 y 7, lo que lo llevó a centrarse en nivelar las clases 2 a 5 contra la mayoritaria (clase 1). No obstante, la aplicación de una limpieza previa de *outliers* con un umbral del 1 % resultó en una mejora del rendimiento.

Esta mejora se atribuye a dos factores clave: la variación en el umbral del radio de densidad y riesgo, y la relajación del umbral de densidad al 0.25 (2/7) en la cantidad de vecinos cercanos. Esto permitió que las clases 6 y 7 fueran consideradas suficientemente densas al encontrar vecinos, logrando su inclusión en el conjunto y, consecuentemente, un aumento en la performance general.

Tabla 4.7: Rendimiento final en conjunto de prueba ordenado por F1 Macro (Shuttle)

Ranking	Umbral IF	Técnica	Sem. Val.*	Sintet.	Train Final (Orig + Sintet.)	F1_M Test	Δ (F1_M)	F1_W Test	Acc Test
–	–	**Caso Base**	–	–	46400	0,855	–	1,000	1,000
1	Umbral 0: no se filtró por IF (candidatas: 9931)	*adasyn*	–	208961	255361	0,952	+0,097	1,000	1,000
2		*borderline*	–	172454	218854	0,952	+0,097	1,000	1,000
3		*smote*	–	208883	255283	0,950	+0,095	1,000	1,000
4		**PC-SMOTE (E2)**	**6756**	**135963**	**182363**	**0.857**	**+0.002**	**1.000**	**1.000**
1	P 1 % (candidatas: 9828)	*adasyn*	–	206831	252763	0,991	+0,136	1,000	1,000
2		*borderline*	–	170731	216663	0,991	+0,136	1,000	1,000
3		*smote*	–	206796	252728	0,950	+0,095	1,000	1,000
4		**PC-SMOTE (E1)**	**7685**	**206796**	**252728**	**0.950**	**+0.095**	**1.000**	**1.000**

* Semillas candidatas validadas en el conjunto de entrenamiento (*train*). Δ (F1_M) representa la mejora absoluta respecto al Caso Base. *Nota:* Las técnicas están ordenadas por F1_M Test dentro de cada bloque.

Tabla 4.8: Configuración de hiperparámetros para experimentos seleccionados (Telco Churn)

Exp.	Umbral IF*	Técnica	PR_dist	PR_ries	Criterio	U_den	U_ries	Tipo_P
E1	1 (1480)	*PC-SMOTE*	85	30	proporción	060	040	Upp060
E2	0 (1495)	*PC-SMOTE*	85	40	entropía	060	045	PE70

* Valor entre paréntesis indica semillas sintéticas candidatas detectadas.

Tabla 4.9: Rendimiento en Validación Cruzada (k-fold CV) para el Caso Base (Telco Churn)

Configuración	Tamaño Train	Tamaño Test	F1_M CV	F1_W CV	Acc CV
Caso Base (Original)	5634	1409	0,711	0,782	0,790

Nota. El conjunto de entrenamiento (80 %) presenta un desbalance de clases: 4139 instancias de la clase mayoritaria (-1) y 1495 de la clase minoritaria (1).

Tabla 4.10: Rendimiento final en conjunto de prueba ordenado por F1 Macro (Telco Churn)

Ranking	Umbral IF	Técnica	Sem. Val.*	Sintet.	Train Final (Orig + Sintet.)	F1_M Test	Δ (F1_M)	F1_W Test	Acc Test
–	0 %	**Caso Base**	–	–	5634	0,705	–	0,779	0,789
–	1 %	**Caso Base**	–	–	5577	0,702	–	0,776	0,786
1	0 % (candidatas: 1495)	*smote*	–	2644	8278	0,711	+0,006	0,782	0,790
2		*adasyn*	–	2594	8228	0,710	+0,005	0,773	0,771
3		**PC-SMOTE (E2)**	**897**	**2644**	**8278**	**0.708**	**+0.003**	**0.775**	**0.778**
4		*borderline*	–	2644	8278	0,708	+0,003	0,770	0,768
1	1 % (candidatas: 1480)	**PC-SMOTE (E1)**	**495**	**2617**	**8194**	**0.715**	**+0.013**	**0.783**	**0.788**
2		*smote*	–	2617	8194	0,713	+0,011	0,776	0,776
3		*adasyn*	–	2535	8112	0,712	+0,010	0,776	0,771
4		*borderline*	–	2617	8194	0,703	+0,001	0,766	0,763

* Semillas candidatas validadas en *train*. Δ ($F1_M$) representa la mejora absoluta respecto al Caso Base. *Nota:* Las técnicas están ordenadas por $F1_M$ Test para mostrar el ranking real de *PC-SMOTE*.

Tabla 4.11: Configuración de hiperparámetros para experimentos seleccionados (US Crime)

Exp.	Umbral IF*	Técnica	PR_dist	PR_ries	Criterio	U_den	U_ries	Tipo_P
E1	0 (120)	*PC-SMOTE*	85	40	entropía	0,45	0,45	PE80
E2	1 (118)	*PC-SMOTE*	85	40	entropía	0,35	0,45	PE60
E3	3 (116)	*PC-SMOTE*	90	45	proporción	0,35	0,50	Upp060

* Valor entre paréntesis indica semillas sintéticas candidatas detectadas.

Tabla 4.12: Rendimiento en Validación Cruzada (k-fold CV) para el Caso Base (US Crime)

Configuración	Tamaño Train	Tamaño Test	F1_M CV	F1_W CV	Acc CV
Caso Base (Original)	1595	399	0,713	0,930	0,941

Nota. El conjunto de entrenamiento (80 %) presenta un fuerte desbalance de clases: 1475 instancias pertenecen a la clase mayoritaria (-1) y solo 120 a la clase minoritaria (1).

Tabla 4.13: Rendimiento final: Comparativa de *PC-SMOTE* vs. Técnicas Clásicas (US Crime)

Exp.	Umbral IF	Técnica	Sem. Val.*	Sintet.	Train Final (Orig + Sintet.)	F1_M Test	Δ (F1_M)	F1_W Test	Acc Test
–	–	**Caso Base**	–	–	1595	0,765	–	0,940	0,945
E1	0 % (candidatas: 120)	**PC-SMOTE**	**21**	**1355**	**2950**	**0.801**	**+0.036**	**0.948**	**0.952**
–		*adasyn*	–	1368	2963	0,752	−0,013	0,928	0,925
–		*smote*	–	1355	2950	0,736	−0,029	0,923	0,920
–		*borderline*	–	1355	2950	0,725	−0,040	0,923	0,922
E2	1 % (candidatas: 118)	**PC-SMOTE**	**2**	**1342**	**2920**	**0.788**	**+0.023**	**0.944**	**0.947**
–		*borderline*	–	1342	2920	0,719	−0,046	0,918	0,915
–		*smote*	–	1342	2920	0,747	−0,018	0,926	0,922
E3	3 % (candidatas: 116)	**PC-SMOTE**	**6**	**1314**	**2860**	**0.742**	**-0.023**	**0.931**	**0.935**
–		*smote*	–	1314	2860	0,715	−0,050	0,916	0,912
–		*adasyn*	–	1304	2850	0,725	−0,040	0,917	0,910
–		*borderline*	–	1314	2860	0,707	−0,058	0,913	0,907

* Semillas candidatas validadas en el conjunto de entrenamiento (*train*). Δ ($F1_M$) representa la ganancia o pérdida absoluta respecto al Caso Base. *Nota:* Los experimentos E1, E2 y E3 resaltan la variante de *PC-SMOTE* con mejor desempeño.

5. CONCLUSIONES Y TRABAJOS FUTUROS

5.1. Conclusiones

En la presente investigación se abordó uno de los desafíos más persistentes en el aprendizaje automático supervisado: la degradación del rendimiento de los clasificadores frente a la sinergia perjudicial entre el desbalance de clases y el solapamiento estructural. Para superar las limitaciones de la interpolación ciega y la sobregeneralización de métodos tradicionales, se desarrolló y validó el algoritmo PC-SMOTE (Percentile-Controlled SMOTE).

La principal contribución de este trabajo radica en proponer y evaluar una heurística geométrica basada en percentiles para definir umbrales de densidad, riesgo y pureza en el proceso de sobremuestreo. En los experimentos realizados con un modelo Random Forest sobre conjuntos de datos reales, PC-SMOTE mostró un comportamiento diferenciado según la geometría local de cada dataset: en algunos casos permitió obtener mejoras respecto de métodos clásicos y, en otros, restringió la generación cuando la vecindad resultó poco favorable para la interpolación.

En conjunto, los resultados permiten situar a PC-SMOTE dentro de la línea reciente de técnicas de sobremuestreo orientadas a considerar la geometría local de los datos. A diferencia de enfoques centrados principalmente en adaptar la generación sintética, la propuesta presentada busca extender esa preocupación a la selección de semillas candidatas mediante una heurística empírica basada en percentiles.

5.2. Discusión

Un hallazgo de particular relevancia durante la etapa experimental fue el comportamiento del algoritmo frente a distintos niveles de solapamiento y fragmentación de clases. Mientras que en datasets con buena separabilidad local PC-SMOTE logró una cobertura de sintéticos que mejoró el poder discriminatorio del modelo, en escenarios de mayor complejidad y ruido la técnica limitó la generación de muestras.

Un contraste especialmente ilustrativo se observó entre los datasets *US Crime* y *Predict Faults*: aunque ambos presentaron configuraciones de radar globalmente similares, PC-SMOTE mostró desempeños diferentes, lo que sugiere que la forma general del radar no basta para anticipar el comportamiento de la técnica, ya que la respuesta del algoritmo también depende de la geometría efectiva de las vecindades, en particular del grado de solapamiento local y de la cohesión de las semillas disponibles. En el caso de *Predict Faults*, la mayor superposición entre instancias normales y de falla habría reducido la calidad geométrica de las semillas candidatas, limitando así la utilidad del sobremuestreo.

Este comportamiento puede interpretarse como una señal empírica sobre la geometría del dataset: una tasa elevada de rechazo de semillas sugiere que la vecindad local no ofrece condiciones favorables para el sobremuestreo. En ese sentido, PC-SMOTE no solo actúa como un método de generación, sino también como una herramienta que aporta información adicional sobre la conveniencia de interpolar en cada escenario.

Bajo esta perspectiva, los resultados obtenidos pueden servir para decidir si conviene insistir con el remuestreo o complementar el análisis con otras estrategias, como la ingeniería de atributos o el aprendizaje sensible al costo.

5.3. Trabajos Futuros

A partir de las conclusiones obtenidas, se proponen las siguientes líneas de investigación:

- **Selección asistida del percentil de densidad y perfiles de rigor:** Se propone explorar procedimientos automáticos o asistidos para la selección del percentil de densidad que actualmente debe ser definido por el usuario. Dado que este percentil determina el radio global de vecindad empleado en la selección de semillas y en la generación de muestras sintéticas, su elección podría estimarse a partir del análisis de la curva de distorsión construida sobre las distancias intra-clase. Sobre esta base, podrían definirse perfiles de rigor preestablecidos (e.g., *Light, Medium, Hard*) que traduzcan dicha recomendación en distintos niveles interpretables de exigencia geométrica.

- **PC-SMOTE como apoyo al análisis geométrico del dataset:** Una línea prometedora consiste en transformar la técnica en un asistente de decisión. Ante un dataset nuevo, PC-SMOTE podría realizar un análisis geométrico preliminar para orientar la elección entre sobremuestreo, ingeniería de atributos u otras estrategias metodológicas.

- **Selección del percentil de pureza mediante entropía:** Si bien PC-SMOTE ya emplea la entropía de Shannon como una métrica de pureza, el percentil utilizado para definir el umbral de aceptación de vecindarios continúa siendo un hiperparámetro ingresado manualmente por el usuario. Como línea futura, se propone automatizar la selección de dicho percentil a partir de un criterio geométrico o empírico. En lugar de fijar un valor arbitrario, el algoritmo podría explorar un rango discreto de percentiles y seleccionar aquel que maximice el equilibrio entre cobertura de semillas candidatas y homogeneidad local de los vecindarios aceptados.

Bibliografía

[1] Carvalho, M., Pinho, A. J., and Brás, S. Resampling approaches to handle class imbalance: a review from a data perspective. *Journal of Big Data 12* (2025), 71. URL: https://doi.org/10.1186/s40537-025-01119-4.

[2] Chawla, N. V., Bowyer, K. W., Hall, L. O., and Kegelmeyer, W. P. Smote: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research 16* (2002), 321–357. URL: https://doi.org/10.1613/jair.953.

[3] Douzas, G., and Bacao, F. Geometric SMOTE: Effective oversampling for imbalanced learning through a geometric extension of SMOTE. *arXiv preprint arXiv:1709.07377* (2017). URL: https://arxiv.org/pdf/1709.07377.

[4] Feng, Y., and Li, J. A novel αDistance Borderline-ADASYN-SMOTE algorithm for imbalanced data and its application in Alzheimer's disease classification based on Dense Convolutional Network. In *Journal of Physics: Conference Series* (2021), vol. 2031, IOP Publishing, p. 012046. URL: https://iopscience.iop.org/article/10.1088/1742-6596/2031/1/012046/pdf.

[5] Fernández, A., García, S., Galar, M., Prati, R. C., Krawczyk, B., and Herrera, F. *Learning from Imbalanced Data Sets*. Springer, 2018. URL: https://doi.org/10.1007/978-3-319-98074-4.

[6] Galar, M., Fernández, A., Barrenechea, E., Bustince, H., and Herrera, F. A review on ensembles for the class imbalance problem: Bagging-, boosting-, and hybrid-based approaches. *IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews) 42*, 4 (2012), 463–484. URL: https://doi.org/10.1109/TSMCC.2011.2161285.

[7] Han, H., Wang, W.-Y., and Mao, B.-H. Borderline-smote: a new over-sampling method in imbalanced data sets learning. In *Advances in Intelligent Computing: International Conference on Intelligent Computing, ICIC 2005* (2005), Springer, pp. 878–887. URL: https://doi.org/10.1007/11538059_91.

[8] He, H., Bai, Y., Garcia, E. A., and Li, S. Adasyn: Adaptive synthetic sampling approach for imbalanced learning. In *2008 IEEE International Joint Conference on Neural Networks* (2008), IEEE, pp. 1322–1328. URL: https://doi.org/10.1109/IJCNN.2008.4633969.

[9] Kaggle. Telco customer churn. https://www.kaggle.com/datasets/blastchar/telco-customer-churn, 2018.

[10] Kaggle. Machine predictive maintenance classification. https://www.kaggle.com/datasets/shivamb/machine-predictive-maintenance-classification, 2020.

[11] Khorshidi, H. A., and Aickelin, U. A synthetic over-sampling method with minority and majority classes for imbalance problems. *Knowledge and Information Systems 67* (2025), 5965–5998. URL: https://doi.org/10.1007/s10115-025-02394-6.

[12] Lyu, J., Yang, J., Su, Z., and Zhu, Z. Ld-smote: A novel local density estimation-based oversampling method for imbalanced datasets. *Symmetry 17*, 2 (2025), 160. URL: https://doi.org/10.3390/sym17020160.

[13] Nasaruddin, N., Masseran, N., Idris, W. M. R., and Ul-Saufie, A. Z. A smote pca hdbscan approach for enhancing water quality classification in imbalanced datasets. *Scientific Reports 15* (2025), 13059. URL: https://doi.org/10.1038/s41598-025-97248-0.

[14] Park, H., and Kim, H. AR-ADASYN: angle radius-adaptive synthetic data generation approach for imbalanced learning. *Statistics and Computing 34*, 5 (2024), 166. URL: https://doi.org/10.1007/s11222-024-10479-5.

[15] Poddar, G. M., Patil, R. V., and Kumar N, S. Approaches to handle data imbalance problem in predictive machine learning models: A comprehensive review. *International Journal of Intelligent Systems and Applications in Engineering 12*, 21s (2024), 841–856. URL: https://www.academia.edu/117048787.

[16] Pradipta, G. A., Wardoyo, R., Musdholifah, A., and Sanjaya, I. N. H. Radius-SMOTE: A new oversampling technique of minority samples based on radius distance for learning from imbalanced data. *IEEE Access 9* (2021), 74763–74777. URL: https://ieeexplore.ieee.org/stamp/stamp.jsp?arnumber=9431216.

[17] Qiu, F., Yang, F., Xiong, Y., Chen, T., Xiao, P., Zheng, W., Chen, X., and Zhou, K. Vs-smote: Leveraging high-value spaces to balance noise control and data diversity for class-imbalanced learning. *Neurocomputing* (2025). URL: https://papers.ssrn.com/sol3/Delivery.cfm?abstractid=5234376.

[18] Santos, M. S., Abreu, P. H., Japkowicz, N., Fernández, A., and Santos, J. A unifying view of class overlap and imbalance: Key concepts, multi-view panorama, and open avenues for research. *Information Fusion 89* (2023), 228–253. URL: https://sci2s.ugr.es/sites/default/files/ficherosPublicaciones/2997_2022-INFFUS-Unifying%20view%20overlap.pdf.

[19] Saputra, D. C. E., Sunat, K., and Ratnaningsih, T. Smote-mrs: A novel smote-multiresolution sampling technique for imbalanced distribution to improve prediction of anemia. *IEEE Access 12* (2024), 154675–154701. URL: https://ieeexplore.ieee.org/stamp/stamp.jsp?arnumber=10721227.

[20] UCI Machine Learning Repository. Statlog (shuttle) data set. https://archive.ics.uci.edu/dataset/148/statlog+shuttle, 1993.

[21] UCI Machine Learning Repository. Communities and crime data set. https://archive.ics.uci.edu/dataset/183/communities+and+crime, 2009.

[22] Wang, J., and Awang, N. Ch-smote algorithm: A novel approach to improve random forest classification on class imbalanced datasets. *Journal of Computational Analysis and Applications 33*, 7 (2024), 1331–1349. URL: https://eudoxuspress.com/index.php/pub/article/view/1234.

[23] Wang, J., and Awang, N. A novel synthetic minority oversampling technique for multiclass imbalance problems. *IEEE Access 13* (2025). URL: https://www.researchgate.net/publication/387809455.