Universidad Nacional de Luján

PC-SMOTE: Una variante de SMOTE controlada por percentiles

Tesina de grado presentada para optar al título de
Licenciado en Sistemas de Información

Juan Natello

Director: Santiago Banchero

2026

RESUMEN

El aprendizaje automático supervisado enfrenta dificultades en conjuntos de datos con desbalance de clases, especialmente cuando este fenómeno se combina con el solapamiento estructural. En ese contexto, técnicas de sobremuestreo como SMOTE pueden degradar el rendimiento del clasificador si generan muestras sintéticas en regiones ambiguas del espacio de datos.

Este trabajo presenta PC-SMOTE (Percentile-Controlled SMOTE), una variante de SMOTE que utiliza una heurística geométrica basada en percentiles para definir radios de vecindad y combinar filtros de densidad, riesgo y pureza. El objetivo es regular la selección de semillas y la generación de muestras sintéticas de acuerdo con la distribución local de radios observada en cada clase.

La metodología fue evaluada experimentalmente mediante un modelo Random Forest sobre diversos conjuntos de datos reales con asimetría severa, entre ellos Shuttle, US Crime, Telco Churn y Predict Faults. Los resultados sugieren que PC-SMOTE puede mejorar el rendimiento predictivo en escenarios con separabilidad local suficiente y, en casos de alto solapamiento, reducir la generación de sintéticos cuando la vecindad no resulta favorable. En conjunto, estos hallazgos indican que la heurística propuesta puede ser útil para regular la interpolación en contextos geométricamente heterogéneos.

Palabras claves: Aprendizaje Automático, Desbalance de Clases, Solapamiento Estructural, Sobremuestreo, SMOTE, Heuristica geometrica, Radios, Percentiles.

AGRADECIMIENTOS

Quiero agradecer a mi director de tesis Santiago Banchero por su dedicación y su guía constante a lo largo de todo el desarrollo de este trabajo, haciendo también extensivo este reconocimiento a mi esposa por su acompañamiento durante toda esta etapa, ya que su respaldo fue un pilar fundamental para poder transitar este exigente camino y alcanzar finalmente esta meta en mi carrera profesional

A mis padres, por los valores inculcados y el ejemplo de esfuerzo.
A mis hijos Giovanna y Dante, por ser mi mayor inspiración
y el motivo de cada paso que doy hacia el futuro.

Índice general

Resumen I

Índice VIII

1.. INTRODUCCIÓN Y OBJETIVOS 1
- 1.1. Introducción 1
- 1.2. Motivación 2
  - 1.2.1. Selección geométrica de semillas 2
- 1.3. Definición del Problema 2
- 1.4. Objetivos 3
  - 1.4.1. Objetivo General 3
  - 1.4.2. Objetivos Específicos 3
  - 1.4.3. Estructura de la Tesis 3

2.. MARCO TEORICO 5
- 2.1. Aprendizaje Automático y Clasificación 5
- 2.2. El Problema del Desbalance de Clases 5
- 2.3. Técnicas de Preprocesamiento: Remuestreo 7
  - 2.3.1. Sobremuestreo Sintético: Evolución Algorítmica y Sensibilidad Espacial 9
  - 2.3.2. Enfoques Híbridos: Integración Externa y Filtrado de Ruido 10
- 2.4. Conceptos Geométricos en Datos 10

3.. METODOLOGÍA 12
- 3.1. Arquitectura de PC-SMOTE 12
  - 3.1.1. Fase 1 (definición heurística de radios mediante percentiles) 13
    - 3.1.1.1. Límites geométricos y alta dimensionalidad 16
  - 3.1.2. Fase 2 (Filtros de pureza, densidad y riesgo) 16
    - 3.1.2.1. Eleccion del parametro k 17
    - 3.1.2.2. Estrategia de vecindad global 18
    - 3.1.2.3. Umbral de dominancia minoritaria en el criterio por entropía 19
    - 3.1.2.4. Variación en la cantidad de semillas válidas 19
  - 3.1.3. Fase 3 (Etapa de Generación adaptativa) 20
- 3.2. Pipeline de sobremuestreo 20
  - 3.2.1. Descripción de los Conjuntos de Datos 21
- 3.3. Pipeline de entrenamiento y testeo 22
  - 3.3.1. Hiperparámetros fijos del clasificador 22
  - 3.3.2. Entrenamiento y testeo comparativo 23
- 3.4. Métricas de Evaluación 24
  - 3.4.1. Precisión y Exhaustividad 25
  - 3.4.2. F1-score 25
  - 3.4.3. F1 macro-average 25
  - 3.4.4. F1 weighted-average 26

4.. RESULTADOS 27
4.1. Análisis de la configuración geométrica basada en percentiles 27
4.2. Análisis de Radios 28
4.2.1. Lectura aplicada del análisis geométrico en Telco Churn 31
4.3. Dinámica de filtrado en PC-SMOTE 31
4.4. Análisis de resultados de la implementación de PC-SMOTE 36

5.. DISCUSIÓN 42
5.1. Interpretación de los resultados de PC-SMOTE 42
5.2. Comparación con estudios sobre datasets afines 43
5.3. Limitaciones e implicancias 45

6.. CONCLUSIONES Y TRABAJOS FUTUROS 47
6.1. Conclusiones 47
6.2. Trabajos Futuros 47

Bibliografía 49

1. INTRODUCCIÓN Y OBJETIVOS

El desbalance de clases es un problema recurrente en la construcción de modelos de aprendizaje automático supervisado, ya que induce sesgos hacia la clase mayoritaria y reduce la capacidad del modelo para reconocer los casos minoritarios [9, 8, 2]. Esta limitación resulta especialmente relevante cuando la clase minoritaria concentra el mayor interés analítico o decisional.

Un ejemplo paradigmático de esta problemática es el dataset *Shuttle* [31], donde la detección de estados críticos en transbordadores espaciales se ve dificultada por el predominio de condiciones normales sobre las anomalías. En escenarios de este tipo, los modelos suelen favorecer a la clase mayoritaria y exhibir bajos niveles de sensibilidad ante eventos poco frecuentes.

Frente a este problema, las técnicas de sobremuestreo sintético se han consolidado como una alternativa para incrementar la representación de la clase minoritaria sin descartar datos [4, 2]. No obstante, su utilidad depende de que la generación de nuevas muestras respete la estructura local del espacio de datos. En ese marco, este trabajo estudia una variante de SMOTE que incorpora criterios de adaptabilidad geométrica y una heurística basada en percentiles para regular la selección de semillas y la generación de muestras sintéticas.

1.1. Introducción

Ante el escenario de desbalance previamente descrito, una respuesta ampliamente utilizada ha sido el preprocesamiento mediante remuestreo, cuyo objetivo es modificar la distribución de clases antes del entrenamiento [22, 8]. Dentro de este campo, el presente trabajo se concentra en el sobremuestreo sintético, ya que busca incrementar la presencia de la clase minoritaria sin descartar observaciones de la clase mayoritaria. En particular, SMOTE se consolidó como un método clásico para la generación de muestras sintéticas [4].

Esta técnica interpola nuevos ejemplos entre vecinos minoritarios cercanos, lo que supone un avance importante frente a la simple replicación de instancias. Sin embargo, su formulación original no considera explícitamente la estructura local de la clase mayoritaria ni el grado de solapamiento entre clases [2], por lo que puede introducir ruido, entendido aquí como muestras sintéticas ubicadas en regiones ambiguas o poco seguras que deterioran la frontera de decisión del clasificador [15, 25]. En consecuencia, la utilidad del sobremuestreo depende en gran medida de cómo se define la vecindad local: qué vecinos observar, cuán cerca deben estar y con qué criterios aceptar una semilla para interpolar.

Este problema vuelve crítica la elección de los hiperparámetros que regulan la vecindad local, en particular el número de vecinos considerados, los radios o umbrales de cercanía y los criterios de aceptación por densidad, riesgo y pureza, que en muchos métodos se fijan de manera estática o empírica [17, 2]. A partir de esta limitación, en esta investigación se propone una definición más adaptable de la cercanía entre muestras. Para ello, en una primera etapa se releva la vecindad inmediata de cada instancia mediante algoritmos basados en k vecinos más cercanos y, posteriormente, se utiliza la distribución empírica de las distancias observadas para definir, mediante percentiles, el significado de cercanía en cada conjunto de datos.

En este estudio se mantiene fijo el número de vecinos k, mientras que se calibran

experimentalmente los percentiles de radio para densidad y riesgo, el criterio de pureza y los umbrales de aceptación asociados.

Este interés por adaptar el sobremuestreo a la geometría local ya aparece en antecedentes relevantes de la literatura. Desde extensiones geométricas tempranas como G-SMOTE, que amplían la región de generación más allá del segmento lineal original [5], hasta propuestas recientes como LD-SMOTE y VS-SMOTE, orientadas a incorporar criterios locales de densidad y control del ruido [17, 25], se observa una evolución hacia técnicas cada vez más sensibles a la estructura espacial de los datos. En continuidad con esa línea, la propuesta desarrollada en esta investigación busca articular y combinar esas ideas mediante una heurística basada en percentiles que permita adaptar la geometría de trabajo a través de radios de densidad y riesgo, utilizando esa información tanto para la selección de semillas candidatas como para la generación de muestras sintéticas.

1.2. Motivación

La motivación de este trabajo surge de la necesidad de contar con una definición más adaptable de la cercanía entre muestras en contextos de desbalance y solapamiento. Si bien el sobremuestreo es un terreno ampliamente explorado, persisten desafíos de investigación vinculados a la adaptabilidad de los algoritmos a la diversidad geométrica de los datos. Asimismo, revisiones recientes señalan que el desempeño de los métodos de remuestreo depende en gran medida de su capacidad para identificar regiones problemáticas y ajustar su comportamiento al contexto local [2, p. 14], lo que refuerza la conveniencia de incorporar heurísticas basadas en percentiles que definan la noción de cercanía y vecindad según la geometría específica de cada conjunto de datos.

1.2.1. Selección geométrica de semillas

Por ello, resulta relevante estudiar estrategias que no se limiten a interpolar entre vecinos minoritarios, sino que también consideren la calidad geométrica de las instancias utilizadas como semillas. La incorporación de criterios de densidad, riesgo y pureza permite formular reglas de selección más sensibles a la estructura local del dataset.

Desde esta perspectiva, la propuesta aquí desarrollada se orienta al diseño de una técnica de remuestreo que combine percentiles y filtros geométricos para regular la elección de semillas candidatas y la posterior síntesis de ejemplos artificiales.

1.3. Definición del Problema

El principal inconveniente a resolver es la sinergia perjudicial que se produce entre el desbalance de clases y el solapamiento estructural (class overlap), ya que estudios previos han demostrado que la asimetría en la distribución de datos por sí sola no obstaculiza el aprendizaje si las clases son fácilmente separables. Sin embargo, la presencia del desbalance exacerba factores de dificultad como el solapamiento y los pequeños disyuntos (small disjuncts), elevando la complejidad del problema [2, 9]. En consecuencia, las escasas muestras de la clase minoritaria pueden quedar inmersas en regiones dominadas por la clase mayoritaria, degradando sustancialmente el rendimiento de los modelos de aprendizaje [7, 34].

Como ejemplo aplicado puede considerarse el escenario de mantenimiento predictivo industrial, evaluado en este trabajo mediante el dataset *Predict Faults* [13]. En este entorno, las maquinarias próximas a una falla pueden presentar parámetros térmicos y físicos muy similares a los de máquinas en funcionamiento normal, por lo que el espacio

de datos exhibe un alto grado de solapamiento y la frontera entre clases se vuelve difícil de delimitar.

Bajo estas condiciones, las técnicas de sobremuestreo que interpolan sin evaluar adecuadamente la seguridad de la vecindad local pueden generar instancias sintéticas en regiones ambiguas. Esto favorece la intrusión sobre el espacio de la clase dominante, aumenta el ruido y deteriora la capacidad del clasificador para distinguir entre condiciones normales y situaciones de falla.

Por lo tanto, el problema central radica en la falta de criterios geométricos basados en percentiles que permitan ajustar los umbrales de densidad, riesgo y pureza a partir de la evidencia empírica provista por cada dataset. Esto plantea la necesidad de una técnica que oriente la generación de muestras sintéticas hacia regiones más adecuadas para la interpolación y preserve, en la medida de lo posible, la estructura local del conjunto de datos original.

1.4. Objetivos

En función del problema planteado, esta investigación propone una variante de SMOTE que incorpora criterios de adaptabilidad geométrica y una heurística basada en percentiles para regular la generación de muestras sintéticas.

1.4.1. Objetivo General

El objetivo general de este trabajo es desarrollar y validar un algoritmo de sobremuestreo, denominado PC-SMOTE, que incorpore criterios geométricos basados en percentiles para mejorar el rendimiento de modelos de clasificación en conjuntos de datos desbalanceados.

1.4.2. Objetivos Específicos

Para alcanzar este objetivo general, se plantean los siguientes objetivos específicos:

- Sintetizar el marco teórico y las limitaciones de los métodos actuales de sobremuestreo.
- Formalizar las etapas de funcionamiento de PC-SMOTE y describir los criterios geométricos que intervienen en cada una de ellas.
- Implementar PC-SMOTE en un entorno de desarrollo que permita su reproducción experimental.
- Analizar el comportamiento de PC-SMOTE en distintos escenarios de solapamiento y ruido.
- Validar estadísticamente la técnica mediante pruebas experimentales sobre datasets con alta disparidad.

1.4.3. Estructura de la Tesis

Para facilitar la lectura, la tesis se organiza en seis capítulos. El primer capítulo introduce el problema del desbalance de clases, su relación con el solapamiento estructural, la motivación del trabajo, la definición del problema y los objetivos que orientan la investigación.

El segundo capítulo presenta el marco teórico y los antecedentes relevantes. En particular, revisa la evolución de las técnicas de sobremuestreo y las propuestas que incorporan criterios de adaptabilidad geométrica y heurísticas basadas en percentiles.

El tercer capítulo describe la metodología propuesta y detalla la arquitectura y el funcionamiento de PC-SMOTE, incluyendo sus etapas principales, los criterios de selección de semillas y el flujo general del proceso de remuestreo, entrenamiento y evaluación.

El cuarto capítulo expone el diseño experimental y los resultados obtenidos en los distintos conjuntos de datos, comparando la propuesta con métodos de referencia.

El quinto capítulo desarrolla la discusión de los resultados, interpreta el comportamiento de PC-SMOTE en función de la geometría local de los datasets, lo contrasta con antecedentes afines y analiza sus principales limitaciones e implicancias.

Finalmente, el sexto capítulo presenta las conclusiones generales del estudio y propone posibles líneas de trabajo futuro.

2. MARCO TEORICO

En el presente capítulo se establecen las bases teóricas y conceptuales sobre las cuales se sostiene esta investigación: inicialmente se abordarán los fundamentos del aprendizaje automático y la clasificación supervisada, luego se profundizará en el problema del desbalance de clases y en la forma en que el solapamiento estructural exacerba su dificultad, y posteriormente se describirán las técnicas de preprocesamiento con especial énfasis en el sobremuestreo y en SMOTE como método clásico. Finalmente, se introducirán conceptos geométricos relevantes para el análisis de vecindades y el uso de percentiles como heurística para definir radios de trabajo, lo que constituye el núcleo teórico del algoritmo propuesto en este trabajo.

2.1. Aprendizaje Automático y Clasificación

El aprendizaje automático supervisado tiene como objetivo principal inducir un modelo o clasificador capaz de predecir la clase de salida para instancias previamente no vistas, buscando siempre una alta capacidad de generalización [9]. En términos formales, el proceso de clasificación implica obtener una aproximación empírica de una función desconocida para mapear un vector de entrada multidimensional hacia valores objetivo o etiquetas de clase específicas [2], a partir del conocimiento extraído de un conjunto de entrenamiento compuesto por instancias cuyas etiquetas ya son conocidas por el sistema.

2.2. El Problema del Desbalance de Clases

En el ámbito de la clasificación, un conjunto de datos se considera desbalanceado cuando existe una disparidad significativa en el número de muestras que pertenecen a las diferentes clases. Convencionalmente, la clase con el menor número de instancias se denomina clase minoritaria (o positiva) y suele representar el concepto de mayor interés analítico, mientras que la clase predominante se conoce como clase mayoritaria (o negativa) [9, 8, 2].

El principal inconveniente de esta condición es que los algoritmos de clasificación estándar asumen distribuciones de clases relativamente equilibradas y son guiados por métricas de evaluación globales, como la precisión general (accuracy). Esto provoca que el modelo tienda a sesgarse hacia la clase mayoritaria para maximizar su rendimiento, ignorando a menudo a los ejemplos de la clase minoritaria al ser incapaz de distinguirlos o al tratarlos simplemente como ruido [8].

Sin embargo, revisiones recientes en la literatura demuestran que la asimetría por sí sola no obstaculiza el proceso de aprendizaje si las clases son fácilmente y linealmente separables [27, 2], y en ese marco el desbalance actúa más bien como un catalizador que exacerba otros factores de dificultad intrínsecos de los datos, siendo el solapamiento de clases (*class overlap*) uno de los fenómenos más perjudiciales [27, 2]. Este solapamiento ocurre cuando existen regiones del espacio pobladas simultáneamente por muestras de diferentes clases, lo que dificulta definir una frontera de decisión clara sin inducir sobreajuste [9, 27] y, cuando además la escasez de muestras minoritarias se combina con ese escenario, las instancias positivas quedan inmersas en regiones dominadas por la clase negativa, elevando drásticamente la complejidad del problema y degradando el rendimiento predictivo [8, 2].

La Figura 2.1 presenta una representación conceptual de este fenómeno sobre un plano bidimensional de atributos, donde ambas clases comparten una región común y la delimitación de la frontera de decisión se vuelve menos nítida. En estas figuras, los ejes f_1 y f_2 representan dos atributos del conjunto de datos, de modo que cada punto corresponde a una muestra observada en ese subespacio de características y no a la gráfica de una función.

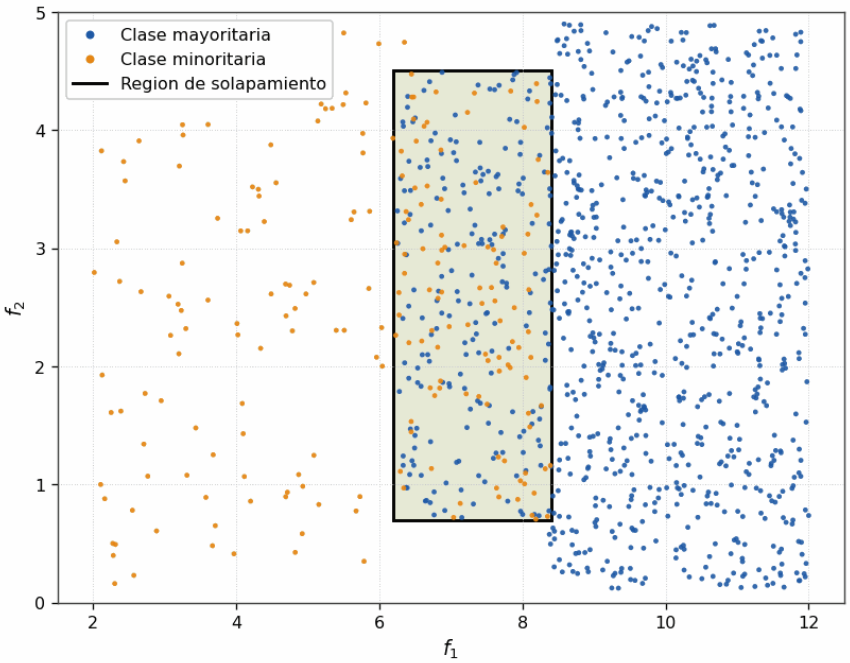

Figura 2.1: Representación conceptual del solapamiento estructural entre clases.

Otro factor de dificultad estrechamente relacionado son los pequeños disyuntos (*small disjuncts*), entendidos como subregiones pequeñas y escasamente representadas de una clase que quedan aisladas respecto del patrón dominante de esa misma clase [9, 2]. Debido a su reducido tamaño, estas estructuras tienden a quedar mal modeladas por el clasificador y se vuelven especialmente frágiles cuando, además, coexisten con desbalance y solapamiento.

La Figura 2.2 ilustra este concepto mediante pequeños grupos minoritarios escasamente representados y muestra que su dificultad aumenta cuando alguno de ellos queda inmerso en una región de solapamiento con la clase mayoritaria.

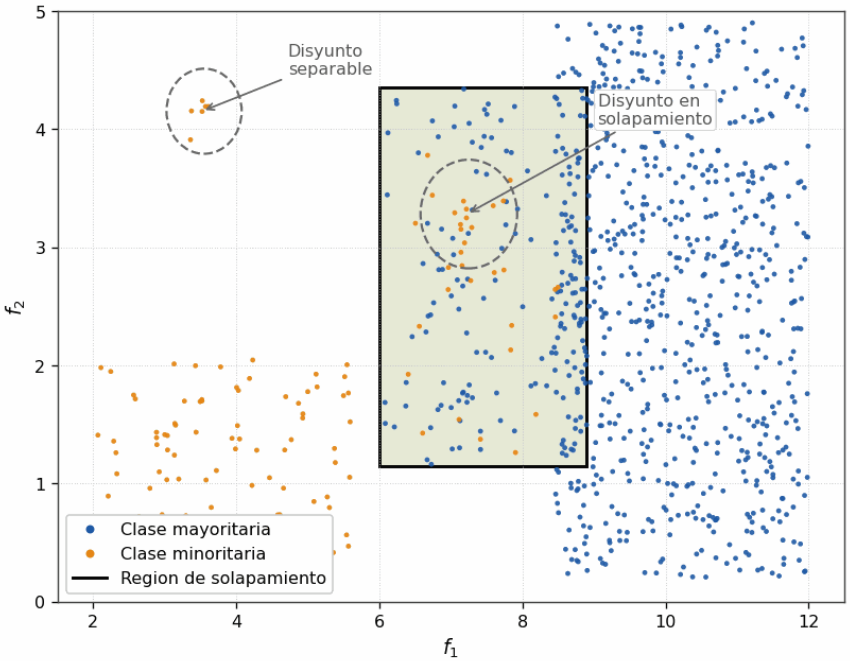

Figura 2.2: Representación conceptual de pequeños disyuntos minoritarios y de su mayor dificultad cuando coexisten con solapamiento.

2.3. Técnicas de Preprocesamiento: Remuestreo

En la literatura sobre aprendizaje con clases desbalanceadas suele distinguirse, en primer lugar, entre estrategias a nivel de datos, a nivel del algoritmo, sensibles al costo y basadas en *ensembles* [8]. La propuesta desarrollada en este trabajo se inscribe dentro del primer grupo, ya que interviene sobre la distribución del conjunto de entrenamiento antes de la etapa de aprendizaje, sin modificar internamente el funcionamiento del clasificador.

Dentro de las estrategias a nivel de datos, el remuestreo constituye una de las familias más utilizadas para corregir la asimetría entre clases [22, 2]. Estas técnicas suelen agruparse en tres grandes subfamilias: el submuestreo (under-sampling), que reduce la representación de la clase mayoritaria; el sobremuestreo (over-sampling), que incrementa la presencia de la clase minoritaria; y los enfoques híbridos, que combinan ambos mecanismos en un mismo esquema de remuestreo [9, 2]. La Figura 2.3 resume esta organización general y sitúa el recorte específico adoptado en este trabajo.

Dentro del sobremuestreo, además, resulta útil diferenciar entre sobremuestreo aleatorio y sobremuestreo sintético. El primero equilibra la clase minoritaria mediante la réplica de instancias ya observadas; su simplicidad lo convierte en un punto de partida natural, aunque sus limitaciones son conocidas, en particular la posibilidad de inducir sobreajuste al duplicar ejemplos idénticos [2, p. 15]. El segundo, en cambio, busca generar nuevas muestras a partir de la estructura local de la clase minoritaria. Dentro de este último grupo pueden distinguirse variantes lineales clásicas, enfoques orientados a frontera o dificultad, métodos geométricos con sensibilidad espacial y esquemas híbridos apoyados en *clustering* o filtrado previo. En este marco, PC-SMOTE puede ubicarse dentro del sobremuestreo sintético geométrico con sensibilidad local, en línea con la discusión de Carvalho et al. sobre métodos que identifican regiones apropiadas para sobremuestrear y adaptan la generación a la estructura local del espacio de datos [2, p. 19], así como con la idea de Santos et al. de que el desbalance debe analizarse conjuntamente con el solapamiento estructural

[27, pp. 228–229].

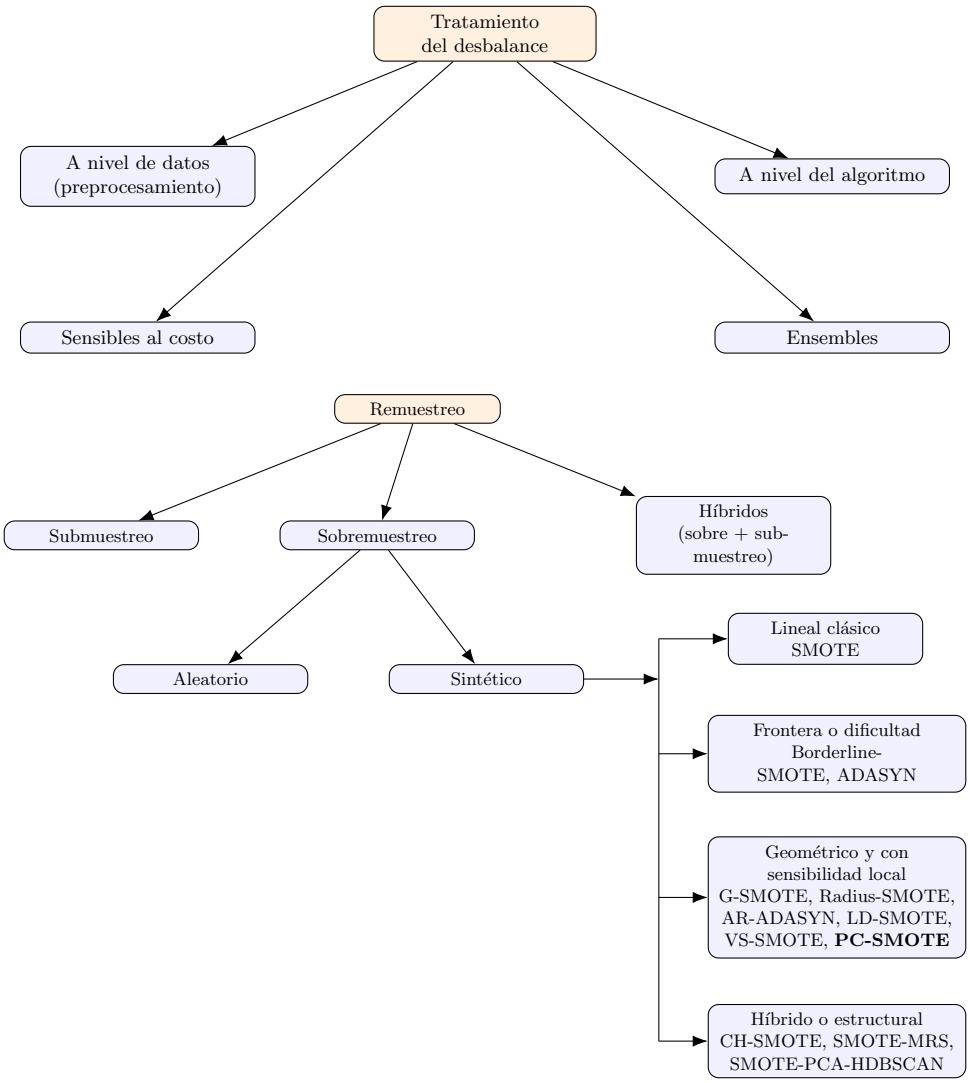

Figura 2.3: Árbol conceptual de familias y subfamilias para el tratamiento del desbalance. Arriba se muestran las familias generales; abajo se detalla la rama de remuestreo relevante para esta tesis.

La Figura 2.4 resume de forma esquemática las dos operaciones básicas del remuestreo, sobre las cuales también se construyen los enfoques híbridos: el submuestreo actúa eliminando observaciones de la clase mayoritaria, mientras que el sobremuestreo incrementa la presencia de la clase minoritaria mediante la incorporación de nuevas muestras.

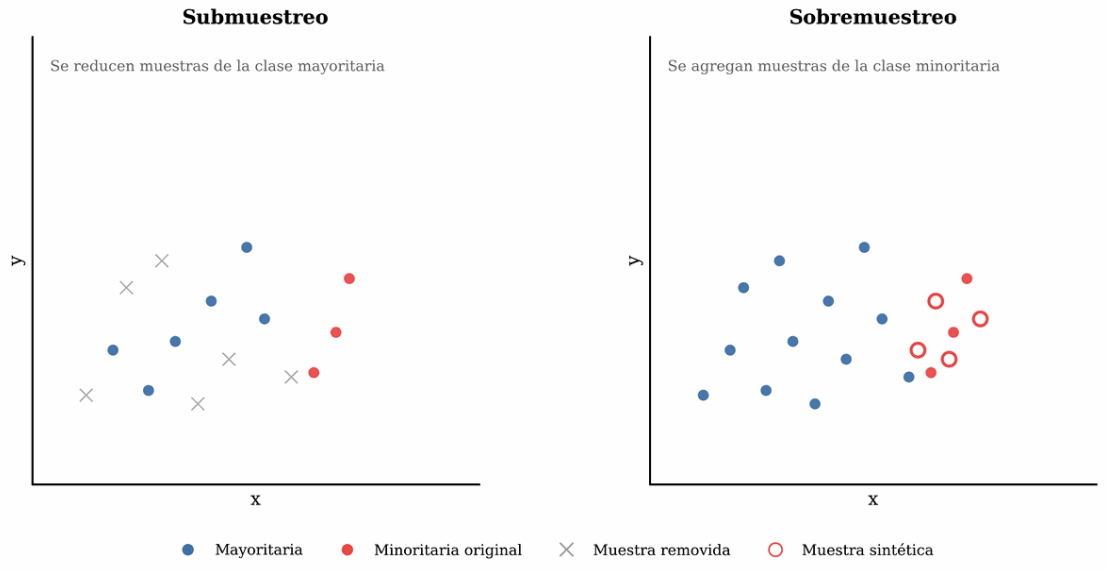

Figura 2.4: Representación conceptual de las operaciones básicas de remuestreo: submuestreo y sobremuestreo.

2.3.1. Sobremuestreo Sintético: Evolución Algorítmica y Sensibilidad Espacial

Para comprender la evolución de las técnicas de sobremuestreo resulta fundamental analizar primero aquellas metodologías que buscaron mejorar el mecanismo interno de generación, cuyo punto de partida es SMOTE, introducido por Chawla et al. [4], que equilibra las clases mediante interpolación lineal entre ejemplos minoritarios y cuyas limitaciones espaciales motivaron variantes tempranas como Borderline-SMOTE de Han et al. [10], que restringe la generación a muestras cercanas a la frontera de decisión, y ADASYN de He et al. [11], que adapta la cantidad de ejemplos sintéticos según la dificultad local de aprendizaje.

Esta primera etapa evolutiva dio paso a una segunda generación de algoritmos enfocados en la restricción geométrica: G-SMOTE de Douzas y Bacao [5] generaliza el mecanismo de SMOTE al permitir la generación dentro de una región geométrica flexible alrededor de cada instancia minoritaria, cuya forma y extensión pueden ajustarse mediante transformaciones geométricas y distintas estrategias de selección de vecindad, con el objetivo de reducir ejemplos ruidosos y aumentar la variedad de muestras sintéticas, mientras que Radius-SMOTE de Pradipta et al. [23] delimita una región segura circular para acotar el espacio de generación de muestras sintéticas y AR-ADASYN de Park y Kim [21] incorpora información angular para refinar ADASYN y obtener una distribución radial más fiel, aunque conserva sensibilidad a la selección de vecinos lejanos.

En una línea similar, αDBASMOTE de Feng & Li [7] combina elementos de Borderline-SMOTE y ADASYN mediante un factor de distancia ponderada para estimar la vulnerabilidad espacial. En conjunto, estas propuestas representan avances frente a la interpolación lineal ciega, pero también evidencian que el uso de métricas rígidas dificulta capturar la heterogeneidad geométrica de los conjuntos de datos.

A estas innovaciones se sumaron propuestas como OCH-SMOTE de Wang y Awang [33], que orienta la interpolación hacia el centro de gravedad de la clase minoritaria como criterio global de generación. A ello se añade SOMM, propuesto por Khorshidi y Aickelin [15], que intenta alejar las instancias sintéticas de la zona dominante mediante vectores

direccionales, aunque ambos enfoques se apoyan en reglas geométricas definidas de antemano o en mecanismos reactivos, en lugar de evaluar preventivamente la seguridad del entorno local.

Esta misma necesidad de evaluación preventiva también aparece en métodos recientes: LD-SMOTE de Lyu et al. [17] incorpora una estimación de la densidad local, aunque la evaluación de la pureza no ocupa un lugar central en su formulación, mientras que VS-SMOTE de Qiu et al. [25] prioriza la pureza de los subespacios sin incorporar un criterio equivalente de densidad local dentro de esa misma etapa.

En conjunto, estas propuestas muestran que densidad y pureza suelen tratarse de manera parcial, manteniendo abierto el desafío de articular ambos criterios dentro de una misma estrategia de generación sintética.

2.3.2. Enfoques Híbridos: Integración Externa y Filtrado de Ruido

Por otro lado, la literatura también ha encarado el problema del desbalance de manera externa mediante enfoques híbridos que combinan el sobremuestreo con herramientas adicionales para filtrar el ruido o reestructurar el espacio antes de la clasificación, destacándose en esta rama el modelo SMOTE-MRS desarrollado por Saputra et al. [28] que integra SMOTE con agrupamiento K-Means para garantizar que las muestras sintéticas se produzcan dentro de subgrupos homogéneos, así como la propuesta SMOTE-PCA-HDBSCAN introducida por Nasaruddin et al. [20] que utiliza el análisis de componentes principales para reducir la dimensionalidad y luego aplica el clustering adaptativo HDBSCAN para detectar y eliminar el ruido de manera dinámica, a las que se suma la implementación de redes generativas antagónicas documentada por Zhou et al. [7], quienes combinaron el modelo CGAN con la distancia de Wasserstein para generar datos altamente realistas evitando la propagación de ruido.

Estas metodologías demuestran que, aunque los pipelines híbridos resultan eficientes para depurar el conjunto de datos, la incorporación de arquitecturas de agrupamiento o redes neuronales externas incrementa el costo computacional y la cantidad de hiperparámetros a calibrar. En consecuencia, sigue siendo relevante investigar métodos de sobremuestreo que preserven la calidad geométrica de las muestras sintéticas sin depender de algoritmos auxiliares complejos.

2.4. Conceptos Geométricos en Datos

Para superar las deficiencias de la interpolación ciega de SMOTE, los enfoques del estado del arte han transitado hacia una evaluación de la geometría local de los datos. Este análisis permite categorizar a las muestras en regiones seguras (*safe*), de frontera (*danger*) o de ruido, dependiendo de la proporción y distancia de las clases presentes en su vecindario inmediato [2].

Para abordar adecuadamente la complejidad geométrica resulta indispensable asimilar que la densidad y distribución de la información en un conjunto de datos real no se presenta de manera uniforme, lo que hace que la utilización de hiperparámetros estáticos o radios de vecindad fijos pueda resultar insuficiente para capturar la estructura de las fronteras de decisión. En este contexto, la aplicación de percentiles en la minería de datos adquiere una utilidad relevante, ya que permite definir radios de vecindad a partir de la distribución empírica de distancias euclidianas evaluadas previamente mediante métodos tradicionales como k-NN, y desde esta perspectiva los percentiles pueden entenderse como una heurística geométrica para ajustar los radios de trabajo al entorno espacial observado.

El uso de percentiles permite adaptar el concepto de "radio" o "cercanía" a la morfología específica de cada clase y conjunto de datos, entendida como la forma que adopta su distribución espacial, así como su grado de concentración, dispersión y conectividad local. A partir de radios definidos heurísticamente mediante percentiles, es posible establecer umbrales de densidad local, pureza y riesgo, lo que favorece que la selección de semillas y la posterior generación de muestras sintéticas se concentren en entornos geométricamente más estables, mitigando la intrusión en el espacio de la clase mayoritaria y preservando la calidad informativa de los datos generados.

3. METODOLOGÍA

Sobre la base de los fundamentos teóricos desarrollados en el capítulo anterior, este capítulo expone el diseño metodológico adoptado para abordar el problema de clasificación en conjuntos de datos severamente desbalanceados. Con este propósito, se presenta el enfoque general de la investigación, así como los procedimientos definidos para la selección y el tratamiento de los datos, la implementación de los modelos y la evaluación de su desempeño. Asimismo, se especifican los criterios y las métricas empleados para analizar los resultados obtenidos. De este modo, se busca garantizar la coherencia entre el marco teórico, las decisiones metodológicas y los objetivos planteados en la investigación.

Esta orientación metodológica se justifica ya que, como afirman Santos et al. [27] y respaldan revisiones recientes de la literatura [2, 8], el desbalance de clases por sí solo no es el único responsable de la degradación del rendimiento de los modelos predictivos, sino que es su sinergia con factores de dificultad intrínsecos —particularmente el solapamiento de clases (*class overlap*), los pequeños disyuntos (*small disjuncts*) y el ruido— es lo que constituye el escenario estructural más perjudicial para el aprendizaje automático [2, p. 6]. Bajo estas condiciones, las técnicas tradicionales de sobremuestreo, como SMOTE, tienden a generar muestras sintéticas en regiones dominadas por la clase mayoritaria, incrementando el ruido y provocando un sobreajuste o sobregeneralización de las fronteras de decisión [2, p. 18]. Por ello, se vuelve necesario plantear un diseño orientado a los datos (*data-centric*) que evalúe activamente la viabilidad del espacio antes de sintetizar nueva información.

Para dar respuesta a este desafío estructural y garantizar una evaluación rigurosa, la metodología de este trabajo se organiza en tres etapas principales: arquitectura de PC-SMOTE (Figura 3.1), flujo de trabajo de sobremuestreo, descripción del proceso de entrenamiento y testeo de los modelos de aprendizaje.

En relacion a la arquitectura de PC-SMOTE, se presenta un esquema general de la técnica y se desarrollan sus tres fases constitutivas: (1) la definición heurística de radios mediante percentiles, (2) la aplicación de filtros geométricos y de pureza para seleccionar semillas candidatas y (3) la etapa de generación e interpolación adaptativa para crear muestras minoritarias.

La segunda etapa detalla el *pipeline* (flujo de trabajo) de sobremuestreo implementado para la experimentación. Este abarca desde la preparación y limpieza inicial del conjunto de datos mediante la detección de anomalías con *Isolation Forest*, hasta la construcción de las distintas versiones sobremuestreadas del conjunto de entrenamiento.

La tercera etapa describe el proceso de entrenamiento y testeo del modelo base seleccionado (*Random Forest*) bajo una configuración fija de hiperparámetros, así como la elección de métricas de rendimiento robustas frente al desbalance —como la métrica *F1-macro*— para evaluar de manera justa la capacidad del clasificador para reconocer a la clase minoritaria de interés.

3.1. Arquitectura de PC-SMOTE

Previo a detallar los fundamentos de cada una de las fases que componen la arquitectura del modelo, se presenta en la Figura 3.1 un esquema de síntesis de PC-SMOTE. Esta representación resume el flujo lógico de la técnica, desde la definición de radios percentiles hasta la generación sintética a partir de semillas validadas. La implementación completa

en Python se encuentra disponible de forma pública en el repositorio del proyecto.[1]

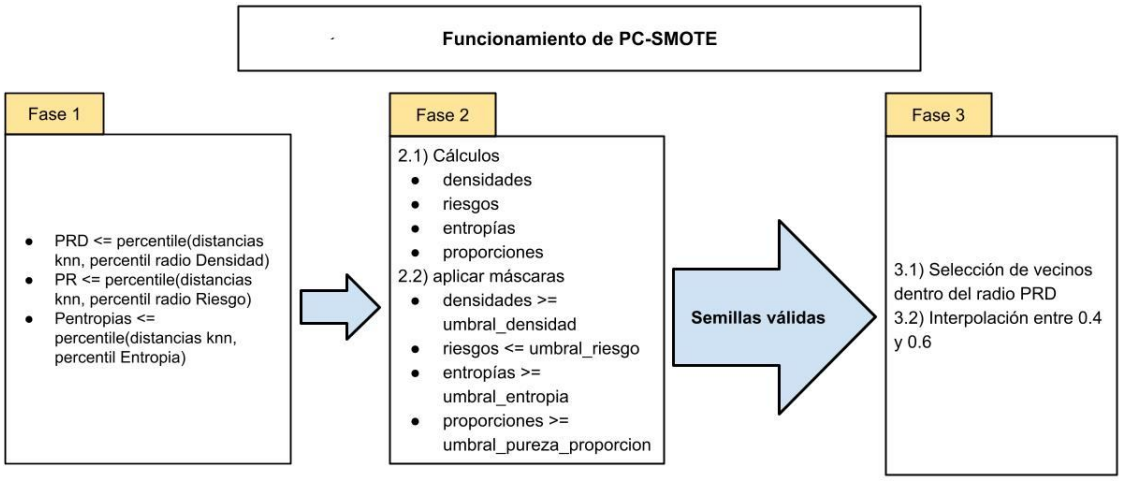

Figura 3.1: Etapas del sobremuestreo de PC-SMOTE

Las subsecciones siguientes desarrollan las tres fases que integran esta arquitectura: la definición heurística de radios, el filtrado de semillas candidatas y la generación adaptativa de muestras sintéticas.

3.1.1. Fase 1 (definición heurística de radios mediante percentiles)

En esta fase se determinan los umbrales de radio por densidad y riesgo y, cuando el criterio de pureza seleccionado es la entropía, también el umbral de entropía. Estos valores establecen los límites operativos de la vecindad, adecuando la escala espacial a la estructura de cada clase.

En este sentido, la heurística basada en percentiles permite fijar los umbrales de radio tanto para los cálculos de densidad como de riesgo y, de manera condicional, derivar también el umbral de entropía a partir del percentil configurado para ese criterio. Para ello, el algoritmo toma cada muestra de la clase actual y recorre sus k vecinos más cercanos utilizando un clasificador k-NN. Para cada vecino se calcula la distancia euclidiana respecto de la muestra de referencia, y al finalizar este proceso se obtienen $X \times k$ distancias totales, donde X corresponde al número de instancias de la clase evaluada.

Sobre el conjunto total de distancias se calcula el percentil definido por el parámetro de configuración. El valor resultante se interpreta como un radio adaptativo que representa el umbral por densidad y el umbral por riesgo. Si la pureza se evalúa mediante entropía, además se calcula el percentil correspondiente sobre el conjunto de entropías locales para obtener el umbral entrópico de aceptación.

En el paso siguiente se calculan todas las métricas de densidad, riesgo y pureza —ya sea por proporción o por entropía— para la clase actual, utilizando los umbrales previamente obtenidos.

El cálculo de estas métricas, que caracterizan el comportamiento de los casos minoritarios en un conjunto de datos desbalanceado, constituye un proceso multifacético basado en la evaluación de la vecindad de cada instancia. Para ello, en primer lugar se determina la densidad de cada caso minoritario obteniéndose al contar cuántos de sus k vecinos más

[1] Repositorio del proyecto: `https://github.com/jnatmed/tesis_pcsmote_natello`

cercanos (sin distinguir a qué clase pertenecen) se encuentran a una distancia menor o igual al *Percentil Radio Densidad* (PRD), dado que el objetivo principal de este filtro es captar vecindades densas en términos generales, dejando el análisis estricto de las clases a cargo de los filtros de pureza por entropía o proporción. La Figura 3.2 ilustra tanto un caso de aceptación como uno de rechazo según la cantidad de vecinos que efectivamente caen dentro del radio PRD.

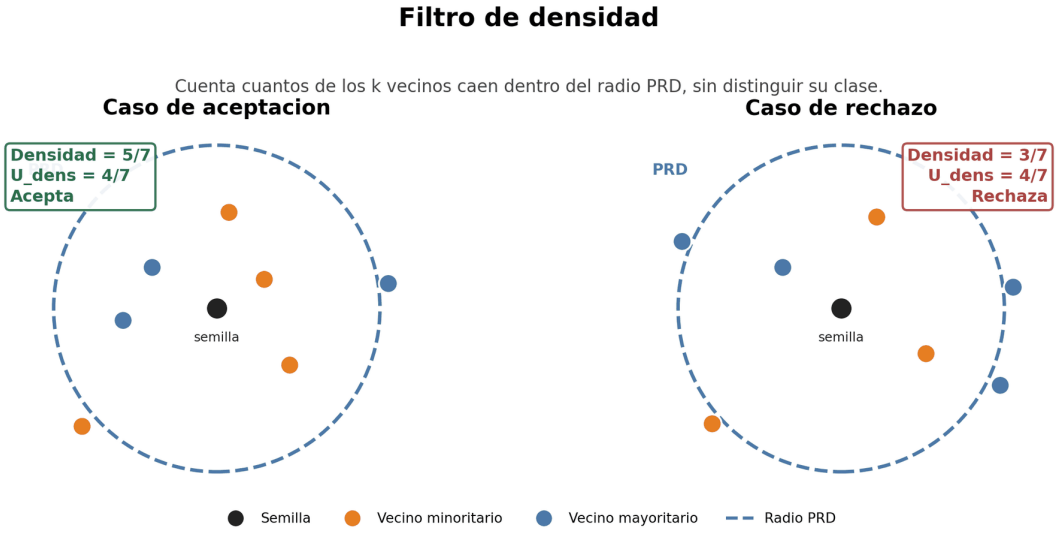

Figura 3.2: Casos de aceptación y rechazo para el filtro de densidad.

En contraste, para evaluar la vulnerabilidad o la posible ubicación en la frontera entre clases, se calcula el riesgo de cada caso minoritario, contabilizando cuántos de los k vecinos más cercanos pertenecen a la clase mayoritaria y se encuentran a una distancia menor o igual al *Percentil Radio Riesgo* (PRR). Un riesgo elevado indica que la instancia minoritaria se encuentra peligrosamente próxima a la clase dominante, lo que sugiere que podría tratarse de un caso en zona de frontera o de difícil clasificación. La Figura 3.3 (Filtro de Riesgo), muestra el contraste entre una semilla aceptada, con presión mayoritaria acotada, y una semilla rechazada por exceso de vecinos de la clase dominante dentro del radio PRR.

La última métrica puede aplicarse de dos maneras diferentes: la primera corresponde a la pureza por proporción, que consiste en contar cuántos vecinos de la misma clase existen dentro de la vecindad definida por los k vecinos más cercanos. Este cálculo constituye una forma directa de evaluar la cohesión local de la clase minoritaria, sin imponer una restricción basada en el radio percentil, y proporciona una visión clara de la concentración local de la clase de interés. La misma Figura 3.3 (Filtro Pureza por Proporción), ejemplifica ambas situaciones, diferenciando una configuración local suficientemente homogénea de otra en la que la proporción minoritaria resulta insuficiente para validar la semilla.

Alternativamente, la pureza puede evaluarse mediante la entropía de Shannon [29], calculada para cada instancia minoritaria a partir de la distribución de clases presentes entre sus k vecinos más cercanos. Así, la entropía actúa como una medida de incertidumbre o mezcla de clases en el entorno inmediato de la instancia, de modo que un valor alto indica un entorno altamente mezclado o ruidoso y sugiere que la instancia minoritaria se encuentra ubicada en una zona de solapamiento significativo entre clases. A diferencia del filtro de riesgo, que utiliza el *Percentil Radio Riesgo* para medir la presión local de la clase mayoritaria, los criterios de pureza por proporción y por entropía se calculan directamente

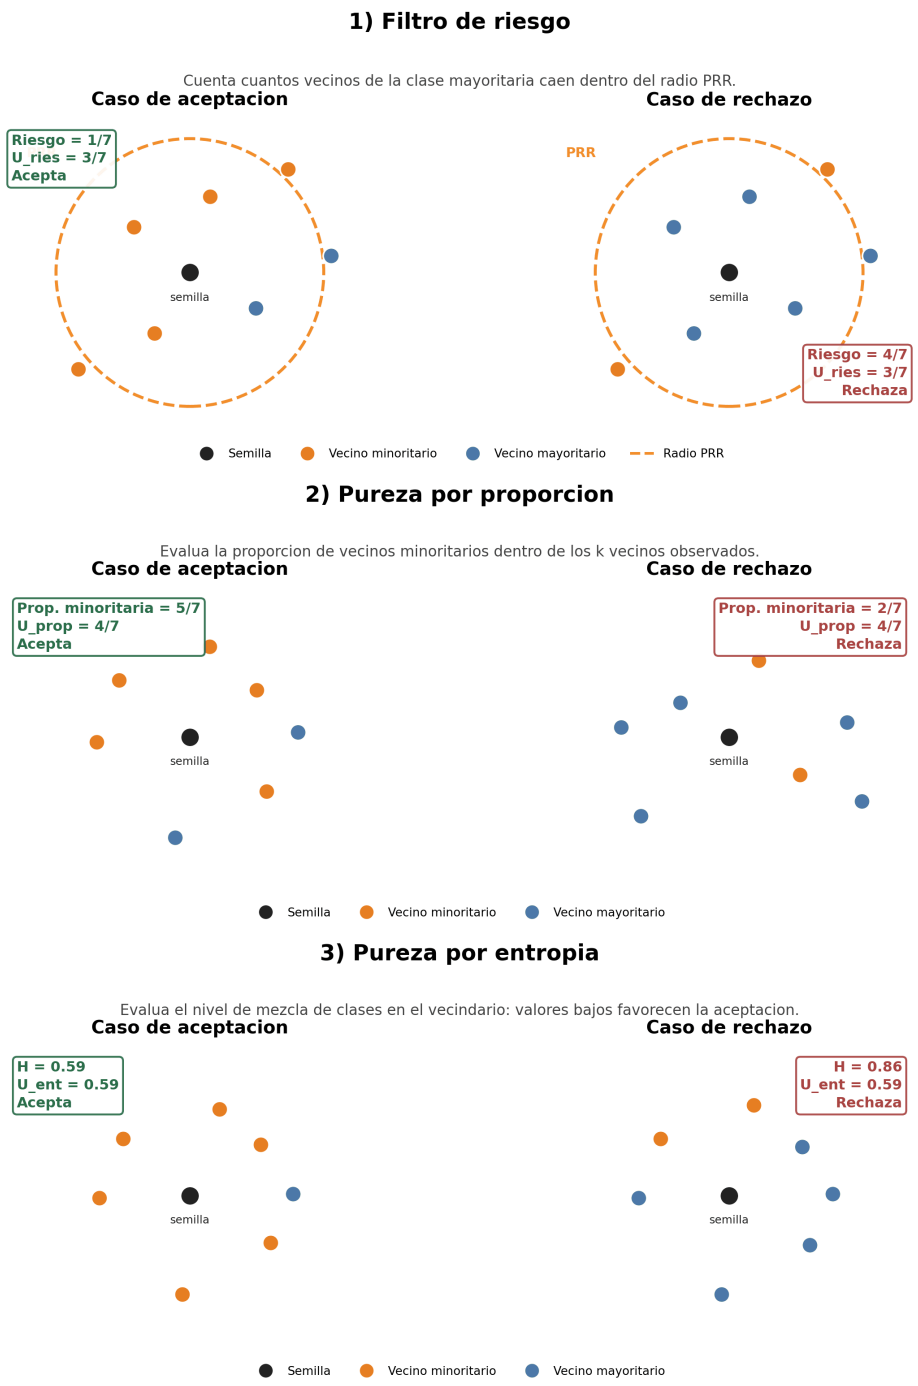

Figura 3.3: Casos de aceptación y rechazo para: (1) filtro de riesgo, (2) pureza por proporción y (3) pureza por entropía.

sobre la composición de los k vecinos observados. La Figura 3.3 (Filtro Pureza por entropía) resume este criterio mediante un caso estable de baja entropía y otro caso mezclado cuya incertidumbre excede el umbral de aceptación.

3.1.1.1. Límites geométricos y alta dimensionalidad

Esta fase presenta una limitación geométrica importante: la distancia euclidiana resulta más fiable en espacios de baja o moderada dimensionalidad. En conjuntos con un número muy elevado de características, la convergencia de distancias asociada a la maldición de la dimensionalidad puede volver poco informativos los percentiles calculados [25, 33]. Por esta razón, en escenarios ultradimensionales se considera recomendable aplicar previamente técnicas de reducción de dimensionalidad, como PCA [20, 28], antes de estimar los radios heurísticos del algoritmo.

3.1.2. Fase 2 (Filtros de pureza, densidad y riesgo)

A estos conjuntos de densidades, riesgos y pureza (proporción — entropía) se les aplica el filtro correspondiente de densidad, riesgo y pureza, también recibidos por parámetro, quedando solo aquellas semillas que hayan superado los tres filtros. Cuando el criterio elegido es la entropía, el valor calculado para cada instancia se contrasta con el umbral entrópico derivado en la Fase 1.

Como demuestran enfoques recientes, Pradipta et al. [23], filtrar las muestras minoritarias iniciales para descartar el ruido y conservar únicamente las instancias situadas en zonas estructuralmente seguras (*safe*) garantiza que la posterior generación de sintéticos no invada el territorio de la clase mayoritaria ni provoque nuevos conflictos en las regiones de solapamiento.

Con el objetivo de complementar la interpretación de los casos ilustrados en las figuras siguientes, se desarrolló un recurso interactivo complementario accesible en línea.[2]

Las Figuras 3.4 y 3.5 permiten visualizar, respectivamente, una semilla candidata que supera los filtros y otra que resulta descartada por la combinación de condiciones locales de densidad, riesgo y pureza.

[2] Recurso interactivo disponible en: `https://jnatmed.github.io/ejemplo-interactivo-pcsmote/pcsmote_interactivo.html`.

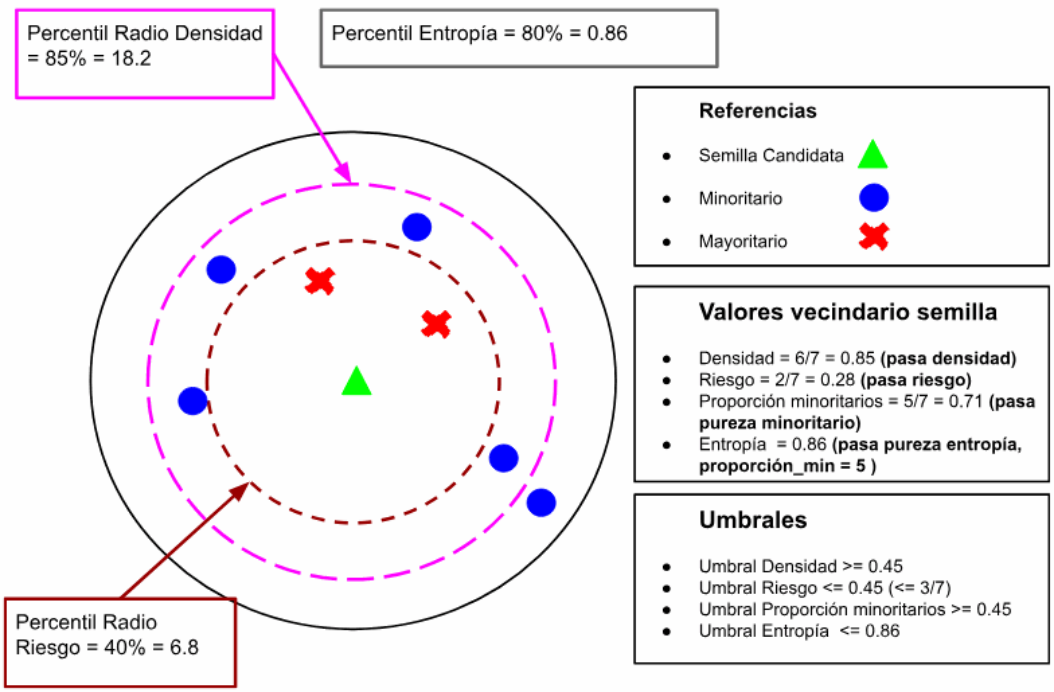

Figura 3.4: Caso de aceptación de semilla candidata

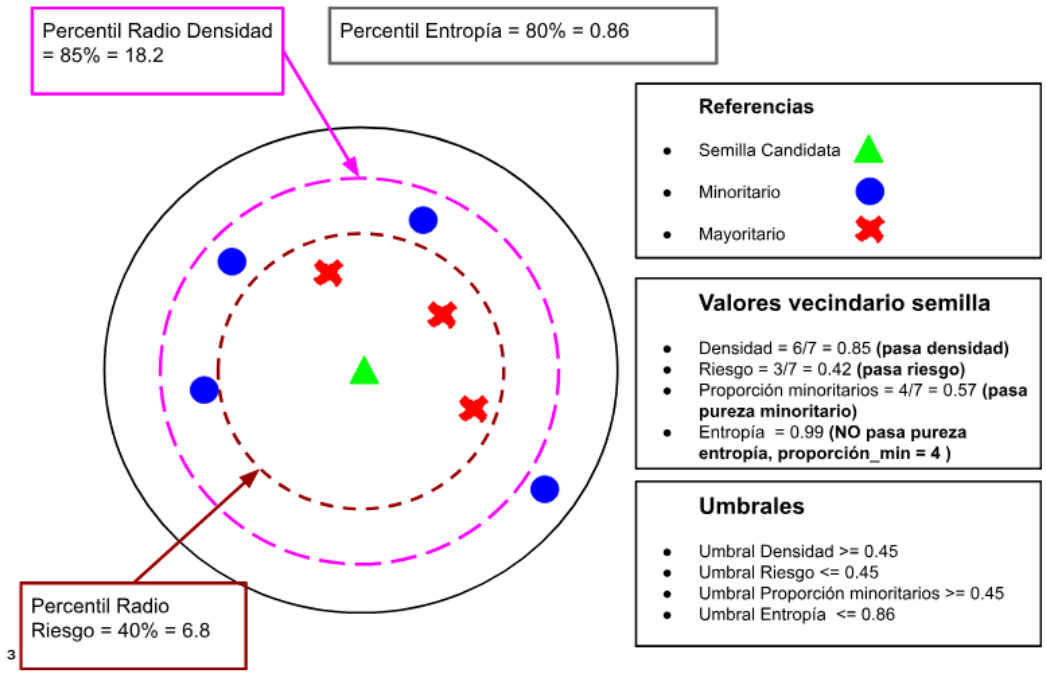

Figura 3.5: Caso Rechazo Semilla Candidata

3.1.2.1. Eleccion del parametro k

Antes de aplicar los filtros de la Fase 2, es necesario justificar el uso de un parámetro de vecindad fijo (k). En esta tesis, k designa siempre el tamaño base del vecindario observado por el clasificador k-NN; experimentalmente, ese valor se fijó en $k = 7$. Aunque la Fase 1

define radios variables mediante percentiles, esos radios no modifican la cantidad de vecinos considerados, sino el umbral espacial con el que se evalúan las condiciones de densidad y riesgo. La entropía de Shannon requiere además una base comparable entre instancias, por lo que se mantiene constante la cantidad de vecinos observados.

Esta decisión responde a un criterio de normalización: si el número de vecinos variara entre regiones densas y dispersas, los valores de entropía dejarían de ser directamente comparables. En consecuencia, la arquitectura adopta un valor constante de $k = 7$ para la evaluación de la pureza, mientras que el umbral de aceptación de dicha pureza se explora experimentalmente según el criterio utilizado.

De este modo, la estrategia experimental distingue entre parámetros fijos y parámetros explorados. Se mantiene fijo $k = 7$ como tamaño base del vecindario para preservar la comparabilidad entre instancias y clases, mientras que se varían los percentiles de radio para densidad y riesgo, el criterio de pureza (proporción o entropía), el parámetro asociado a ese criterio —umbral de pureza por proporción o percentil de entropía, a partir del cual se deriva el umbral entrópico de aceptación— y los umbrales de aceptación de densidad y riesgo.

Asi las cosas cabe destacar que, la adopción de $k = 7$ no implica que el algoritmo no pueda operar con valores superiores, los cuales podrían explorarse en estudios posteriores para analizar vecindarios más amplios. No obstante, no resulta conveniente descender por debajo de ese valor cuando la pureza se evalúa mediante entropía, ya que ello reduciría la granularidad del filtro correspondiente. Con un número demasiado pequeño de vecinos, la distribución local de clases admitida por la medida entrópica se vuelve excesivamente gruesa, limitando su sensibilidad para discriminar entre configuraciones geométricas próximas.

3.1.2.2. Estrategia de vecindad global

A diferencia de *SMOTE* clásico, que calcula los vecinos de cada semilla minoritaria únicamente dentro del subconjunto de instancias de la misma clase, PC-SMOTE ajusta el clasificador k-NN sobre el conjunto de datos completo. Esta decisión de diseño es intencional y responde a una necesidad metodológica: para calcular simultáneamente las métricas de densidad, riesgo y pureza, resulta imprescindible que los k vecinos más cercanos de cada semilla minoritaria puedan incluir instancias de la clase mayoritaria.

En efecto, el filtro de riesgo cuantifica la presión de vecinos contrarios dentro del radio r_{riesgo}. Si el clasificador se ajustase únicamente sobre X_{min}, todos los vecinos retornados pertenecerían siempre a la clase minoritaria, haciendo imposible medir la proximidad al territorio de la clase mayoritaria. Asimismo, los filtros de pureza por proporción y por entropía evalúan la distribución de clases en el vecindario inmediato, lo que requiere la presencia de instancias de ambas clases para ser informativos. En consecuencia, la estrategia de vecindad global no es simplemente una elección de implementación, sino un requisito estructural para que los tres filtros operen de forma conjunta y complementaria.

Tabla 3.1: Análisis de vecindarios y criterios de aceptación en PC-SMOTE basados en entropía y proporción de clase. V. Min. y V. May. indican la cantidad de vecinos minoritarios y mayoritarios, respectivamente; Prop. Min. expresa la proporción de vecinos minoritarios.

V. Min.	**V. May.**	**Prop. Min.**	**Entropía**	**Interpretación**	**Aceptación PC-SMOTE**
7	0	1,00	0,00	Pureza absoluta	Aceptado (Ideal)
6	1	0,86	0,59	Contaminación mínima	Aceptado
5	2	0,71	0,86	Contaminación moderada	Aceptado
4	3	0,57	0,99	Frontera (Dom. Min.)	Aceptado
3	4	0,43	0,99	Frontera (Dom. May.)	Aceptado ($t_{dom} = 0,4$)
2	5	0,29	0,86	Ruido	Descartado
1	6	0,14	0,59	Ruido	Descartado
0	7	0,00	0,00	Vecindario opuesto	Descartado

3.1.2.3. Umbral de dominancia minoritaria en el criterio por entropía

La quinta fila de la Tabla 3.1 presenta un vecindario con dominancia de la clase mayoritaria: 3/7 vecinos son minoritarios (proporción = 0,43) y la entropía es máxima ($H = 0{,}99$). En este caso, el criterio de entropía aceptaría la semilla si H fuese baja; sin embargo, dado que el vecindario está altamente mezclado, la sola condición de entropía resulta insuficiente para discriminar si la instancia está rodeada principalmente de su propia clase o de la contraria.

Para resolver esta ambigüedad, cuando el criterio de pureza seleccionado es la entropía, PC-SMOTE aplica un segundo criterio complementario: exige que la proporción de vecinos de la clase minoritaria supere un umbral de dominancia mínima $t_{dom} = 0{,}4$ (equivalente a al menos 3/7 vecinos positivos). Este parámetro se establece como constante de diseño del algoritmo y cumple una función de respaldo: asegura que las semillas aceptadas bajo el criterio de entropía siempre presenten una presencia local de la clase minoritaria suficiente para respaldar una interpolación confiable, descartando los vecindarios donde la clase positiva en sí misma es minoría dentro de una región ruidosa. La elección de 0,4 como umbral implica tolerar que la clase mayoritaria tenga hasta cuatro de los siete vecinos, lo que cubre los casos de frontera con dominancia minoritaria (fila 4) pero rechaza los de dominancia mayoritaria estricta (filas 6 y 7).

De esta forma, la semilla candidata queda sometida a tres análisis geométricos complementarios: debe pertenecer a un vecindario suficientemente denso, presentar una presión acotada de vecinos contrarios y, simultáneamente, exhibir un nivel adecuado de pureza local.

El uso de percentiles y umbrales permite regular de manera escalonada y controlada la evaluación de los vecindarios obtenidos por el clasificador k-NN. En efecto, dicho clasificador identifica los vecinos más cercanos, pero no incorpora por sí mismo un criterio acerca de cuán apropiada resulta la distancia observada desde el punto de vista geométrico. Por ello, PC-SMOTE añade esta capa de análisis al examinar esos k vecinos mediante los filtros de densidad, riesgo y pureza, definiendo así si una semilla resulta apta para la generación de muestras sintéticas de la misma clase.

3.1.2.4. Variación en la cantidad de semillas válidas

La cantidad de semillas que superan los filtros de densidad, riesgo y pureza no se fija de antemano, sino que depende de la geometría local observada en cada clase. En

consecuencia, PC-SMOTE puede operar con diferentes niveles de cobertura de semillas candidatas según el dataset y la configuración experimental considerada.

Este comportamiento forma parte del mecanismo de selección del algoritmo: solo las instancias que satisfacen simultáneamente los criterios definidos ingresan a la etapa de interpolación. El análisis empírico de cómo varía esta cobertura entre conjuntos de datos se presenta en el capítulo de resultados y se retoma en la discusión final.

3.1.3. Fase 3 (Etapa de Generación adaptativa)

En esta fase, al momento de examinar cada una de las semillas que pasaron el filtro, se seleccionan aquellos vecinos de su misma clase de manera aleatoria, pero se usan solo aquellos que estén dentro del $PR_{\text{radio_densidad}}$, a fin de asegurar la generación de sintéticos dentro del vecindario seguro.

Además, a diferencia de *SMOTE* que trabaja con σ entre 0,1 y 0,9, *PC-SMOTE* genera un σ entre 0,4 y 0,6 para procurar generar el nuevo sintético en medio de ambas muestras. La idea central es que no esté accidentalmente pegado a ninguna de las dos muestras, es decir, ni demasiado próximo a la semilla que superó los filtros, ni demasiado próximo al vecino con el cual va a interpolar.

Finalmente, tras estas dos verificaciones se procede a realizar el cálculo de interpolación correspondiente.

3.2. Pipeline de sobremuestreo

La Figura 3.6 ilustra el *pipeline* de sobremuestreo, cuyo proceso comienza con la división de cada *dataset* en conjuntos de entrenamiento (*train*) y de prueba (*test*). A partir del conjunto de entrenamiento, se calculan la mediana y el rango intercuartílico, definido por el primer cuartil (Q_1, percentil 25) y el tercer cuartil (Q_3, percentil 75).

Posteriormente, tanto el conjunto de entrenamiento como el de prueba se escalan. La normalización se realiza utilizando la técnica *Robust Scaler* (ver Ecuación 3.1), que consiste en restar la mediana a cada muestra y dividir el resultado por la diferencia entre Q_3 y Q_1:

$$X_{scaled} = \frac{X - \text{mediana}}{Q_3 - Q_1} \tag{3.1}$$

El conjunto de datos de testeo se reserva inicialmente para la etapa de prueba del modelo de aprendizaje, tras lo cual el trabajo se centra exclusivamente en el conjunto de entrenamiento. El conjunto de datos de testeo se obtiene de este conjunto inicial y se utiliza para evaluar el rendimiento final del modelo.

El proceso de preparación del conjunto de entrenamiento comienza con la Limpieza de Datos, donde se aplica el algoritmo *Isolation Forest*. Este proceso se ajusta mediante umbrales de percentiles predefinidos (0 % para no aplicación, 1 % para limpieza leve, 3 % para limpieza media y 5 % para limpieza profunda) para controlar el nivel de depuración.

Una vez reducido el tamaño del conjunto de entrenamiento a causa de la limpieza, se procede al Sobremuestreo (*Oversampling*) Clásico, para lo cual se emplean técnicas conocidas como *SMOTE*, *Borderline SMOTE* y *ADASYN*. Finalmente, se aplica la técnica de sobremuestreo propuesta en este trabajo: *PC-SMOTE*.

Como resultado de estas etapas de preparación, se obtienen cinco versiones distintas del conjunto de entrenamiento (*train set*) para cada *dataset*: el conjunto original, y cuatro conjuntos sobremuestreados utilizando *SMOTE*, *Borderline SMOTE*, *ADASYN* y *PC-SMOTE*, respectivamente. Con la obtención de estos cinco conjuntos, concluye la fase

de preparación de datos, dando paso a la fase de entrenamiento y testeo del modelo de aprendizaje.

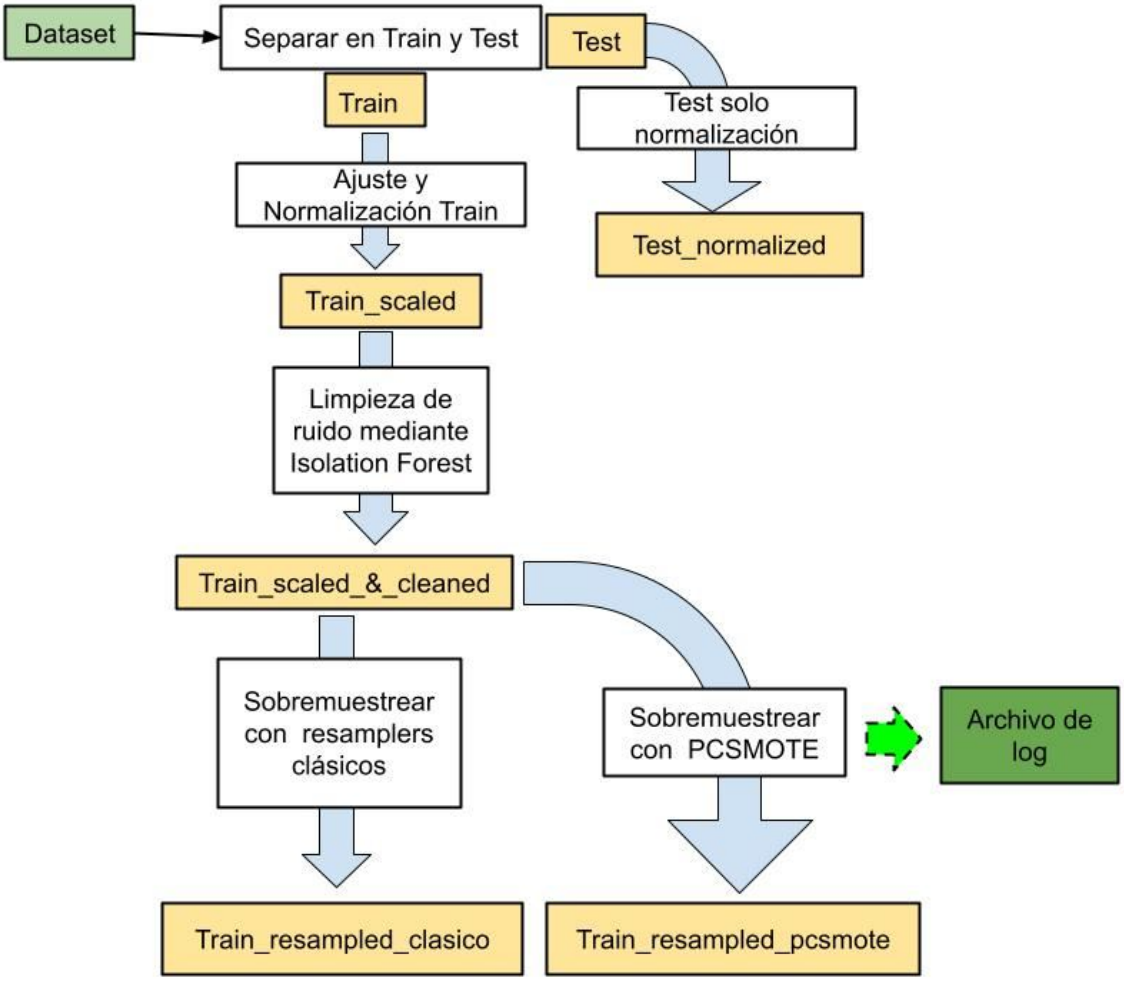

Figura 3.6: Pipeline de sobremuestreo

3.2.1. Descripción de los Conjuntos de Datos

Con el propósito de evaluar rigurosamente el comportamiento de la heurística geométrica propuesta, se seleccionaron cuatro conjuntos de datos reales. Estos presentan desafíos críticos de desbalance y solapamiento estructural, los cuales se pueden observar en la tabla 3.2.

En primer lugar, destaca el dataset Shuttle, el cual se caracteriza por un predominio masivo de las condiciones de vuelo normales frente a las anomalías. Esto genera una pérdida sustantiva de información relevante al operar sobre 9 características numéricas que describen las posiciones de los radiadores en un transbordador espacial de la NASA [31].

A esto se suma el conjunto de datos Telco Churn, que refleja un escenario comercial de telecomunicaciones donde el abandono del servicio crea nubes de dispersión altamente irregulares [12]. Asimismo, se incorpora el dataset Predict Faults, cuyo entorno de mante-

nimiento predictivo industrial simula fallas en maquinarias empleando parámetros físicos y térmicos casi idénticos a los de funcionamiento normal [13].

Finalmente, el conjunto US Crime aporta un nivel adicional de ruido espacial mediante 143 características demográficas y socioeconómicas originales, incluyendo niveles de ingresos y composición racial [32]. Esta colección integral permite validar cómo la técnica propuesta adapta sus radios percentiles a distintas configuraciones geométricas para mejorar el rendimiento predictivo.

Tabla 3.2: Características principales de los conjuntos de datos experimentales

Dataset	**Instancias**	**Atributos**	**Distribución**	**Tipo**
Shuttle [31]	58.000	9	Maj: 45.586 Min: 12.414	Multiclase (7)
Predict Faults [13]	10.000	Múltiples	Maj: 9.652 Min: 348	Binaria
Telco Churn [12]	7.043	Múltiples	Maj: 5.174 Min: 1.869	Binaria
US Crime [32]	1.994	143	Maj: 1.844 Min: 150	Binaria

3.3. Pipeline de entrenamiento y testeo

El pipeline de Entrenamiento y Testeo se estructura en dos etapas. La primera es la Configuración del Clasificador Base, en la cual se define un conjunto de hiperparámetros fijos para el modelo *Random Forest* que será utilizado de forma uniforme en todas las condiciones experimentales. La segunda es la Evaluación Comparativa de Estrategias de Sobremuestreo, en la que ese mismo clasificador configurado se entrena y evalúa de manera individual sobre cada versión del conjunto de entrenamiento. A diferencia de un flujo con ajuste automático, el esquema final de esta tesis no incorpora una búsqueda de hiperparámetros específica para cada conjunto aumentado.

3.3.1. Hiperparámetros fijos del clasificador

Un aspecto central del diseño experimental adoptado en este trabajo es que el modelo *Random Forest* se configura con un único conjunto de hiperparámetros fijos, aplicado de manera idéntica tanto al conjunto de entrenamiento base (desbalanceado) como a cada uno de los conjuntos sobremuestreados (*SMOTE*, *Borderline SMOTE*, *ADASYN* y *PC-SMOTE*). Esta decisión garantiza la igualdad de condiciones en la comparación y evita efectos confundidos: lo que varía entre condiciones es exclusivamente la estrategia de sobremuestreo aplicada al conjunto de entrenamiento, y no la configuración del clasificador.

Esta práctica es estándar en la literatura de aprendizaje con datos desbalanceados [8, 16], donde el modelo base se trata como una herramienta neutral cuya configuración permanece constante, con el objetivo de aislar y cuantificar el efecto puro de la técnica de remuestreo sobre el rendimiento final. Si cada condición experimental recibiera hiperparámetros optimizados individualmente sobre su propio conjunto de entrenamiento aumentado, el experimento mediría simultáneamente el beneficio del sobremuestreo y el del ajuste del clasificador, impidiendo atribuir con claridad cada diferencia de rendimiento a uno u otro factor.

Los hiperparámetros adoptados se detallan en la Tabla 3.3. Los valores seleccionados son consistentes con las recomendaciones empíricas de la literatura para *Random Forest* en problemas de clasificación binaria y multiclase [24], y fueron adicionalmente verificados de forma exploratoria sobre los conjuntos de datos utilizados en este trabajo, confirmando que constituyen una configuración razonable y estable.

Tabla 3.3: Hiperparámetros fijos del modelo Random Forest

Hiperparámetro	**Valor**
`n_estimators`	300
`max_features`	`sqrt`
`criterion`	`gini`
`bootstrap`	`True`
`random_state`	42

3.3.2. Entrenamiento y testeo comparativo

Con el clasificador configurado según los hiperparámetros fijos detallados en la Tabla 3.3, se entrena y evalúa un modelo *Random Forest* por cada versión del conjunto de entrenamiento disponible. Para cada dataset y grado de limpieza (I) se consideran:

- El conjunto de entrenamiento base (sin sobremuestreo), como línea de referencia o *baseline*.
- Los conjuntos sobremuestreados con *SMOTE*, *Borderline SMOTE* y *ADASYN*, como técnicas clásicas de comparación.
- Los conjuntos sobremuestreados con *PC-SMOTE* bajo distintas configuraciones de parámetros, como la propuesta de este trabajo.

En todos los casos, el modelo se entrena con las variables del conjunto de entrenamiento (X_{train}) y sus etiquetas asociadas (y_{train}). Una vez ajustado el clasificador, se realiza la predicción sobre el conjunto de testeo preservado (X_{test}), obteniéndose las clases predichas para instancias no vistas durante el entrenamiento. Estas predicciones se comparan luego con las etiquetas reales del conjunto de prueba (y_{test}), que no fue objeto de ninguna transformación derivada del sobremuestreo, preservando así la validez del proceso de evaluación.

Finalmente, se procede al Análisis Comparativo a partir de esa comparación entre valores predichos y valores reales, registrando para cada condición las métricas $F1_{\text{macro}}$, $F1_{\text{weighted}}$ (promedio ponderado por soporte de clase), *balanced accuracy*, *recall macro* y *accuracy*. Esto permite establecer un *ranking* centrado en la métrica de interés ($F1_{\text{macro}}$) y determinar el porcentaje de mejora (Δ) de cada estrategia respecto al *baseline*.

La Figura 3.7 resume visualmente este flujo de entrenamiento, comparación entre estrategias de sobremuestreo y evaluación final sobre un mismo conjunto de prueba preservado, manteniendo constante la configuración del clasificador base.

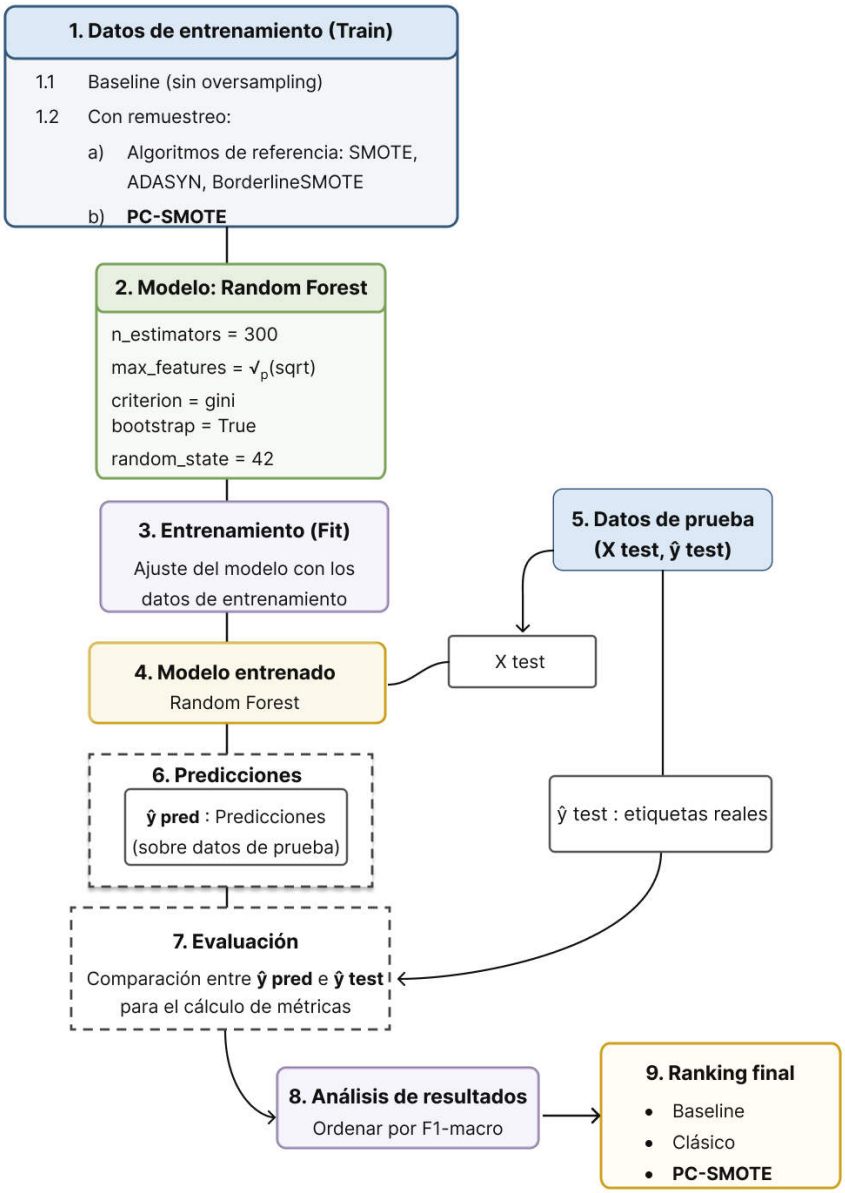

Figura 3.7: Pipeline de train y test del modelo de aprendizaje con hiperparámetros fijos

3.4. Métricas de Evaluación

Dado que la comparación entre estrategias de sobremuestreo depende directamente del criterio con que se mida el rendimiento, en esta sección se presentan las métricas adoptadas en la evaluación experimental. Primero se definen los conceptos fundamentales de Precisión y Exhaustividad, luego se detalla el F_1-score y, finalmente, la métrica F_1-macro average [2, p. 13]. Esta última se utiliza como indicador principal, ya que el desbalance de clases —propio de los datasets analizados— puede provocar en otras métricas una falsa sensación de eficiencia o exactitud.

3.4.1. Precisión y Exhaustividad

La Precisión (P), también conocida como valor predictivo positivo, mide la capacidad del modelo para no etiquetar como positiva una muestra que es negativa. Su definición formal se expresa en la Ecuación 3.2. Una precisión baja indica un alto número de falsos positivos (FP):

$$P = \frac{TP}{TP + FP} \tag{3.2}$$

Por otro lado, la Exhaustividad (R, por *Recall*) o sensibilidad, mide la capacidad del modelo para detectar todas las muestras positivas dentro del conjunto de datos. Su definición se presenta en la Ecuación 3.3. Es crítica en escenarios donde omitir un caso positivo (falso negativo) tiene un alto costo:

$$R = \frac{TP}{TP + FN} \tag{3.3}$$

Donde TP representa los verdaderos positivos, FP los falsos positivos y FN los falsos negativos. En el desarrollo de variantes de SMOTE controladas por percentiles, el objetivo central es mejorar el *Recall* de la clase minoritaria sin degradar drásticamente la precisión.

3.4.2. F1-score

El F_1-score es la media armónica entre la precisión y la exhaustividad. Se utiliza como una métrica única que busca un equilibrio entre ambas. Su formulación se presenta en la Ecuación 3.4. A diferencia de la media aritmética, la media armónica penaliza fuertemente los valores extremos, de modo que si cualquiera de las dos métricas (P o R) es baja, el F_1-score reflejará dicho rendimiento deficiente:

$$F1 = 2 \cdot \frac{P \cdot R}{P + R} \tag{3.4}$$

3.4.3. F1 macro-average

La métrica principal para evaluar los resultados de esta investigación es el F_1-*macro average*, cuya elección responde a la necesidad de evaluar el rendimiento del modelo de manera equitativa ante el desbalance de datos. A diferencia del promedio simple (*micro-average*), el enfoque *macro* calcula el valor F_1 de forma independiente para cada clase y luego obtiene el promedio aritmético, otorgando el mismo peso a la clase minoritaria que a la mayoritaria.

Para definir el F_1-macro, consideramos el F_1 para cada clase i, cuya formulación se presenta en la Ecuación 3.5:

$$F1_i = 2 \cdot \frac{P_i \cdot R_i}{P_i + R_i} \tag{3.5}$$

Finalmente, el F_1-macro se calcula promediando los valores obtenidos para las n clases del conjunto de datos, tal como se indica en la Ecuación 3.6:

$$F1_{\text{macro}} = \frac{1}{n} \sum_{i=1}^{n} F1_i \tag{3.6}$$

Este procedimiento garantiza que cualquier mejora en la clasificación de la clase minoritaria se vea reflejada directamente en la métrica global, evitando que el alto desempeño

en la clase predominante enmascare deficiencias del modelo en los casos de mayor interés para este estudio.

3.4.4. F1 weighted-average

Como medida complementaria, en el pipeline experimental también se registra la métrica $F1_{\text{weighted}}$, calculada con la opción `average="weighted"` en la implementación del notebook de entrenamiento y prueba. A diferencia del promedio macro, este promedio pondera el F_1 de cada clase según su soporte, es decir, según la cantidad de instancias reales de esa clase en el conjunto evaluado.

En consecuencia, el $F1_{\text{weighted}}$ tiende a reflejar con mayor intensidad el comportamiento sobre las clases más frecuentes. Por ello, en datasets severamente desbalanceados puede mantenerse alto aun cuando el rendimiento sobre la clase minoritaria no mejore de forma equivalente. En esta tesis se utiliza como métrica complementaria para acompañar la lectura del $F1_{\text{macro}}$, y en las tablas de resultados se abrevia como $F1_W$.

Su definición general puede expresarse según la Ecuación 3.7:

$$F1_{\text{weighted}} = \sum_{i=1}^{n} \frac{N_i}{N} F1_i \tag{3.7}$$

donde N_i representa la cantidad de instancias de la clase i y N el número total de instancias del conjunto evaluado.

4. RESULTADOS

En este capítulo se presentan los hallazgos empíricos derivados de la evaluación de *PC-SMOTE* sobre los conjuntos de datos seleccionados. El análisis comienza con el estudio de la configuración heurística basada en percentiles (Fase 1 del algoritmo) y luego detalla su impacto en el rendimiento del clasificador.

Los resultados indican que la combinación de estos hiperparámetros geométricos permitió ajustar el comportamiento del algoritmo a los conjuntos de datos analizados. Asimismo, el hecho de que *PC-SMOTE* no genere sintéticos o los genere a partir de pocas semillas candidatas aportó información adicional sobre la geometría de cada dataset, ya que en algunos casos los datos mostraron condiciones favorables para métodos basados en vecindad y, en otros, el grado de solapamiento hizo menos conveniente la interpolación local.

4.1. Análisis de la configuración geométrica basada en percentiles

Los resultados expuestos en la Tabla 4.1 muestran las mejores configuraciones encontradas de *PC-SMOTE* con cada dataset. Es dable destacar que estos valores fueron escalados, ya que de lo contrario la técnica se volvería imprecisa al trabajar con magnitudes de distancia diferentes.

Tabla 4.1: Auto-calibración de percentiles por dataset y parámetros

Datasets / Hiperparámetros	**Shuttle**	**Telco Churn**	**Predict Faults**	**US Crime**
PR_{dens} (Radio densidad)	70 (medio)	85 (alto)	85 (alto)	85 (alto)
Radio físico densidad	0,40 $\sim$ 981*	1,43	0,582	18,2
PR_{riesgo} (Radio riesgo)	30 (muy bajo)	40 (bajo)	50 (medio)	40 (bajo)
Radio físico riesgo	0,2 $\sim$ 503*	1	0,319	6,8
$PR_{\text{entropía}}$	–	70	–	80
Valor entropía	–	0,59	–	0,86
Criterio pureza	proporción	entropía	proporción	entropía
Densidad (umbral densidad)	25	60	45	45
Riesgo (umbral riesgo)	30	45	55	45
Pureza (umbral prop.)	40	–	45	–
Grado de Isolation Forest	1	0	0	0

Nota. * Rango por clase.

En todos los experimentos se mantuvo fijo $k = 7$ como tamaño base del vecindario, tal como se justificó en el Capítulo 3, Sección 3.1.2.1, mientras que la exploración se concentró en los percentiles de radio para densidad y riesgo, en el criterio de pureza y en los umbrales geométricos asociados.

La tabla muestra cómo *PC-SMOTE* pudo adaptar los hiperparámetros de radio-densidad, radio-riesgo y entropía a la geometría del dataset gracias al uso de los percentiles. Esto se puede observar entre los conjuntos de datos *Predict Faults* y *US Crime*, donde se nota cómo la definición de cercanía varía entre un conjunto de datos y otro y, en *Predict Faults*, por ejemplo, las muestras están tan juntas que incluso un percentil alto sigue tomando un valor de radio físico pequeño, lo que indica una alta concentración de los datos.

Por el contrario, en *US Crime* y *Shuttle* se observó un valor de radio físico más grande, es decir, se expandió drásticamente para encontrar vecinos en un espacio disperso de alta

dimensión. Al cambiar la noción de "cerca" en estos conjuntos, se observó una mejora en el desempeño del clasificador y un mejor aporte por parte de *PC-SMOTE*.

4.2. Análisis de Radios

Se incluye este apartado sobre el análisis de radios porque *PC-SMOTE* utiliza esta información en la primera fase de definición de los valores de radio-densidad y riesgo. Las Figuras 4.1, 4.2, 4.3, 4.4 y 4.5 muestran la distribución acumulada de las distancias euclídeas entre las instancias minoritarias y sus k vecinos más cercanos en los datasets analizados.

El gráfico muestra que, dentro del mismo dataset (ver Figura 4.1 y Figura 4.2 - *Shuttle*), la Clase 1 requiere un radio de apenas 0,33 para alcanzar el percentil 70, mientras que la Clase 6 necesita un radio de 981,5 para el mismo percentil. Esto sugiere que un radio fijo habría sido insuficiente para capturar ambas estructuras simultáneamente, mientras que el uso de percentiles permitió ajustar la escala espacial para cada clase.

En el caso de *Telco Churn* (Figura 4.3), la curva de radio destaca por su forma creciente con aumentos repentinos. Este fenómeno indica que la clase minoritaria no presenta una densidad binaria (denso/disperso), sino una estratificación estructural en cuatro bloques de densidad decreciente: el primer segmento (rango percentil 0–20 %), caracterizado por radios mínimos (radio $< 0{,}5$), corresponde a los centroides de los *clusters* donde la redundancia de información es máxima, el segundo bloque (rango percentil 20–55 %) evidencia un incremento escalonado del radio, indicando la presencia de sub-grupos o *small disjuncts* que requieren una mayor tolerancia espacial para ser conectados, el tercer tramo (rango percentil 55–85 %) representa la periferia de las estructuras, donde la densidad disminuye pero mantiene la conectividad suficiente para validar la interpolación (entre 3/7 a 4/7 vecinos dentro del umbral) y, finalmente, el último segmento exhibe un crecimiento vertical asintótico, correspondiente a *outliers* globales y ruido desconectado de cualquier estructura latente.

Este análisis sugiere que la elección del Percentil de Densidad al 85 % respondió a un patrón geométrico observable en los datos. Este corte permitió al algoritmo contener los tres primeros bloques estructurales y excluir el cuarto bloque de dispersión, favoreciendo la generación sin incorporar sintéticos en regiones más inestables. Las Figuras 4.4 y 4.5 complementan esta lectura al mostrar, respectivamente, un escenario donde todavía existen radios aprovechables para interpolar y otro donde la estructura local resulta mucho más ambigua.

La correlación entre el patrón gráfico observado y los datos operativos se confirma mediante la auditoría de los *logs* generados por *PC-SMOTE*. Específicamente, se constata que el cuarto bloque (Nube de Dispersión) corresponde materialmente a las semillas que presentaron una densidad vecinal crítica, registrando densidades del orden de 0/7, 1/7 y 2/7 vecinos válidos, lo que valida la decisión del algoritmo de clasificar estas instancias como ruido u *outliers* y excluirlas del proceso de generación para preservar la integridad de la frontera de decisión.

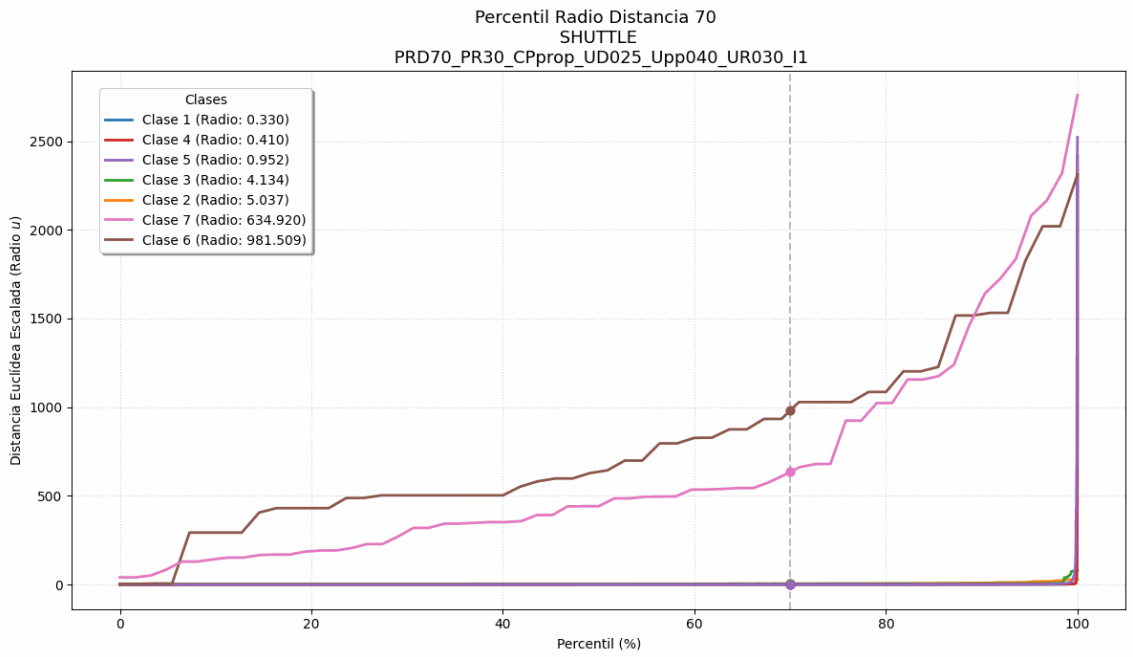

Figura 4.1: Visualización de radios por clase del dataset Shuttle.

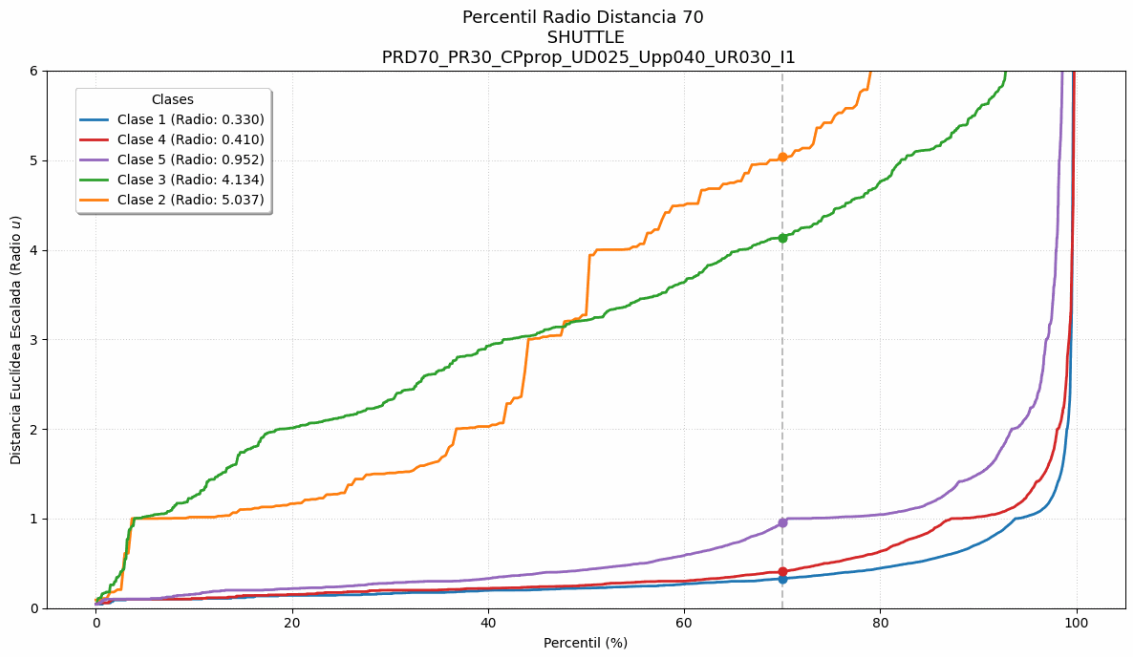

Figura 4.2: Visualización de radios con foco en las clases 1 a 5 del dataset Shuttle.

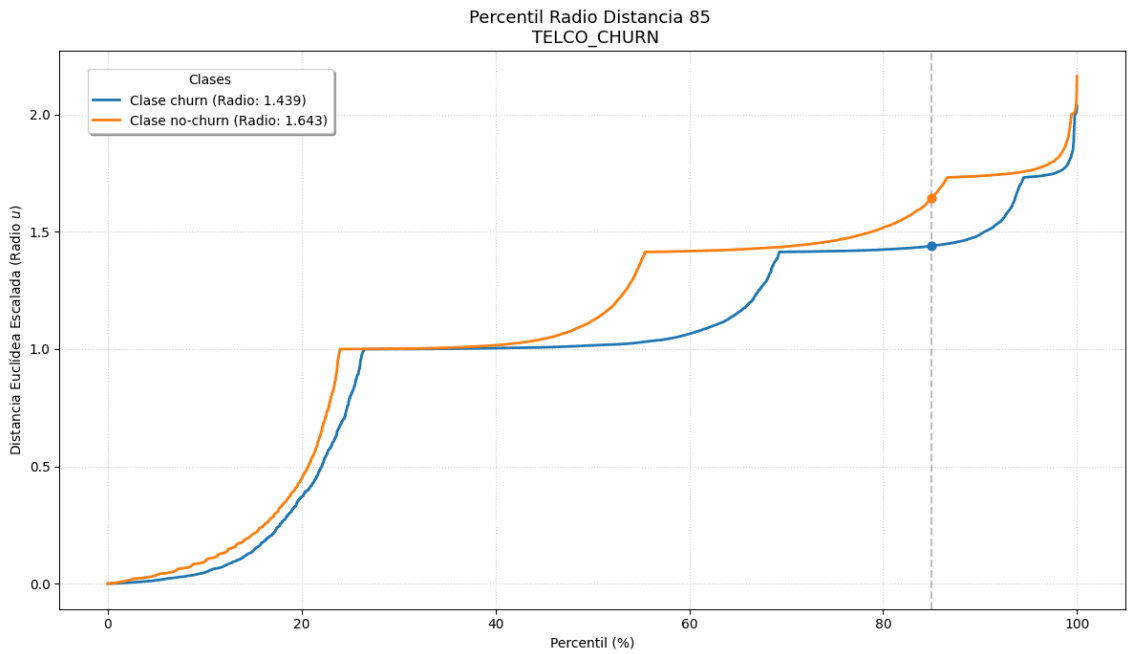

Figura 4.3: Visualización de radios por clase del dataset Telco Churn.

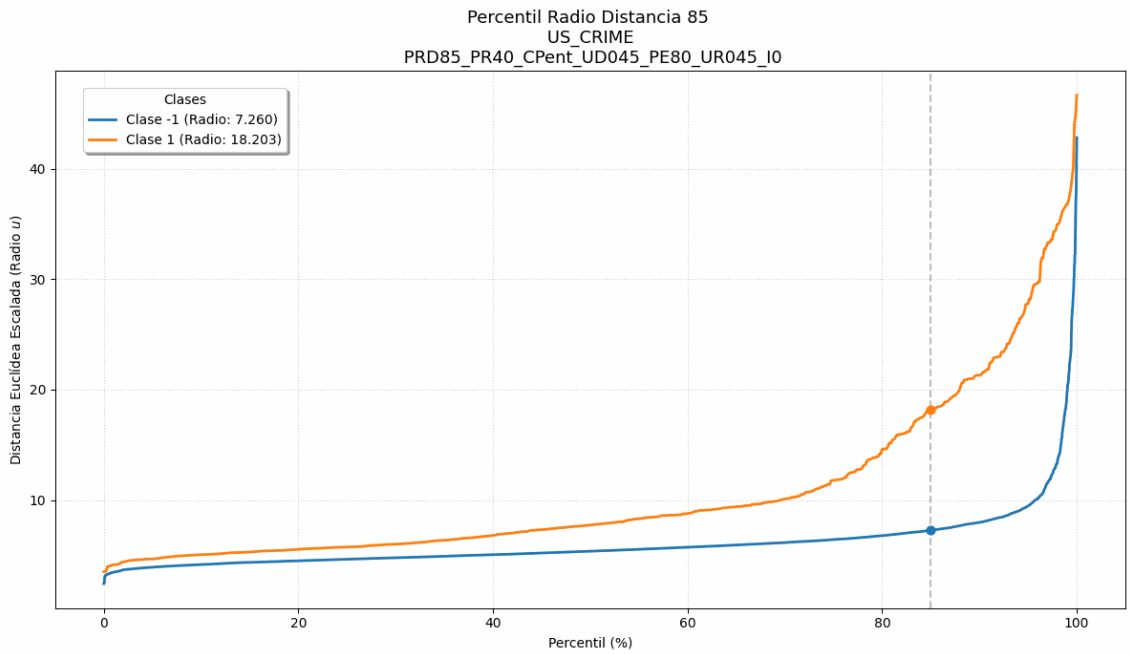

Figura 4.4: Visualización de radios por clase del dataset US Crime.

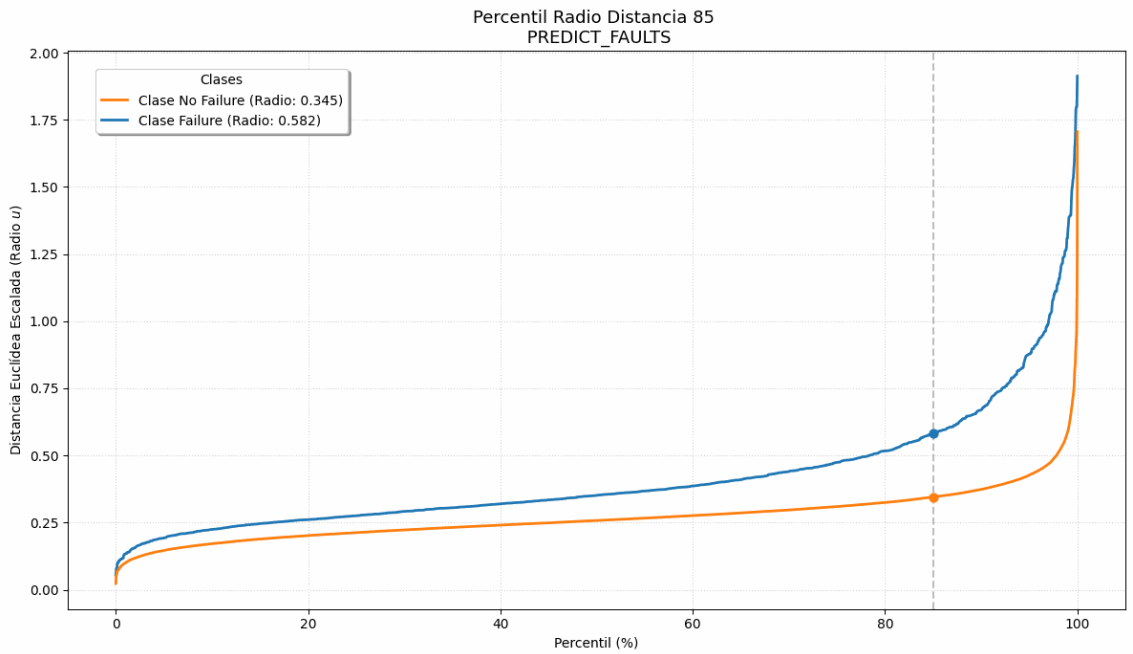

Figura 4.5: Visualización de radios por clase del dataset Predict Faults.

4.2.1. Lectura aplicada del análisis geométrico en Telco Churn

La estratificación observada en este conjunto de datos, particularmente el descarte del último bloque asintótico (nube de dispersión) evaluado mediante la entropía de Shannon, puede interpretarse como una decisión asociada a regiones de alta dispersión y mayor mezcla de clases. Desde una lectura aplicada, los vecindarios donde PC-SMOTE permitió generar datos corresponden a sectores con mayor cohesión local, mientras que la nube de dispersión reúne casos menos estables para la interpolación.

En consecuencia, la restricción de la generación en esas zonas puede entenderse como una medida para evitar la incorporación de sintéticos sobre regiones poco informativas para el modelo.

4.3. Dinámica de filtrado en PC-SMOTE

El análisis transversal de los experimentos muestra cómo *PC-SMOTE* no operó con una tasa de generación uniforme, sino que actuó como un filtro selectivo dependiente de la morfología de los datos, es decir, de la forma y del grado de dispersión que adopta la distribución local de las instancias. La Figura 4.6 muestra un escenario con alta aceptación de semillas, mientras que la Figura 4.9 muestra el caso opuesto, donde el algoritmo optó por no usar la mayoría de las semillas. De forma complementaria, las Figuras 4.7 y 4.8 muestran comportamientos intermedios, con aceptación dependiente de la geometría local de cada conjunto.

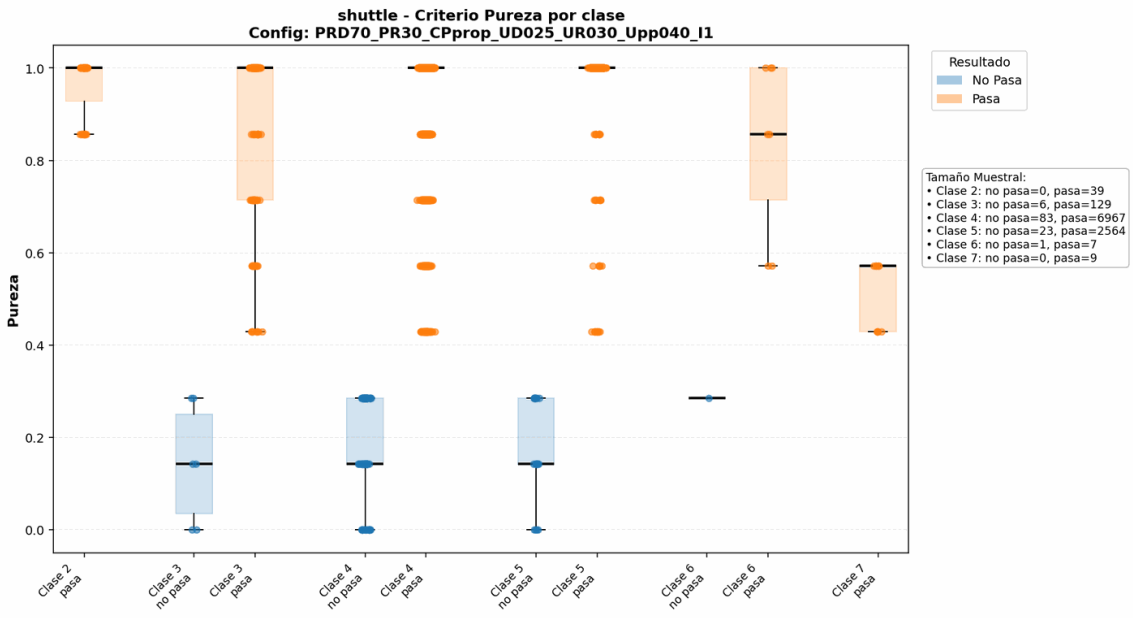

Figura 4.6: Visualización de purezas por clase del dataset Shuttle.

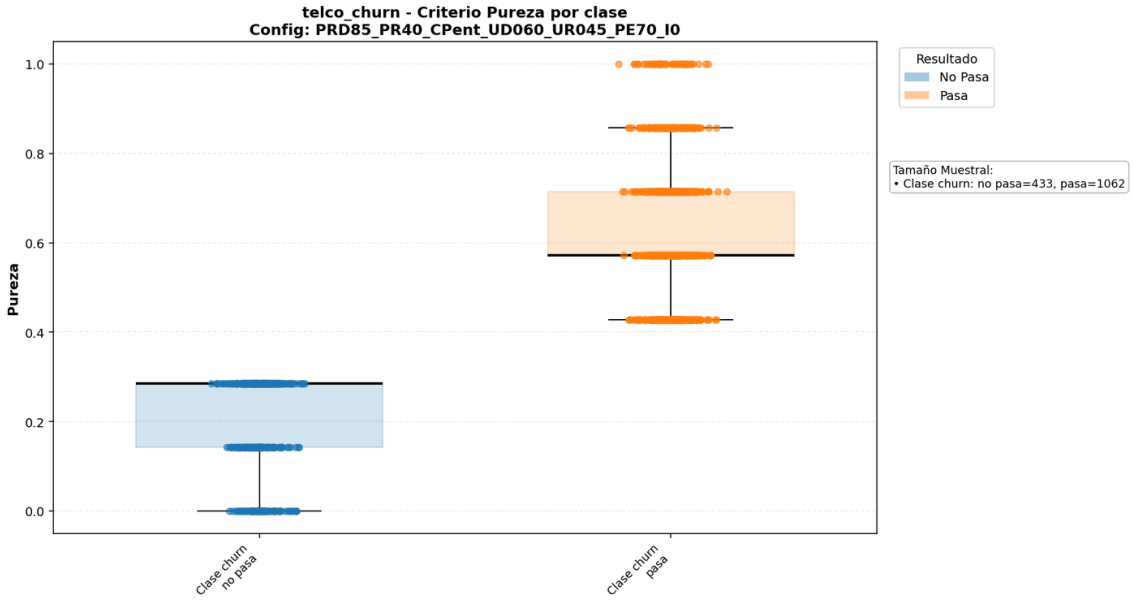

Figura 4.7: Visualización de purezas por clase del dataset Telco Churn.

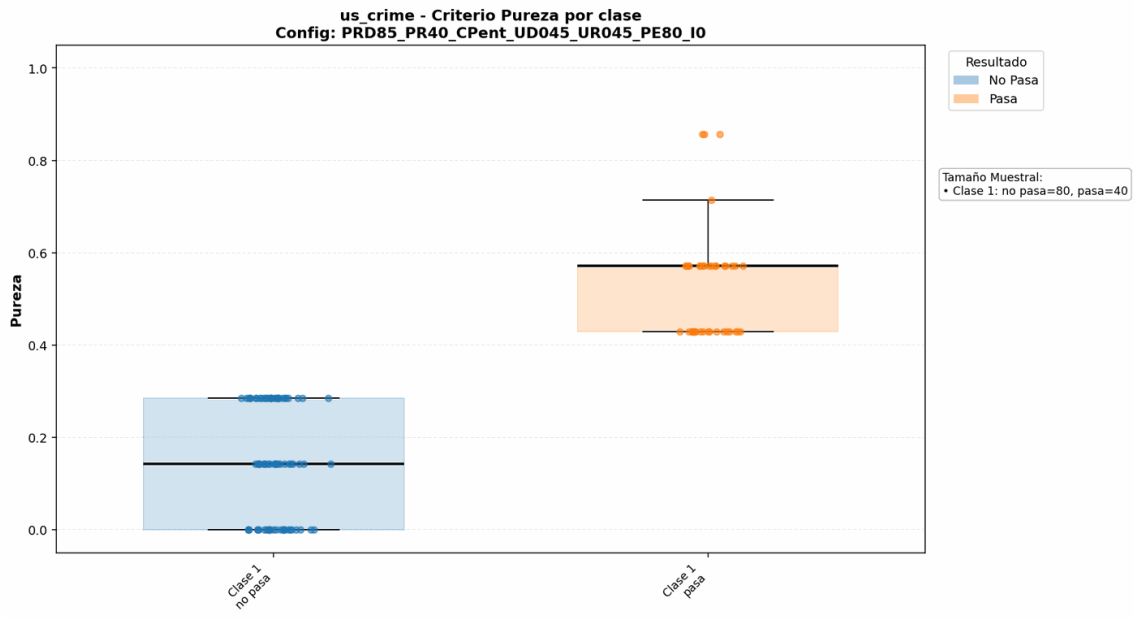

Figura 4.8: Visualización de purezas por clase del dataset US Crime.

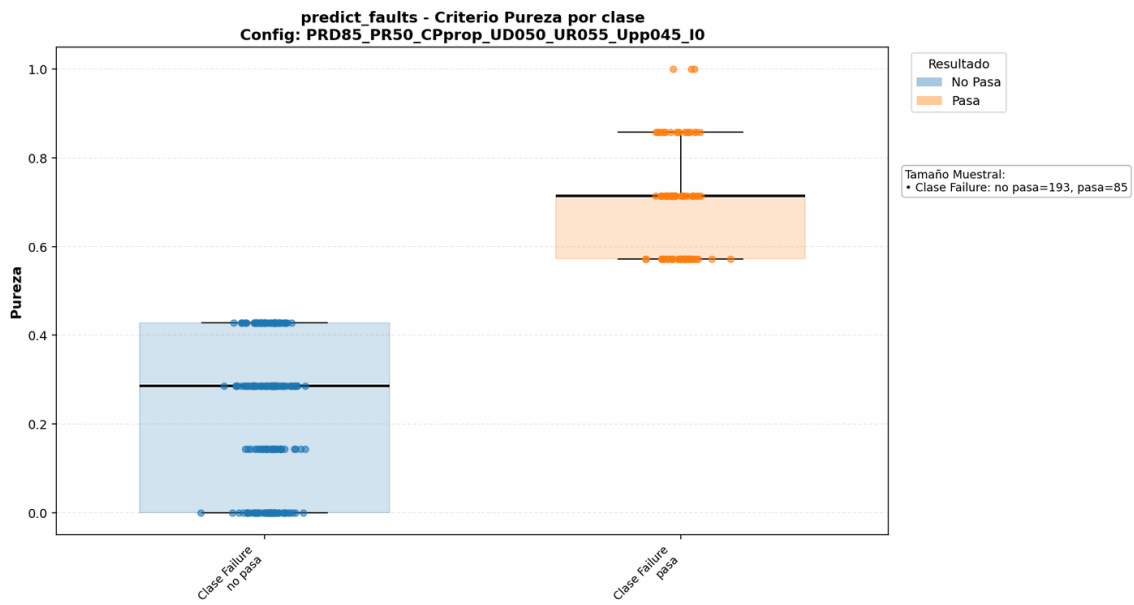

Figura 4.9: Visualización de purezas por clase del dataset Predict Faults.

Esto confirmó que la técnica, logró identificar escenarios con buena separabilidad local, permitiendo la interpolación intensiva sin comprometer la frontera.

En los gráficos radar, la arista "Reparto de Semillas" nos dice si la generación de semillas está concentrada en muchas o pocas muestras, de modo que cuanto más se acerca a 1 más repartido está y, al contrario, cuanto más se acerca a cero, la generación se concentra en pocas candidatas.

A pesar de la alta cobertura de clases observada en algunos casos (como en el caso Shuttle, Figura 4.10), se concluye que esto no es suficiente. Es indispensable que la generación de semillas sintéticas se distribuya en una mayor cantidad de semillas para prevenir

el sobreajuste (overfitting). Esta misma lógica puede observarse en el caso intermedio de *Telco Churn* (Figura 4.11), donde la cobertura lograda por *PC-SMOTE* es razonable, pero el beneficio final depende de cuán repartida quede la generación entre semillas validadas.

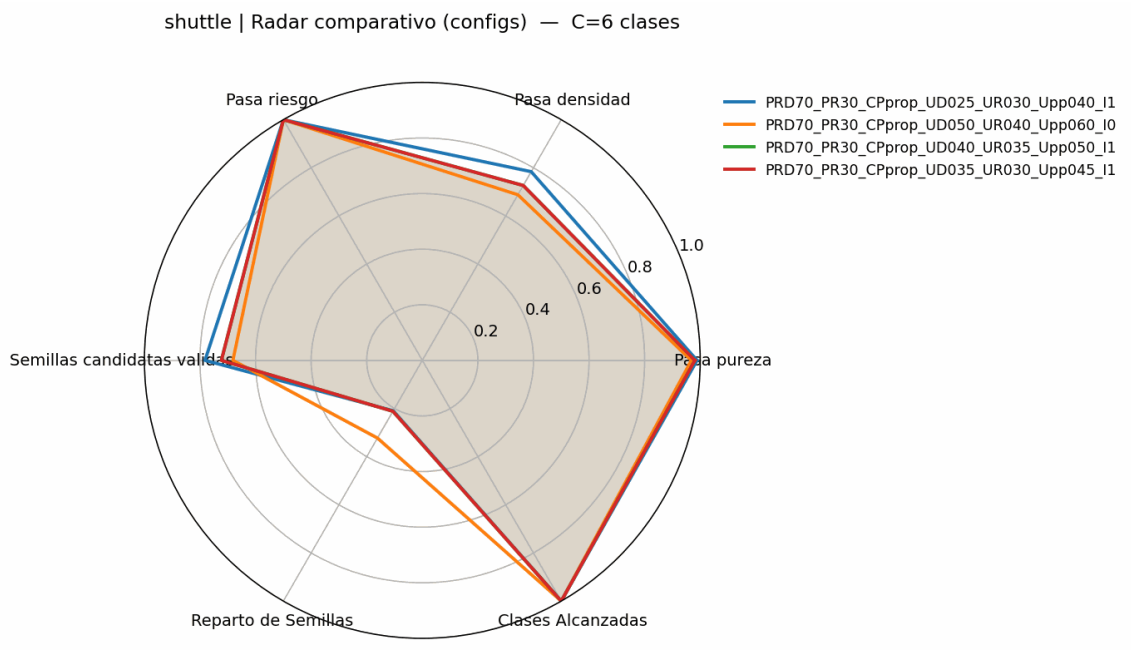

Figura 4.10: Radar comparativo (configs) del dataset Shuttle.

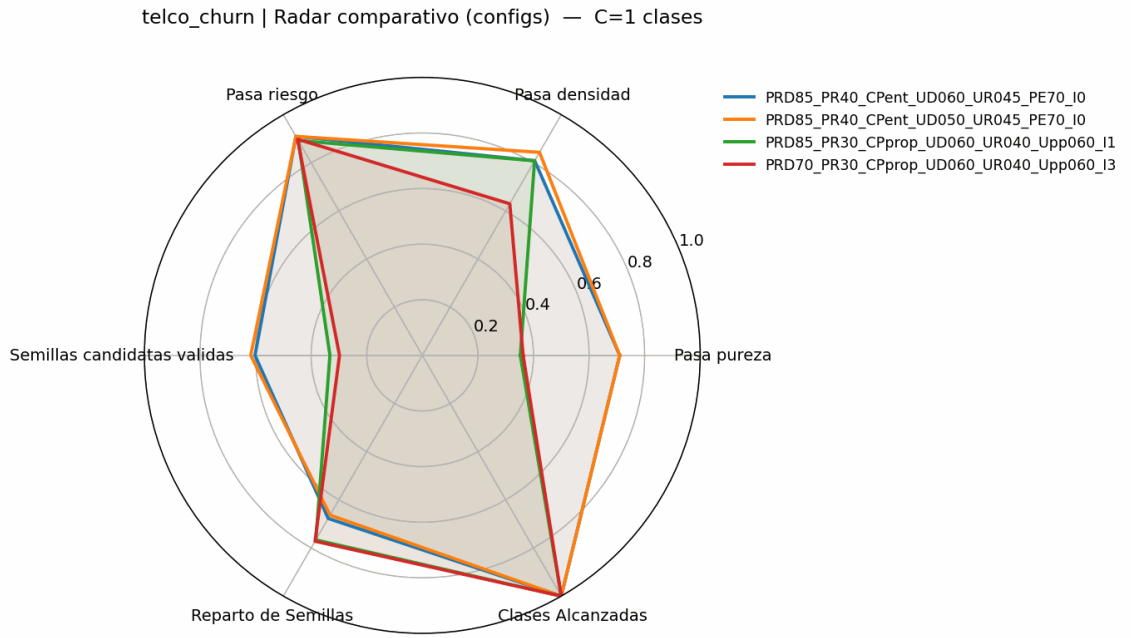

Figura 4.11: Radar comparativo (configs) del dataset Telco Churn.

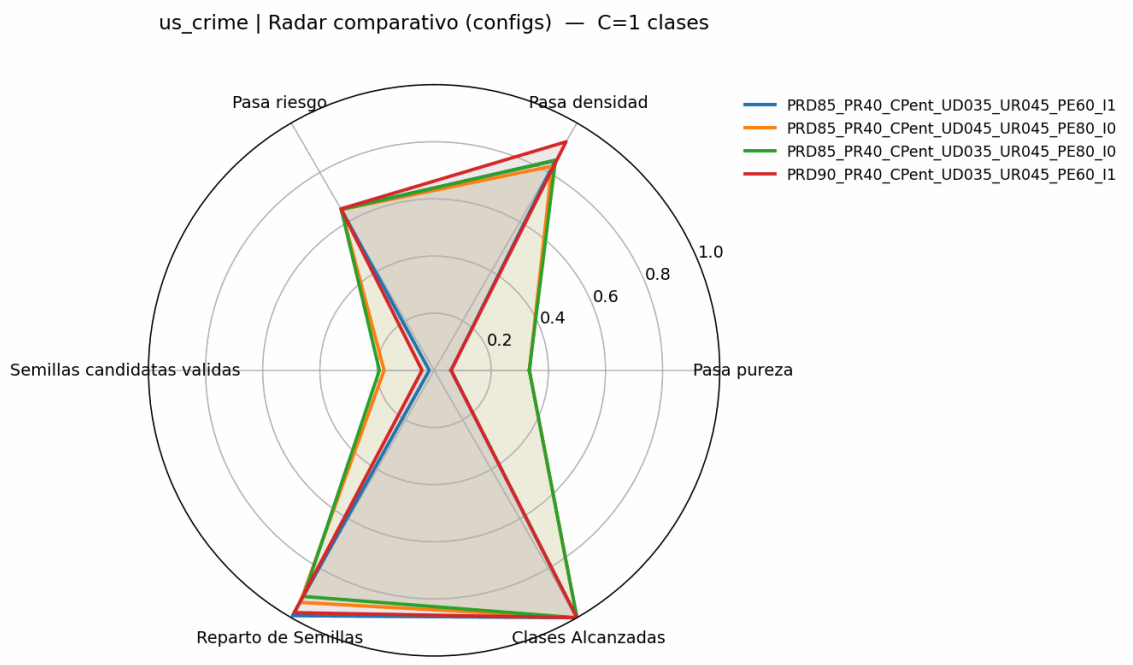

Figura 4.12: Radar comparativo (configs) del dataset US Crime.

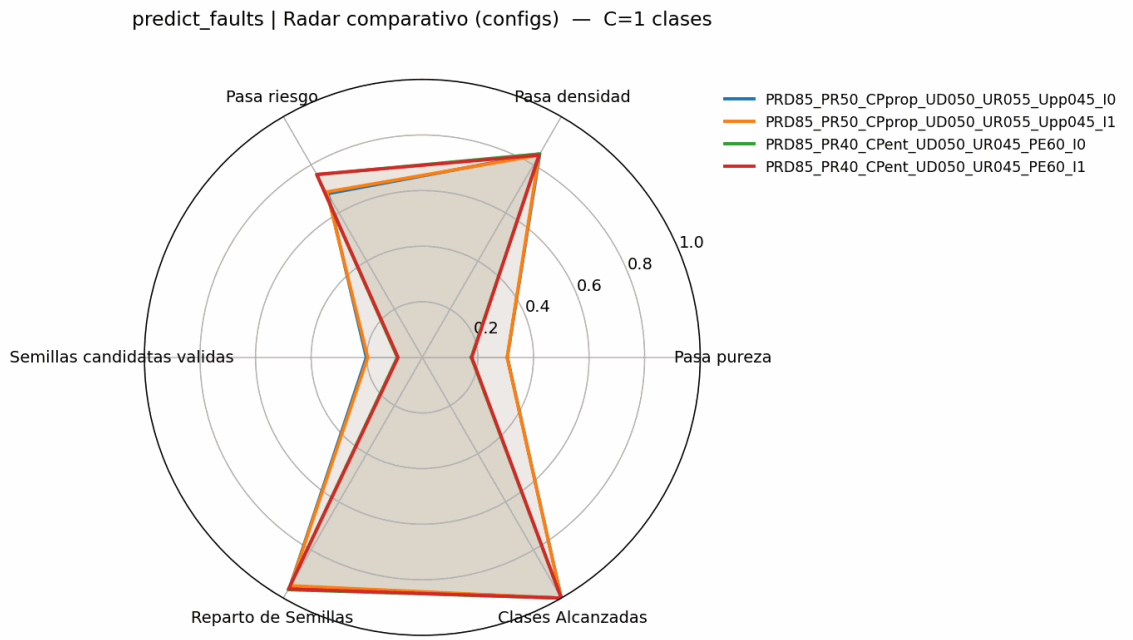

Figura 4.13: Radar comparativo (configs) del dataset Predict Faults.

Es interesante ver cómo las figuras 4.12 y 4.13 de radar en US Crime y Predict Faults son muy similares. Sin embargo, PC-SMOTE se comportó de manera diferente en ambos casos. En el primer caso, con US Crime, la mejor configuración de PC-SMOTE (E1, sin limpieza previa por IF) logró una mejora acotada pero consistente respecto del caso base, mientras que variantes más restrictivas, como E2 con 1 % de limpieza, ya no sostuvieron esa ganancia frente al *baseline* original. En el segundo caso, *Predict Faults*, a pesar de identificar una estructura global similar, la intervención de la técnica generó un desempeño

inferior al caso base, lo que confirma que la geometría efectiva del vecindario resulta más decisiva que la forma global del radar (ver Tablas 4.13 y 4.4).

Asimismo, se observó una relación inversa entre la cantidad de semillas sintéticas válidas y la carga de generación por semilla: cuando muchas semillas superaron los filtros, los sintéticos tendieron a repartirse entre un conjunto más amplio de instancias; cuando pocas semillas resultaron aceptadas, la generación quedó concentrada en un número reducido de puntos.

Este patrón también se evidenció en el caso del dataset US Crime, donde PC-SMOTE logró cubrir todas las clases y distribuir la generación sobre una fracción relevante de las semillas validadas, aunque el beneficio final quedó concentrado en la configuración sin limpieza previa por IF. A partir de umbrales de limpieza más agresivos, el conjunto perdió semillas útiles y la ganancia frente al caso base original se debilitó.

Lectura aplicada del análisis geométrico (Predict Faults): El comportamiento de PC-SMOTE en el dataset *Predict Faults* (fallas industriales), donde el algoritmo rechazó la mayor parte de las semillas candidatas, sugiere una geometría local altamente mezclada. En este dataset, las maquinarias cercanas a una falla presentan parámetros físicos y térmicos muy similares a los de máquinas en funcionamiento normal.

En estas condiciones, una estrategia de sobremuestreo indiscriminada podría introducir instancias sintéticas en regiones ambiguas y dificultar la discriminación entre clases. Por ello, el hecho de que la técnica reduzca la generación no debe interpretarse necesariamente como una deficiencia, sino como un resultado coherente con la geometría observada.

4.4. Análisis de resultados de la implementación de PC-SMOTE

Para presentar los resultados de forma ordenada, en cada conjunto de datos se incluyen tres tablas complementarias: la primera resume las configuraciones de *PC-SMOTE* consideradas en el análisis, la segunda muestra el rendimiento del caso base sobre la misma partición de entrenamiento y prueba, incluyendo los tamaños de ambos subconjuntos y las métricas obtenidas, y la tercera presenta la comparación final entre el caso base, las técnicas clásicas de sobremuestreo y las variantes de *PC-SMOTE*, lo que permite observar el efecto de cada estrategia sobre el clasificador.

La tabla comparativa se interpreta del siguiente modo: la columna "Umbral IF" indica el nivel de limpieza previo aplicado con *Isolation Forest*, de modo que, cuando el valor es 0 %, no se realizó limpieza, y entre paréntesis se informa la cantidad de semillas candidatas detectadas en el conjunto de entrenamiento; la columna "Técnica" identifica el método evaluado y, en el caso de *PC-SMOTE*, "Sem. Val." o "Semillas Validadas" indica cuántas semillas superaron los filtros del algoritmo, mientras que "Sintet." informa la cantidad de muestras sintéticas generadas. Cabe aclarar que, en algunos casos, *PC-SMOTE* no produce la misma cantidad de sintéticos que *SMOTE*, ya que si ninguna muestra de una clase supera los filtros no se generan nuevas instancias para esa clase, aunque, si al menos una semilla resulta válida, la generación se realiza igualando el número de muestras de la clase mayoritaria. Por su parte, la columna "Train Final (Orig + Sintet.)" indica el tamaño total del conjunto de entrenamiento luego del sobremuestreo, mientras que las columnas $F1_M$, $F1_W$ y Acc muestran el rendimiento en el conjunto de prueba; en este trabajo, $F1_M$ corresponde a *F1 macro-average*, $F1_W$ a *F1 weighted-average* y Acc a la exactitud final del clasificador.

Este desempeño depende en gran medida de la calidad informativa de los datos de entrenamiento. Si una técnica de sobremuestreo genera muestras sintéticas idénticas, resultaría en información redundante (sobreajuste), lo cual obstaculiza el trabajo del clasificador.

De lo anteriormente dicho, puede observarse que, en aquellos casos donde *PC-SMOTE* pudo cubrir la generación de sintéticos en todas las clases, el clasificador tendió a responder mejor, como en el caso de *Shuttle* (Figura 4.10). En escenarios más hostiles, como *US Crime* (Figura 4.12), el aporte existió, pero quedó concentrado en configuraciones puntuales y se redujo al endurecer la limpieza previa.

Al analizar los resultados del dataset *Predict Faults* (Tablas 4.2, 4.3 y 4.4; Figura 4.13), se observa que la técnica restringió fuertemente la interpolación. Este comportamiento coincide con el análisis previo del conjunto, que mostró una geometría local especialmente ambigua para la generación de sintéticos.

Si bien las técnicas clásicas pueden generar una mayor cantidad de muestras y eventualmente mejorar ciertas métricas, ese aumento no siempre implica una representación más fiel de la estructura local. En este caso, la restricción de PC-SMOTE sugiere que la vecindad disponible no ofrecía condiciones favorables para una interpolación confiable.

Por lo tanto, que PC-SMOTE no supere el F1-macro del caso base en este dataset no invalida la propuesta, sino que muestra que la heurística puede actuar de forma conservadora cuando la geometría local no respalda la generación de sintéticos. Desde esta lectura, la limitación en la generación de muestras forma parte del comportamiento esperado del algoritmo ante entornos especialmente ambiguos.

Tabla 4.2: Configuración de hiperparámetros por técnica y Umbral de limpieza (Predict Faults)

Exp.	Umbral IF*	Técnica	PR_dist	PR_ries	Criterio	U_den	U_ries	Tipo_P
E1	Umbral 0: no se filtró por IF (candidatas: 278)	**PC-SMOTE**	**85**	**40**	**entropía**	**050**	**045**	**PE60**
E2		PC-SMOTE	85	50	proporción	050	055	Upp045
E3	P 1 % (275)	**PC-SMOTE**	**85**	**40**	**entropía**	**050**	**045**	**PE60**
E4		PC-SMOTE	85	50	proporción	050	055	Upp045
E5	P 3 % (269)	**PC-SMOTE**	**85**	**50**	**proporción**	**050**	**055**	**Upp045**

* El valor entre paréntesis indica las semillas sintéticas candidatas.

Tabla 4.3: Rendimiento del Caso Base en conjunto de prueba (Predict Faults)

Configuración	Tamaño Train (80 %)	Tamaño Test (20 %)	F1_M	F1_W	Acc
Caso Base (Original)	8000	2000	0,865	0,983	0,985

Nota. El conjunto de entrenamiento (80 %) presenta un fuerte desbalance de clases: 7722 instancias pertenecen a la clase mayoritaria (-1) y solo 278 a la clase minoritaria (1).

Tabla 4.4: Rendimiento final en conjunto de prueba: Caso Base vs. Sobremuestreo (Predict Faults)

Exp.	Umbral IF	Técnica	Semillas Validadas*	Sintet.	Train Final (Orig + Sintet.)	F1_M	Δ (F1_M)	F1_W	Acc
–	**Caso Base**	–	–	–	8000	0,859	–	0,982	0,984
E1	Umbral 0: no se filtro por IF (candidatas: 278)	**PC-SMOTE**	**25**	**7444**	**15444**	**0.828**	**-0.031**	**0.978**	**0.980**
E2		PC-SMOTE	56	7444	15444	0,820	−0,040	0,977	0,979
–		borderline	–	7444	15444	0,817	−0,042	0,975	0,976
–		adasyn	–	7453	15453	0,808	−0,051	0,973	0,973
–		smote	–	7444	15444	0,808	−0,051	0,974	0,973
E3	P 1 % (candidatas: 275)	**PC-SMOTE**	**24**	**7369**	**15288**	**0.836**	**-0.023**	**0.979**	**0.981**
E4		PC-SMOTE	54	7369	15288	0,820	−0,040	0,977	0,979
–		borderline	–	7369	15288	0,827	−0,032	0,977	0,977
–		smote	–	7369	15288	0,836	−0,024	0,977	0,976
–		adasyn	–	7380	15299	0,815	−0,044	0,974	0,973
E5	P 3 % (candidatas: 269)	**PC-SMOTE**	**53**	**7221**	**14980**	**0.841**	**-0.018**	**0.980**	**0.981**

* Semillas candidatas validadas en el conjunto de entrenamiento (*train*). Δ ($F1_M$) representa la diferencia absoluta respecto al Caso Base. *Nota:* Las filas en negrita resaltan los experimentos con mejor desempeño relativo.

Los valores de las Tablas 4.2, 4.3 y 4.4 confirman que, aun en su mejor variante (E5), PC-SMOTE alcanzó un $F1_M$ de 0,841, por debajo del caso base (0,859). Esto refuerza la lectura geométrica previa: en *Predict Faults*, la principal utilidad de la heurística no estuvo en maximizar la métrica final, sino en evitar una interpolación agresiva sobre vecindarios localmente ambiguos.

Las Tablas 4.5, 4.6 y 4.7 reúnen, para *Shuttle*, las configuraciones seleccionadas, el comportamiento del caso base y la comparación final con las técnicas clásicas de sobremuestreo.

Tabla 4.5: Configuración de hiperparámetros para experimentos seleccionados (Shuttle)

Exp.	Umbral IF*	Técnica	PR_dist	PR_ries	Criterio	U_den	U_ries	Tipo_P
E1	1 (9828)	*PC-SMOTE*	70	30	proporción	025	030	Upp040
E2	0 (9931)	*PC-SMOTE*	70	30	proporción	050	040	Upp060

* Valor entre paréntesis indica semillas sintéticas candidatas detectadas.

Tabla 4.6: Rendimiento del Caso Base en conjunto de prueba (Shuttle)

Configuración	Tamaño Train	Tamaño Test	F1_M	F1_W	Acc
Caso Base (Original)	46400	11600	0,963	1,000	1,000

Nota. El conjunto de entrenamiento (80 %) se compone de 36469 instancias de la Clase 1 (mayoritaria), y las clases minoritarias: Clase 4 (7122), Clase 5 (2614), Clase 3 (137), Clase 2 (40), Clase 7 (10) y Clase 6 (8).

Este mecanismo también se pudo observar en el conjunto de datos Shuttle (Tabla 4.7), más precisamente en la generación de sintéticos por parte del algoritmo, donde solo se crearon 135.963 muestras, a diferencia de los 208.883 generados por el SMOTE clásico. Esta reducción numérica es una característica del funcionamiento de PC-SMOTE y se manifestó de forma más marcada en ambas aplicaciones en conjunto con Isolation Forest.

Específicamente, con Isolation Forest Umbral Percentil 0, PC-SMOTE no pudo identificar semillas candidatas para las clases minoritarias 6 y 7, lo que lo llevó a centrarse en nivelar las clases 2 a 5 contra la mayoritaria (clase 1). No obstante, la aplicación de una limpieza previa de *outliers* con un umbral del 1 % resultó en una mejora del rendimiento.

Esta mejora se atribuye a dos factores clave: la variación en el umbral del radio de densidad y riesgo, y la relajación del umbral de densidad al 0.25 (2/7) en la cantidad de vecinos cercanos. Esto permitió que las clases 6 y 7 fueran consideradas suficientemente densas al encontrar vecinos, logrando su inclusión en el conjunto y, consecuentemente, un aumento en la performance general.

En una lectura más amplia, los resultados obtenidos permiten ubicar a PC-SMOTE dentro de la evolución reciente de técnicas de sobremuestreo sensibles a la geometría local. Mientras antecedentes como G-SMOTE introducen la flexibilización de la región de generación sintética y propuestas más recientes como LD-SMOTE y VS-SMOTE refuerzan la relevancia de la densidad local y del control del ruido, los resultados obtenidos en este trabajo sugieren que dicha adaptabilidad también resulta pertinente en una etapa previa de selección de semillas candidatas. En este sentido, PC-SMOTE no se plantea como una reformulación directa de esos métodos, sino como una heurística que, a partir de percentiles, densidad, riesgo y pureza, busca incorporar esa misma sensibilidad geométrica tanto en la elección de las instancias a interpolar como en la generación posterior de ejemplos sintéticos.

Tabla 4.7: Rendimiento final en conjunto de prueba ordenado por F1 Macro (Shuttle)

Ranking	Umbral IF	Técnica	Sem. Val.*	Sintet.	Train Final (Orig + Sintet.)	F1_M	Δ (F1_M)	F1_W	Acc
–	–	**Caso Base**	–	–	46400	0,855	–	1,000	1,000
1	Umbral 0: no se filtró por IF (candidatas: 9931)	*adasyn*	–	208961	255361	0,952	+0,097	1,000	1,000
2		*borderline*	–	172454	218854	0,952	+0,097	1,000	1,000
3		*smote*	–	208883	255283	0,950	+0,095	1,000	1,000
4		**PC-SMOTE (E2)**	**6756**	**135963**	**182363**	**0.857**	**+0.002**	**1.000**	**1.000**
1	P 1 % (candidatas: 9828)	*adasyn*	–	206831	252763	0,991	+0,136	1,000	1,000
2		*borderline*	–	170731	216663	0,991	+0,136	1,000	1,000
3		*smote*	–	206796	252728	0,950	+0,095	1,000	1,000
4		**PC-SMOTE (E1)**	**7685**	**206796**	**252728**	**0.950**	**+0.095**	**1.000**	**1.000**

* Semillas candidatas validadas en el conjunto de entrenamiento (*train*). Δ (F1_M) representa la mejora absoluta respecto al Caso Base. *Nota:* Las técnicas están ordenadas por F1_M dentro de cada bloque.

Las Tablas 4.8, 4.9 y 4.10 sintetizan, para *Telco Churn*, la relación entre las configuraciones exploradas, el caso base y el ranking final obtenido por cada técnica.

Tabla 4.8: Configuración de hiperparámetros para experimentos seleccionados (Telco Churn)

Exp.	Umbral IF*	Técnica	PR_dist	PR_ries	Criterio	U_den	U_ries	Tipo_P
E1	1 (1480)	*PC-SMOTE*	85	50	proporción	050	055	Upp045
E2	0 (1495)	*PC-SMOTE*	85	40	entropía	060	045	PE70

* Valor entre paréntesis indica semillas sintéticas candidatas detectadas.

Tabla 4.9: Rendimiento del Caso Base en conjunto de prueba (Telco Churn)

Configuración	Tamaño Train	Tamaño Test	F1_M	F1_W	Acc
Caso Base (Original)	5634	1409	0,711	0,782	0,790

Nota. El conjunto de entrenamiento (80 %) presenta un desbalance de clases: 4139 instancias de la clase mayoritaria (-1) y 1495 de la clase minoritaria (1).

Tabla 4.10: Rendimiento final en conjunto de prueba ordenado por F1 Macro (Telco Churn)

Ranking	Umbral IF	Técnica	Sem. Val.*	Sintet.	Train Final (Orig + Sintet.)	F1_M	Δ (F1_M)	F1_W	Acc
–	0 %	**Caso Base**	–	–	5634	0,705	–	0,779	0,789
–	1 %	**Caso Base**	–	–	5577	0,703	–	0,777	0,787
1	0 % (candidatas: 1495)	*smote*	–	2644	8278	0,713	+0,008	0,776	0,776
2		**PC-SMOTE (E2)**	**897**	**2644**	**8278**	**0.711**	**+0.006**	**0.777**	**0.780**
3		*adasyn*	–	2594	8228	0,710	+0,005	0,773	0,772
4		*borderline*	–	2644	8278	0,708	+0,003	0,770	0,768
1	1 % (candidatas: 1480)	**PC-SMOTE (E1)**	**760**	**2617**	**8194**	**0.716**	**+0.013**	**0.782**	**0.786**
2		*smote*	–	2617	8194	0,711	+0,008	0,775	0,774
3		*adasyn*	–	2535	8112	0,710	+0,006	0,772	0,770
4		*borderline*	–	2617	8194	0,704	+0,001	0,767	0,764

* Semillas candidatas validadas en *train*. Δ ($F1_M$) representa la mejora absoluta respecto al Caso Base. *Nota:* Las técnicas están ordenadas por $F1_M$ para mostrar el ranking real de *PC-SMOTE*.

En *Telco Churn*, el mejor desempeño de PC-SMOTE se obtuvo con la configuración E1 asociada a una limpieza del 1 %, criterio de pureza por proporción y umbrales PRD85/PR50/UD050/UR055, alcanzando un $F1_M$ de 0,716 frente a 0,703 del caso base del mismo bloque. La mejora fue moderada, pero consistente, y sugiere que el dataset ofrece regiones aptas para interpolar siempre que los umbrales de pureza y riesgo se ajusten con mayor precisión.

Las Tablas 4.11, 4.12 y 4.13 permiten seguir, para *US Crime*, cómo varía el rendimiento de *PC-SMOTE* al endurecer la limpieza previa y cómo se compara frente al caso base y a los métodos clásicos.

Tabla 4.11: Configuración de hiperparámetros para experimentos seleccionados (US Crime)

Exp.	Umbral IF*	Técnica	PR_dist	PR_ries	Criterio	U_den	U_ries	Tipo_P
E1	0 (120)	*PC-SMOTE*	85	40	entropía	0,45	0,45	PE80
E2	1 (118)	*PC-SMOTE*	85	40	entropía	0,35	0,45	PE60
E3	3 (116)	*PC-SMOTE*	90	45	proporción	0,35	0,50	Upp060

* Valor entre paréntesis indica semillas sintéticas candidatas detectadas.

Tabla 4.12: Rendimiento del Caso Base en conjunto de prueba (US Crime)

Configuración	Tamaño Train	Tamaño Test	F1_M	F1_W	Acc
Caso Base (Original)	1595	399	0,713	0,930	0,941

Nota. El conjunto de entrenamiento (80 %) presenta un fuerte desbalance de clases: 1475 instancias pertenecen a la clase mayoritaria (-1) y solo 120 a la clase minoritaria (1).

Tabla 4.13: Rendimiento final: Comparativa de *PC-SMOTE* vs. Técnicas Clásicas (US Crime)

Exp.	Umbral IF	Técnica	Sem. Val.*	Sintet.	Train Final (Orig + Sintet.)	F1_M	Δ (F1_M)	F1_W	Acc
–	–	**Caso Base**	–	–	1595	0,765	–	0,940	0,945
E1	0 % (candidatas: 120)	**PC-SMOTE**	**21**	**1355**	**2950**	**0.794**	**+0.029**	**0.946**	**0.950**
–		*adasyn*	–	1368	2963	0,731	−0,034	0,921	0,917
–		*smote*	–	1355	2950	0,740	−0,025	0,925	0,922
–		*borderline*	–	1355	2950	0,720	−0,045	0,921	0,920
E2	1 % (candidatas: 118)	**PC-SMOTE**	**2**	**1342**	**2920**	**0.756**	**-0.009**	**0.935**	**0.937**
–		*borderline*	–	1342	2920	0,707	−0,058	0,915	0,912
–		*smote*	–	1342	2920	0,743	−0,023	0,924	0,920
E3	3 % (candidatas: 116)	**PC-SMOTE**	**6**	**1314**	**2860**	**0.742**	**-0.024**	**0.932**	**0.935**
–		*smote*	–	1314	2860	0,715	−0,050	0,916	0,912
–		*adasyn*	–	1304	2850	0,725	−0,040	0,917	0,910
–		*borderline*	–	1314	2860	0,707	−0,059	0,913	0,907

* Semillas candidatas validadas en el conjunto de entrenamiento (*train*). Δ ($F1_M$) representa la ganancia o pérdida absoluta respecto al Caso Base. *Nota:* Los experimentos E1, E2 y E3 resaltan la variante de *PC-SMOTE* con mejor desempeño.

En *US Crime*, el efecto favorable de PC-SMOTE quedó concentrado en la configuración E1 sin limpieza previa por IF, que elevó el $F1_M$ a 0,794 frente a 0,765 del caso base. En cambio, al incrementar la limpieza, la ventaja se redujo: E2 ya no superó al *baseline* original y E3 quedó más lejos todavía. Este comportamiento sugiere que, en este conjunto, una depuración demasiado agresiva también puede eliminar semillas potencialmente útiles para la interpolación.

En conjunto, los resultados obtenidos muestran que el desempeño de *PC-SMOTE* no fue homogéneo entre los distintos conjuntos de datos analizados, sino que dependió de la estructura geométrica local de cada problema. En aquellos escenarios donde la clase minoritaria conservó suficiente cohesión y una exposición acotada a la clase mayoritaria, la técnica logró mejoras consistentes en las métricas de interés; en cambio, en contextos más ambiguos o con mayor solapamiento, su comportamiento fue más restrictivo y los beneficios resultaron más acotados. Estos hallazgos permiten establecer una base empírica para el capítulo siguiente, en el que se discutirán las implicancias de este comportamiento diferencial y su relación con los antecedentes revisados.

5. DISCUSIÓN

En este capítulo se interpretan los resultados obtenidos por PC-SMOTE en función de los experimentos realizados, sus correspondientes resultados y los antecedentes revisados. La discusión se organiza en tres ejes: la interpretación general del comportamiento de la técnica, la comparación con trabajos desarrollados sobre datasets iguales o afines y, finalmente, sus principales alcances y limitaciones.

5.1. Interpretación de los resultados de PC-SMOTE

Los resultados del capítulo anterior muestran que PC-SMOTE no tuvo un comportamiento uniforme entre datasets, sino que respondió de manera distinta según la geometría local de cada conjunto. Esta variabilidad no debe interpretarse como una inconsistencia del método, sino como un indicio de que su rendimiento depende de la estructura efectiva del vecindario sobre el cual opera. En aquellos escenarios donde la clase minoritaria conserva suficiente cohesión local y una exposición acotada a la clase mayoritaria, la interpolación sintética resulta más favorable; por el contrario, cuando predominan el solapamiento, la dispersión o la mezcla local, la técnica tiende a restringir la generación. En otras palabras, PC-SMOTE prioriza la regulación geométrica del sobremuestreo mediante filtros previos de densidad, riesgo y pureza, antes que la mera cantidad total de muestras sintéticas producidas.

Esta lógica general se refleja en las Tablas 4.7, 4.10, 4.4 y 4.13. Consideradas en conjunto, dichas evidencias muestran que las mejoras de PC-SMOTE fueron más claras cuando el conjunto de datos ofrecía regiones localmente aptas para interpolar, y que su aporte se debilitó cuando la geometría de la clase minoritaria fue demasiado ambigua o inestable. Desde esta perspectiva, el comportamiento selectivo del algoritmo constituye parte central de su propuesta: no se trata solamente de generar ejemplos nuevos, sino de establecer condiciones explícitas para decidir cuándo y dónde esa generación resulta metodológicamente razonable.

Las diferencias entre métricas también son relevantes para interpretar el conjunto de resultados. En varios experimentos, F1_W y la exactitud permanecieron elevadas incluso cuando el comportamiento sobre las clases minoritarias variaba de manera apreciable. En cambio, F1_M captó con mayor sensibilidad esos cambios y permitió distinguir con mayor precisión si el sobremuestreo contribuía efectivamente a mejorar el reconocimiento de las clases de menor representación. Por esta razón, en esta tesis se adoptó F1_M como criterio principal de comparación, mientras que F1_W y la exactitud se utilizaron como medidas complementarias para examinar si esa mejora local también se trasladaba al rendimiento global.

En conjunto, estos resultados refuerzan una idea central de la tesis: el aporte de PC-SMOTE no radica solamente en producir nuevos ejemplos, sino en introducir un criterio geométrico explícito para decidir cuándo y dónde esa producción resulta razonable. La recurrencia de configuraciones con exigencia de cohesión local, control del riesgo y filtros de pureza relativamente estrictos sugiere que el método tiende a favorecer una interpolación prudente. Esa prudencia puede traducirse en ganancias moderadas pero consistentes cuando la estructura del conjunto lo permite y, al mismo tiempo, en una restricción deliberada de la generación cuando la vecindad no ofrece condiciones suficientemente confiables.

5.2. Comparación con estudios sobre datasets afines

La comparación con trabajos previos desarrollados sobre datasets iguales o afines presenta una limitación evidente: no todos comparten el mismo clasificador, las mismas métricas ni el mismo protocolo experimental. En varios antecedentes, las métricas reportadas son exactitud, precisión o un $F1$-score no especificado como macro o ponderado, mientras que en esta tesis la referencia principal es F1_M. Por ello, las comparaciones numéricas solo se realizan cuando el dataset coincide y la métrica permite una lectura razonable; en los demás casos, la comparación es contextual.

En el caso de *Telco Churn*, los antecedentes localizados son útiles porque emplean el mismo conjunto de datos de IBM disponible en Kaggle. Nalatissifa y Pardede [19] trabajaron sobre ese dataset con un enfoque centrado en *deep neural networks* y ajuste de hiperparámetros, reportando una exactitud de 83,09 %. Más recientemente, Agrawal et al. [1] utilizaron también el mismo dataset y propusieron una estrategia híbrida basada en SMOTE y GAN. En ese trabajo, el mejor resultado con *Random Forest* y *SMOTified-GAN* alcanzó una exactitud de 77,53 % y una precisión de 85,37 % para la clase churn. En esta tesis, la mejor configuración de PC-SMOTE sobre *Telco Churn* obtuvo un F1_M de 71,6 %, un F1_W de 78,2 % y una exactitud de 78,6 %. La comparación directa de precisión no es posible porque esa métrica no fue reportada bajo el mismo protocolo experimental; sin embargo, los valores de exactitud muestran que el rendimiento global queda en un rango cercano al de Agrawal et al., mientras que F1_M permite aquí observar con mayor detalle el efecto del método sobre la clase minoritaria.

En *Predict Faults*, la referencia más cercana identificada es el trabajo de Yang y Wang [35], quienes utilizaron el dataset *Machine Predictive Maintenance Classification* dentro de un estudio comparativo entre modelos, encontrando en *Random Forest* el mejor desempeño global. Ese trabajo reporta para *Random Forest* una exactitud de 99,5 %, una precisión de 99,28 %, un *recall* de 99,5 % y un $F1$-score de aproximadamente 99,38 %. En los experimentos de esta tesis, el caso base sobre el mismo dataset alcanzó un F1_W de 98,2 % y una exactitud de 98,4 %, también muy altos, pero el F1_M fue de 85,9 % y ninguna variante de sobremuestreo logró superarlo. Esta diferencia entre métricas sugiere que el dataset puede mostrar un rendimiento casi perfecto cuando se analiza con medidas globales o ponderadas, aunque la clase de falla continúa siendo más exigente cuando se utiliza una métrica balanceada entre clases.

Para *Shuttle*, la comparación con trabajos previos debe realizarse con cautela, debido a que varios antecedentes reportan principalmente exactitud global y no métricas macro orientadas a clases minoritarias. Aun así, el trabajo de Sainin et al. [26] constituye una referencia útil, ya que utiliza *Statlog (Shuttle)* como benchmark multiclase desbalanceado y evalúa combinaciones de remuestreo, SMOTE, ensambles y *Random Forest*. En dicho estudio, los modelos basados en *Random Forest* alcanzan exactitudes muy elevadas sobre Shuttle, cercanas a 99,99 % sin remuestreo y entre 99,83 % y 99,93 % al combinar remuestreo con ensambles. Este comportamiento es consistente con los resultados de esta tesis, donde Shuttle también alcanzó valores prácticamente perfectos de exactitud y F1_W. Sin embargo, esa coincidencia debe interpretarse como una validación del alto rendimiento global del clasificador sobre el dataset, no como evidencia suficiente de buen comportamiento sobre todas las clases.

Por ese motivo, la comparación más relevante en esta tesis se desplaza desde la exactitud hacia F1_M. En Shuttle, PC-SMOTE alcanzó un F1_M de 95,0 % en la configuración E1 con 1 % de limpieza, igualando a SMOTE en el mismo bloque experimental, aunque quedando por debajo de ADASYN y Borderline-SMOTE, que alcanzaron un F1_M de

99,1 %. Esta diferencia muestra que, aunque PC-SMOTE logra sostener el rendimiento global observado también en la literatura, su comportamiento macro revela una contribución competitiva pero no dominante frente a técnicas clásicas más agresivas. En este sentido, Shuttle funciona como un caso especialmente útil para la discusión: la exactitud confirma comparabilidad con antecedentes externos, mientras que F1_M permite observar diferencias que la exactitud tiende a ocultar en contextos multiclase severamente desbalanceados.

Esta lectura también es compatible con el análisis de Fachrie et al. [6], quienes identifican a *Shuttle* como uno de los datasets multiclase más desbalanceados dentro de su revisión, con un índice de desbalance de 853,0 y una exactitud promedio balanceada de referencia de 87,7 %. Ese índice se obtiene como la razón entre la clase más numerosa y la clase menos representada en la versión de Shuttle utilizada por dichos autores (1706/2 = 853,0). En esta tesis se trabajó con la versión completa de Shuttle, cuya clase mayoritaria contiene 45586 instancias y cuya clase más pequeña contiene 10, por lo que el desbalance máximo es aún más severo (45586/10 = 4558,6). Aunque la formulación experimental de Fachrie et al. no coincide exactamente con la utilizada aquí, el trabajo refuerza la pertinencia de evaluar Shuttle mediante métricas sensibles al desempeño por clase y no solo mediante exactitud global.

De forma complementaria, Malyarchuk [18] trabaja sobre Shuttle completo y evalúa tanto modelos basados en XGBoost como arquitecturas que incorporan BorderlineSMOTE. Su pipeline está documentado: parte de la división original de Shuttle en entrenamiento y prueba, recompone el conjunto para normalizar las variables numéricas y luego lo vuelve a dividir de forma estratificada en una proporción 80/20, conservando 46400 instancias para entrenamiento y 11600 para prueba. En particular, reporta para XGBoost aplicado sobre los datos originales preprocesados una exactitud de 99,97 %, un WAF1 de 99,97 % y un MAF1 de 95,01 %; WAF1 corresponde a *Weighted Average F1 Score*, equivalente conceptual al F1_W utilizado en esta tesis, mientras que MAF1 corresponde a *Macro Average F1 Score*, equivalente al F1_M. Además, una de sus arquitecturas con BorderlineSMOTE y XGBoost alcanza en Shuttle un WAF1 de 99,94 % y un MAF1 de 96,60 %. Este punto resulta especialmente relevante porque en esta tesis Borderline-SMOTE con *Random Forest* obtuvo un F1_W de 100,0 % y un F1_M de 99,1 % en el mismo dataset. Aunque ambos resultados no son directamente equivalentes por diferencias en el clasificador y en el pipeline de modelado, la cercanía metodológica permite una comparación más informativa que la basada solo en exactitud: en ambos casos se trabaja sobre Shuttle completo, se utiliza una división 80/20 entre entrenamiento y prueba, se emplea una variante de SMOTE orientada a frontera y se reportan métricas macro y ponderadas sensibles al desempeño de las clases. Desde esta perspectiva, los resultados obtenidos por PC-SMOTE no deben interpretarse únicamente por su exactitud perfecta, sino por su capacidad de mejorar F1_M respecto del caso base en el bloque con 1 % de limpieza, pasando de 83,1 % a 95,0 %, bajo una estrategia de generación regulada por filtros de densidad, riesgo y pureza.

En *US Crime*, la comparación también requiere distinguir entre dataset, formulación del objetivo y métrica utilizada. La referencia más cercana es el trabajo de Sonoda [30], que utiliza *Communities and Crime* en un problema de clasificación binaria y define la clase de crimen elevado a partir del percentil 70 de la tasa de criminalidad. En ese estudio, la utilidad predictiva se reporta mediante *balanced accuracy*: para *Logistic Regression*, SMOTE alcanza 84,77 %; para SVM, 84,79 %; y para *Naive Bayes*, 72,38 %. Esta métrica no es equivalente a F1_W: la *balanced accuracy* promedia el *recall* de las clases, mientras que F1_W promedia el F1 de cada clase ponderado por su frecuencia. Por lo tanto, esos valores no son directamente comparables con el F1_M ni con el F1_W utilizados en esta

tesis, pero permiten ubicar los resultados de PC-SMOTE dentro de una familia de problemas comparables sobre el mismo dominio. En particular, esta tesis utiliza una versión experimental ya binarizada y más severamente desbalanceada de US Crime, con 1844 instancias mayoritarias y 150 minoritarias; en ese escenario, PC-SMOTE alcanzó un F1_M de 79,4 %, un F1_W de 94,6 % y una exactitud de 95,0 % en el bloque sin limpieza previa.

Resulta relevante, además, que la formulación de Sonoda [30] también recurre a un criterio percentilar, aunque con una función distinta a la empleada por PC-SMOTE. En su caso, el percentil 70 se utiliza para definir el umbral de crimen elevado y construir la variable objetivo binaria; en esta tesis, en cambio, los percentiles operan dentro del algoritmo como mecanismo de autocalibración geométrica para definir radios de densidad y riesgo. Esta diferencia impide una comparación metodológica directa, pero establece una cercanía conceptual: en ambos casos, el percentil permite adaptar la definición operativa del problema a la distribución observada de los datos.

Otros antecedentes sobre *Communities and Crime* aportan evidencia complementaria, aunque con menor comparabilidad directa. Kerdprasop y Kerdprasop [14] estudian la generación de modelos predictivos en datos altamente desbalanceados e incluyen *communities-and-crime* dentro de sus experimentos, mostrando que el uso de técnicas de sobremuestreo puede mejorar indicadores como sensibilidad, especificidad y medidas tipo F sobre clases raras. No obstante, parte de sus resultados se presenta de forma gráfica y bajo un protocolo distinto, por lo que su utilidad principal es tendencial. Por su parte, Cavadas et al. [3] emplean *Communities and Crime Unnormalized* en una formulación de regresión para predecir crimen violento y aplican SmoteR para tratar valores raros extremos. Aunque SmoteR está emparentado con la familia SMOTE, su adaptación a regresión impide una comparación directa con F1_M. No obstante, el antecedente resulta relevante porque trabaja en el mismo dominio de criminalidad y muestra que el tratamiento explícito de casos raros mejora el desempeño predictivo: de acuerdo con los boxplots reportados, el F-measure de RF con SmoteR se ubica aproximadamente en torno a 76 %–77 %, frente a valores cercanos a 72 %–73 % para RF sin SmoteR. En esta tesis, PC-SMOTE alcanzó en US Crime un F1_M de 79,4 % con *Random Forest*; aunque se trata de una métrica y una formulación experimental distintas, la proximidad entre ambos rangos resulta informativa, ya que en los dos casos el tratamiento de regiones raras o minoritarias del dominio de criminalidad se asocia con mejoras de desempeño. En conjunto, estos antecedentes permiten sostener la inclusión de US Crime en la discusión, siempre que la comparación se presente como contextual y no como un ranking directo entre métodos.

5.3. Limitaciones e implicancias

Los resultados analizados permiten delimitar con mayor precisión el alcance de PC-SMOTE. La técnica se orienta a escenarios donde la generación sintética puede beneficiarse de una lectura local de la geometría de los datos y donde resulta importante regular el proceso de interpolación. Por ello, sus implicancias principales se relacionan con el modo en que el método identifica regiones aptas para generar nuevas instancias, más que con la simple ampliación cuantitativa de la clase minoritaria.

Desde el punto de vista metodológico, PC-SMOTE funciona como una estrategia de sobremuestreo selectiva. Su mecanismo regula la interpolación a partir de la estructura local de los datos, combinando información de vecindad, criterios percentilares y filtros de densidad, riesgo y pureza. Esta decisión de diseño explica que su comportamiento pueda diferir del de técnicas más expansivas como SMOTE, ADASYN o Borderline-SMOTE: mientras estas cubren con mayor amplitud la clase minoritaria, PC-SMOTE prioriza la

generación en regiones consideradas localmente más confiables.

Un aspecto adicional de esta formulación es su bajo costo computacional relativo. PC-SMOTE no incorpora arquitecturas de aprendizaje profundas, procesos iterativos de optimización ni modelos auxiliares complejos para decidir la generación sintética. Su funcionamiento se apoya en operaciones simples y transparentes: búsqueda de vecinos, cálculo de percentiles, evaluación de densidad, riesgo y pureza, e interpolación local entre instancias. Esta simplicidad favorece su implementación, facilita la interpretación de sus decisiones y permite integrarlo como etapa de preprocesamiento sin introducir una carga computacional excesiva frente al entrenamiento posterior del clasificador.

En datasets donde la clase minoritaria presenta suficiente cohesión local, como ocurrió especialmente en *US Crime* y *Telco Churn*, la regulación geométrica permitió obtener mejoras relevantes sin deteriorar de manera marcada el rendimiento global. En *Shuttle*, la comparación con ADASYN y Borderline-SMOTE muestra valores superiores de F1_M para estrategias de generación más expansivas. En ese contexto, PC-SMOTE ofrece una lectura complementaria: sostiene un desempeño competitivo bajo un enfoque que privilegia la calidad geométrica de la interpolación y el control de las regiones sintéticas generadas.

Esta característica tiene una implicancia práctica relevante. El patrón de semillas aceptadas, semillas rechazadas y regiones finalmente utilizadas para generar sintéticos aporta información sobre la estructura del dataset. Una concentración alta de rechazos o una generación localizada en pocas zonas puede indicar dispersión, solapamiento o contaminación local de la clase minoritaria. En esos casos, el comportamiento de PC-SMOTE puede orientar decisiones complementarias, como ingeniería de atributos, limpieza estructural, ajuste del clasificador o estrategias sensibles al costo.

En síntesis, la discusión desarrollada en este capítulo sugiere que PC-SMOTE aporta una contribución específica dentro del aprendizaje con datos desbalanceados: una heurística geométrica basada en percentiles que introduce condiciones explícitas para decidir cuándo y dónde generar nuevas instancias. Sus resultados se interpretan tanto por las mejoras obtenidas en F1_M como por la capacidad del método para controlar la interpolación en función de la confiabilidad local de los datos. De este modo, PC-SMOTE se posiciona como una alternativa regulada dentro de la familia de técnicas SMOTE, especialmente pertinente cuando se busca mejorar el desempeño sobre clases minoritarias sin perder de vista la calidad de las regiones sintéticas generadas.

6. CONCLUSIONES Y TRABAJOS FUTUROS

6.1. Conclusiones

A partir de los resultados experimentales y de la discusión desarrollada en el capítulo anterior, puede afirmarse que la presente investigación abordó uno de los desafíos más persistentes del aprendizaje automático supervisado: la degradación del rendimiento de los clasificadores cuando el desbalance de clases coexiste con solapamiento estructural, ruido y vecindarios localmente ambiguos. Para responder a este problema se desarrolló y validó *PC-SMOTE* (*Percentile-Controlled SMOTE*), una variante de SMOTE orientada a regular el proceso de sobremuestreo mediante una heurística geométrica basada en percentiles.

La principal contribución del trabajo radica en proponer una estrategia que no solo define cómo generar muestras sintéticas, sino también cuándo conviene hacerlo. En lugar de interpolar de manera uniforme sobre toda la clase minoritaria, *PC-SMOTE* calibra radios de densidad y riesgo a partir de la distribución empírica de distancias y valida semillas candidatas mediante criterios combinados de densidad, exposición a la clase mayoritaria y pureza local. Esta decisión previa permitió convertir el sobremuestreo en un proceso más selectivo e interpretable.

En los experimentos realizados con *Random Forest* sobre conjuntos de datos reales, *PC-SMOTE* mostró un comportamiento diferenciado según la geometría local de cada dataset. En *US Crime* y *Telco Churn* produjo mejoras frente al caso base y frente a las variantes clásicas mejor posicionadas en cada configuración. En *Shuttle* alcanzó un desempeño competitivo, aunque por debajo de los métodos más agresivos en cobertura de clases raras. En *Predict Faults*, finalmente, actuó de forma deliberadamente conservadora: fue la mejor alternativa entre los métodos sintéticos evaluados, pero sin superar al *baseline*. Este patrón refuerza la idea de que la utilidad del sobremuestreo depende de la calidad geométrica de las semillas disponibles y no solo de la cantidad total de sintéticos generados.

La discusión con la literatura también permitió ubicar a *PC-SMOTE* dentro de la evolución reciente de las variantes geométricas de SMOTE. Frente a enfoques como *Radius-SMOTE*, *LD-SMOTE* y *VS-SMOTE*, la propuesta presentada se distingue por articular en una misma regla de decisión la densidad, el riesgo y la pureza, y por calibrar la noción de cercanía a partir de percentiles observados en el propio dataset. En este sentido, el aporte de *PC-SMOTE* no consiste únicamente en generar nuevos ejemplos, sino en transformar la interpolación en una decisión geométrica explícita y dependiente del contexto.

En síntesis, los resultados obtenidos permiten sostener que *PC-SMOTE* constituye una extensión válida de SMOTE para escenarios donde la estructura local del espacio de atributos resulta decisiva. Su principal fortaleza reside en combinar adaptabilidad, interpretabilidad y prudencia geométrica. Al mismo tiempo, sus límites muestran que no todo conjunto desbalanceado debe necesariamente sobremuestrearse, y que en algunos casos el mayor aporte del método puede ser precisamente advertir cuándo la interpolación deja de ser aconsejable.

6.2. Trabajos Futuros

A partir de estas conclusiones, se proponen las siguientes líneas de investigación:

- **Selección asistida del percentil de densidad y perfiles de rigor:** Se propone explorar procedimientos automáticos o asistidos para la selección del percentil de

densidad que actualmente debe ser definido por el usuario. Dado que este percentil determina el radio global de vecindad empleado en la selección de semillas y en la generación de muestras sintéticas, su elección podría estimarse a partir del análisis de la curva de distorsión construida sobre las distancias intra-clase. Sobre esta base, podrían definirse perfiles de rigor preestablecidos (e.g., *Light, Medium, Hard*) que traduzcan dicha recomendación en distintos niveles interpretables de exigencia geométrica.

- **PC-SMOTE como apoyo al análisis geométrico del dataset:** Como línea de trabajo futura, se plantea transformar la técnica en un asistente de decisión. Ante un dataset nuevo, PC-SMOTE podría realizar un análisis geométrico preliminar para orientar la elección entre sobremuestreo, ingeniería de atributos u otras estrategias metodológicas.

- **Selección del percentil de pureza mediante entropía:** Si bien PC-SMOTE ya emplea la entropía de Shannon como una métrica de pureza, el percentil utilizado para definir el umbral de aceptación de vecindarios continúa siendo un hiperparámetro ingresado manualmente por el usuario. Como línea futura, se propone automatizar la selección de dicho percentil a partir de un criterio geométrico o empírico. En lugar de fijar un valor arbitrario, el algoritmo podría explorar un rango discreto de percentiles y seleccionar aquel que maximice el equilibrio entre cobertura de semillas candidatas y homogeneidad local de los vecindarios aceptados.

Bibliografía

[1] Agrawal, R., Hamdare, S., Ghosh, D., et al. Improving predictive performance in telecom churn modeling with hybrid smote and gan-based synthetic data generation. *International Journal of Computational Intelligence Systems 19* (2026), 141. URL: https://doi.org/10.1007/s44196-026-01204-3.

[2] Carvalho, M., Pinho, A. J., and Brás, S. Resampling approaches to handle class imbalance: a review from a data perspective. *Journal of Big Data 12* (2025), 71. URL: https://doi.org/10.1186/s40537-025-01119-4.

[3] Cavadas, B., Branco, P., and Pereira, S. Crime prediction using regression and resources optimization. In *Progress in Artificial Intelligence: 17th Portuguese Conference on Artificial Intelligence, EPIA 2015* (2015), Springer, pp. 513–525. URL: https://www.researchgate.net/profile/Paula-Branco/publication/281450865_Crime_Prediction_Using_Regression_and_Resources_Optimization/links/59d1f76ea6fdcc181ad5dc44/Crime-Prediction-Using-Regression-and-Resources-Optimization.pdf.

[4] Chawla, N. V., Bowyer, K. W., Hall, L. O., and Kegelmeyer, W. P. Smote: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research 16* (2002), 321–357. URL: https://doi.org/10.1613/jair.953.

[5] Douzas, G., and Bacao, F. Geometric SMOTE: Effective oversampling for imbalanced learning through a geometric extension of SMOTE. *arXiv preprint arXiv:1709.07377* (2017). URL: https://arxiv.org/pdf/1709.07377.

[6] Fachrie, M., Musdholifah, A., and Pulungan, R. Effectiveness of data resampling and ensemble learning in multiclass imbalance learning. *Artificial Intelligence Review 58* (2025), 368. URL: https://link.springer.com/content/pdf/10.1007/s10462-025-11357-w.pdf.

[7] Feng, Y., and Li, J. A novel αDistance Borderline-ADASYN-SMOTE algorithm for imbalanced data and its application in Alzheimer's disease classification based on Dense Convolutional Network. In *Journal of Physics: Conference Series* (2021), vol. 2031, IOP Publishing, p. 012046. URL: https://iopscience.iop.org/article/10.1088/1742-6596/2031/1/012046/pdf.

[8] Fernández, A., García, S., Galar, M., Prati, R. C., Krawczyk, B., and Herrera, F. *Learning from Imbalanced Data Sets*. Springer, 2018. URL: https://doi.org/10.1007/978-3-319-98074-4.

[9] Galar, M., Fernández, A., Barrenechea, E., Bustince, H., and Herrera, F. A review on ensembles for the class imbalance problem: Bagging-, boosting-, and hybrid-based approaches. *IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews) 42*, 4 (2012), 463–484. URL: https://doi.org/10.1109/TSMCC.2011.2161285.

[10] Han, H., Wang, W.-Y., and Mao, B.-H. Borderline-smote: a new over-sampling method in imbalanced data sets learning. In *Advances in Intelligent Computing: Inter-*

national Conference on Intelligent Computing, ICIC 2005 (2005), Springer, pp. 878–887. URL: https://doi.org/10.1007/11538059_91.

[11] He, H., Bai, Y., Garcia, E. A., and Li, S. Adasyn: Adaptive synthetic sampling approach for imbalanced learning. In *2008 IEEE International Joint Conference on Neural Networks* (2008), IEEE, pp. 1322–1328. URL: https://doi.org/10.1109/IJCNN.2008.4633969.

[12] Kaggle. Telco customer churn. https://www.kaggle.com/datasets/blastchar/telco-customer-churn, 2018.

[13] Kaggle. Machine predictive maintenance classification. https://www.kaggle.com/datasets/shivamb/machine-predictive-maintenance-classification, 2020.

[14] Kerdprasop, N., and Kerdprasop, K. On the generation of accurate predictive model from highly imbalanced data with heuristics and replication techniques. *International Journal of Bio-Science and Bio-Technology 4*, 1 (2012), 11–22. URL: https://gvpress.com/journals/IJBSBT/vol4_no1/4.pdf.

[15] Khorshidi, H. A., and Aickelin, U. A synthetic over-sampling method with minority and majority classes for imbalance problems. *Knowledge and Information Systems 67* (2025), 5965–5998. URL: https://doi.org/10.1007/s10115-025-02394-6.

[16] Lemaître, G., Nogueira, F., and Aridas, C. K. Imbalanced-learn: A python toolbox to tackle the curse of imbalanced datasets in machine learning. *Journal of Machine Learning Research 18*, 17 (2017), 1–5. URL: https://jmlr.org/papers/v18/16-365.html.

[17] Lyu, J., Yang, J., Su, Z., and Zhu, Z. Ld-smote: A novel local density estimation-based oversampling method for imbalanced datasets. *Symmetry 17*, 2 (2025), 160. URL: https://doi.org/10.3390/sym17020160.

[18] Malyarchuk, V. Developing a general neural network architecture for solving multi-class classification problems in imbalanced multivariate data. Master's thesis, TU Dortmund University, Faculty of Computer Science, Chair of Enterprise Computing, 2025. Master's thesis. URL: https://eldorado.tu-dortmund.de/server/api/core/bitstreams/ee8dedde-9b7a-47c0-9049-73cf8c30f532/content.

[19] Nalatissifa, H., and Pardede, H. F. Predicting telco customer churn by applying deep neural network optimization. *Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi) 5*, 5 (2021), 959–966. URL: https://doi.org/10.29207/resti.v5i5.3436.

[20] Nasaruddin, N., Masseran, N., Idris, W. M. R., and Ul-Saufie, A. Z. A smote pca hdbscan approach for enhancing water quality classification in imbalanced datasets. *Scientific Reports 15* (2025), 13059. URL: https://doi.org/10.1038/s41598-025-97248-0.

[21] Park, H., and Kim, H. AR-ADASYN: angle radius-adaptive synthetic data generation approach for imbalanced learning. *Statistics and Computing 34*, 5 (2024), 166. URL: https://doi.org/10.1007/s11222-024-10479-5.

[22] Poddar, G. M., Patil, R. V., and Kumar N, S. Approaches to handle data imbalance problem in predictive machine learning models: A comprehensive review. *International Journal of Intelligent Systems and Applications in Engineering 12*, 21s (2024), 841–856. URL: https://www.academia.edu/117048787.

[23] Pradipta, G. A., Wardoyo, R., Musdholifah, A., and Sanjaya, I. N. H. Radius-SMOTE: A new oversampling technique of minority samples based on radius distance for learning from imbalanced data. *IEEE Access 9* (2021), 74763–74777. URL: https://ieeexplore.ieee.org/stamp/stamp.jsp?arnumber=9431216.

[24] Probst, P., Wright, M. N., and Boulesteix, A.-L. Hyperparameters and tuning strategies for random forest. *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery 9*, 3 (2019), e1301. URL: https://doi.org/10.1002/widm.1301.

[25] Qiu, F., Yang, F., Xiong, Y., Chen, T., Xiao, P., Zheng, W., Chen, X., and Zhou, K. Vs-smote: Leveraging high-value spaces to balance noise control and data diversity for class-imbalanced learning. *Neurocomputing* (2025). URL: https://papers.ssrn.com/sol3/Delivery.cfm?abstractid=5234376.

[26] Sainin, M. S., Alfred, R., Adnan, F., and Ahmad, F. Combining sampling and ensemble classifier for multiclass imbalance data learning. In *Intelligent and Interactive Computing* (2018), vol. 488 of *Lecture Notes in Electrical Engineering*, Springer, pp. 262–272. URL: https://www.researchgate.net/profile/Rayner_Alfred/publication/323360636_Combining_Sampling_and_Ensemble_Classifier_for_Multiclass_Imbalance_Data_Learning/links/5e40f38d299bf1cdb91be62f/Combining-Sampling-and-Ensemble-Classifier-for-Multiclass-Imbalance-Data-Learning.pdf.

[27] Santos, M. S., Abreu, P. H., Japkowicz, N., Fernández, A., and Santos, J. A unifying view of class overlap and imbalance: Key concepts, multi-view panorama, and open avenues for research. *Information Fusion 89* (2023), 228–253. URL: https://sci2s.ugr.es/sites/default/files/ficherosPublicaciones/2997_2022-INFFUS-Unifying%20view%20overlap.pdf.

[28] Saputra, D. C. E., Sunat, K., and Ratnaningsih, T. Smote-mrs: A novel smote-multiresolution sampling technique for imbalanced distribution to improve prediction of anemia. *IEEE Access 12* (2024), 154675–154701. URL: https://ieeexplore.ieee.org/stamp/stamp.jsp?arnumber=10721227.

[29] Shannon, C. E. A mathematical theory of communication. *The Bell System Technical Journal 27*, 3 (1948), 379–423.

[30] Sonoda, R. Fair oversampling technique using heterogeneous clusters. *arXiv preprint arXiv:2305.13875* (2023). URL: https://arxiv.org/pdf/2305.13875.

[31] UCI Machine Learning Repository. Statlog (shuttle) data set. https://archive.ics.uci.edu/dataset/148/statlog+shuttle, 1993.

[32] UCI Machine Learning Repository. Communities and crime data set. https://archive.ics.uci.edu/dataset/183/communities+and+crime, 2009.

[33] Wang, J., and Awang, N. Ch-smote algorithm: A novel approach to improve random forest classification on class imbalanced datasets. *Journal of Computational Analysis and Applications 33*, 7 (2024), 1331–1349. URL: https://eudoxuspress.com/index.php/pub/article/view/1234.

[34] Wang, J., and Awang, N. A novel synthetic minority oversampling technique for multiclass imbalance problems. *IEEE Access 13* (2025). URL: https://www.researchgate.net/publication/387809455.

[35] Yang, Y., and Wang, Y. Machine failure prediction using machine learning models on predictive maintenance data. *Scientific Reports* (2025). Referencia utilizada para el dataset Machine Predictive Maintenance Classification.